

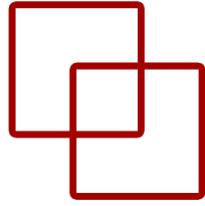
Improving Deep Learning by Exploiting Synthetic Images



Dr. Manuel Castillo-Cara
www.manuelcastillo.eu

Departamento de Inteligencia Artificial
Escuela Técnica Superior de Ingeniería Informática
Universidad Nacional de Educación a Distancia (UNED)

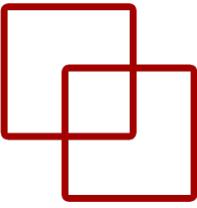
Preliminar



- Improving Deep Learning by Exploiting Synthetic Images © 2024 by Manuel Castillo-Cara is licensed under Attribution-NonCommercial 4.0 International



Índice



- Background
- Arquitecturas unitarias
- Assessment Criteria
- Métodos de conversión
- TINTOlib
- Arquitecturas Híbridas
- Use cases

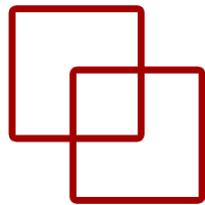
Background

ETS de
Ingeniería
Informática



UNED

Regression vs. Classification



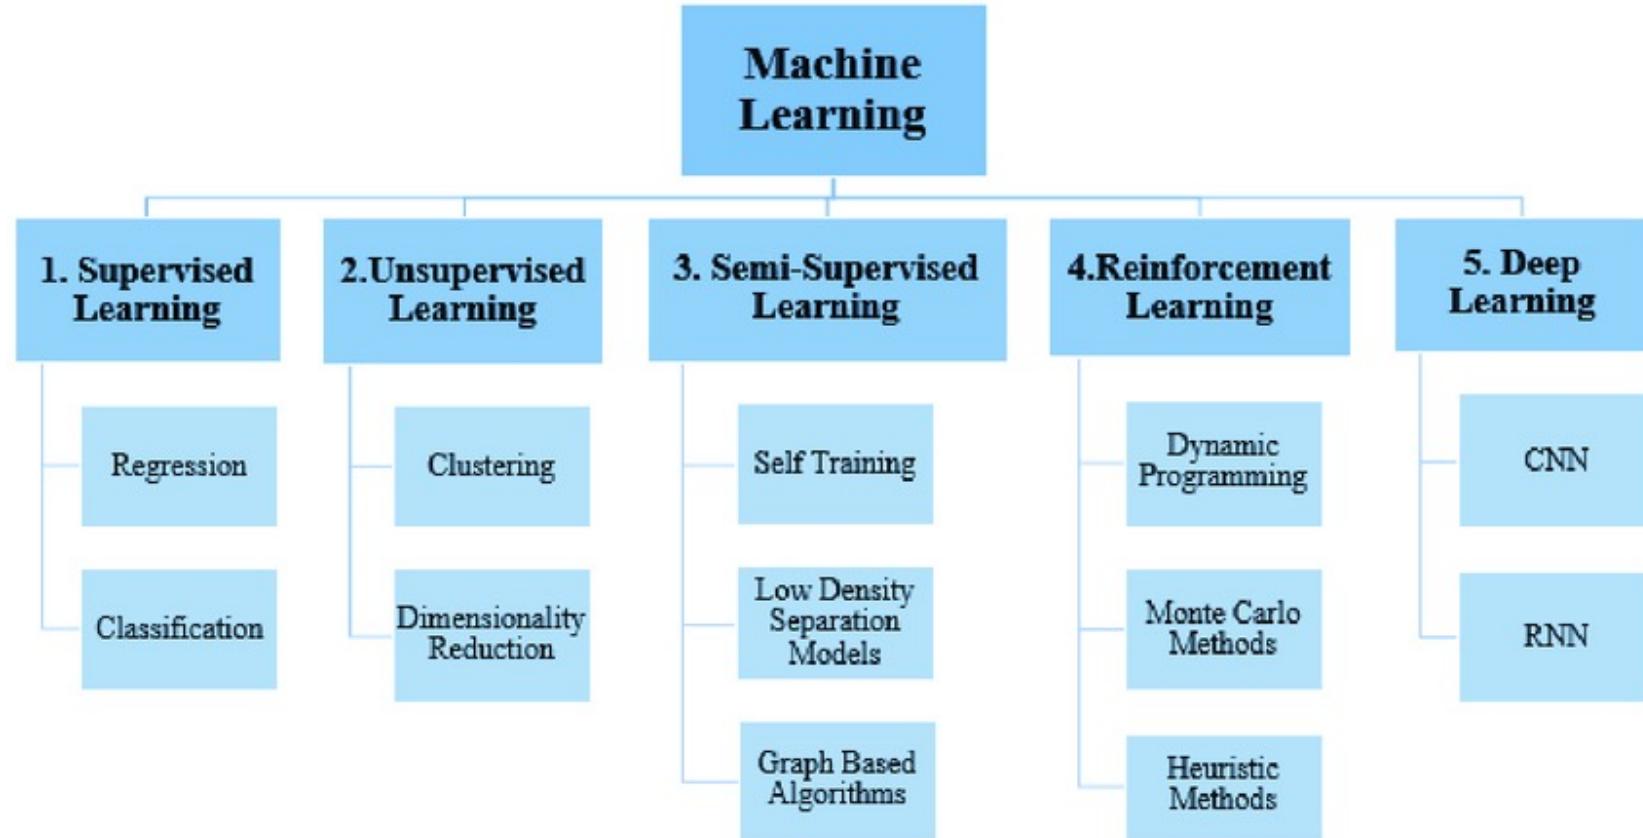
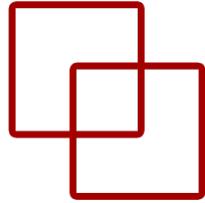
	A	B	C	D	E	F	G	H	I	
1	preg	plas	pres	skin	insu	mass	pedi	age	class	
2	1	85	66	29	0	26.6	351	31	tested_negative	
3	5	116	74	0	0	25.6	201	30	tested_negative	
4	10	115	0	0	0	35.3	134	29	tested_negative	
5	4	110	92	0	0	37.6	191	30	tested_negative	
6	10	139	80	0	0	27.1	1441	57	tested_negative	
7	8	99	84	0	0	35.4	388	50	tested_negative	
8	5	117	92	0	0	34.1	337	38	tested_negative	
9	5	109	75	26	0	36	546	60	tested_negative	

Classification

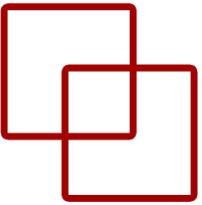
Regression

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
1	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	class
2	0.00632	18.231		0	538	6575	65.2	4.09	1	296	15.3	396.9	4.98	24
3	0.02731	0.707		0	469	6421	78.9	4.9671	2	242	17.8	396.9	9.14	21.6
4	0.02729	0.707		0	469	7185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
5	0.03237	0.218		0	458	6998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
6	0.06905	0.218		0	458	7147	54.2	6.0622	3	222	18.7	396.9	5.33	36.2
7	0.02985	0.218		0	458	6.43	58.7	6.0622	3	222	18.7	394.12	5.21	28.7

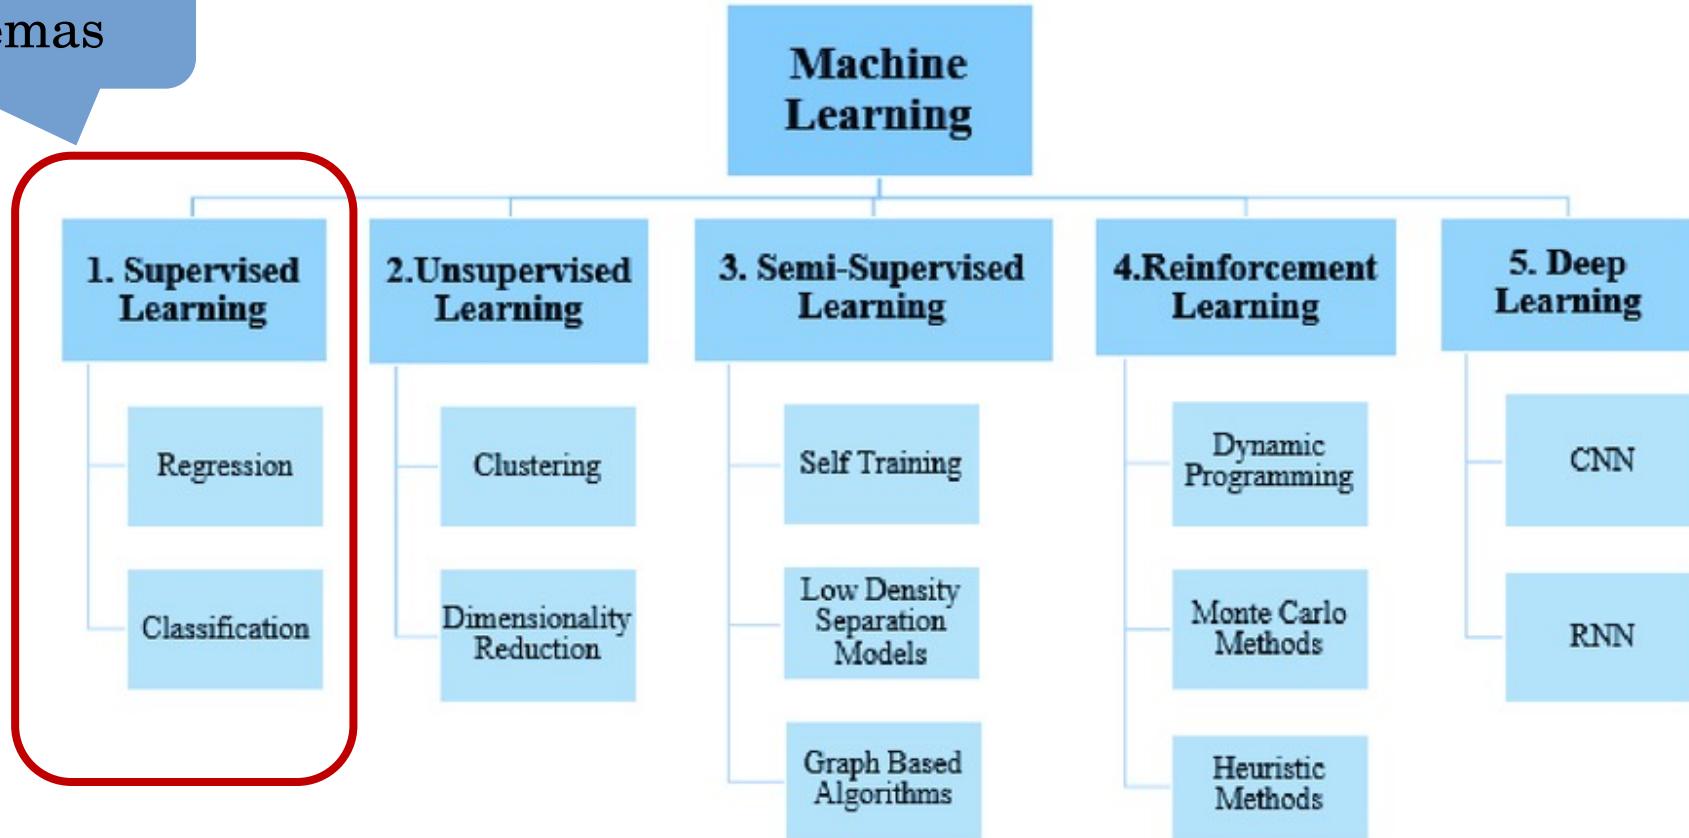
Machine Learning



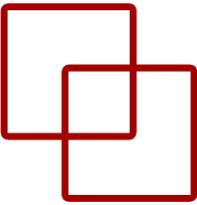
Machine Learning



Vamos a resolver
estos problemas

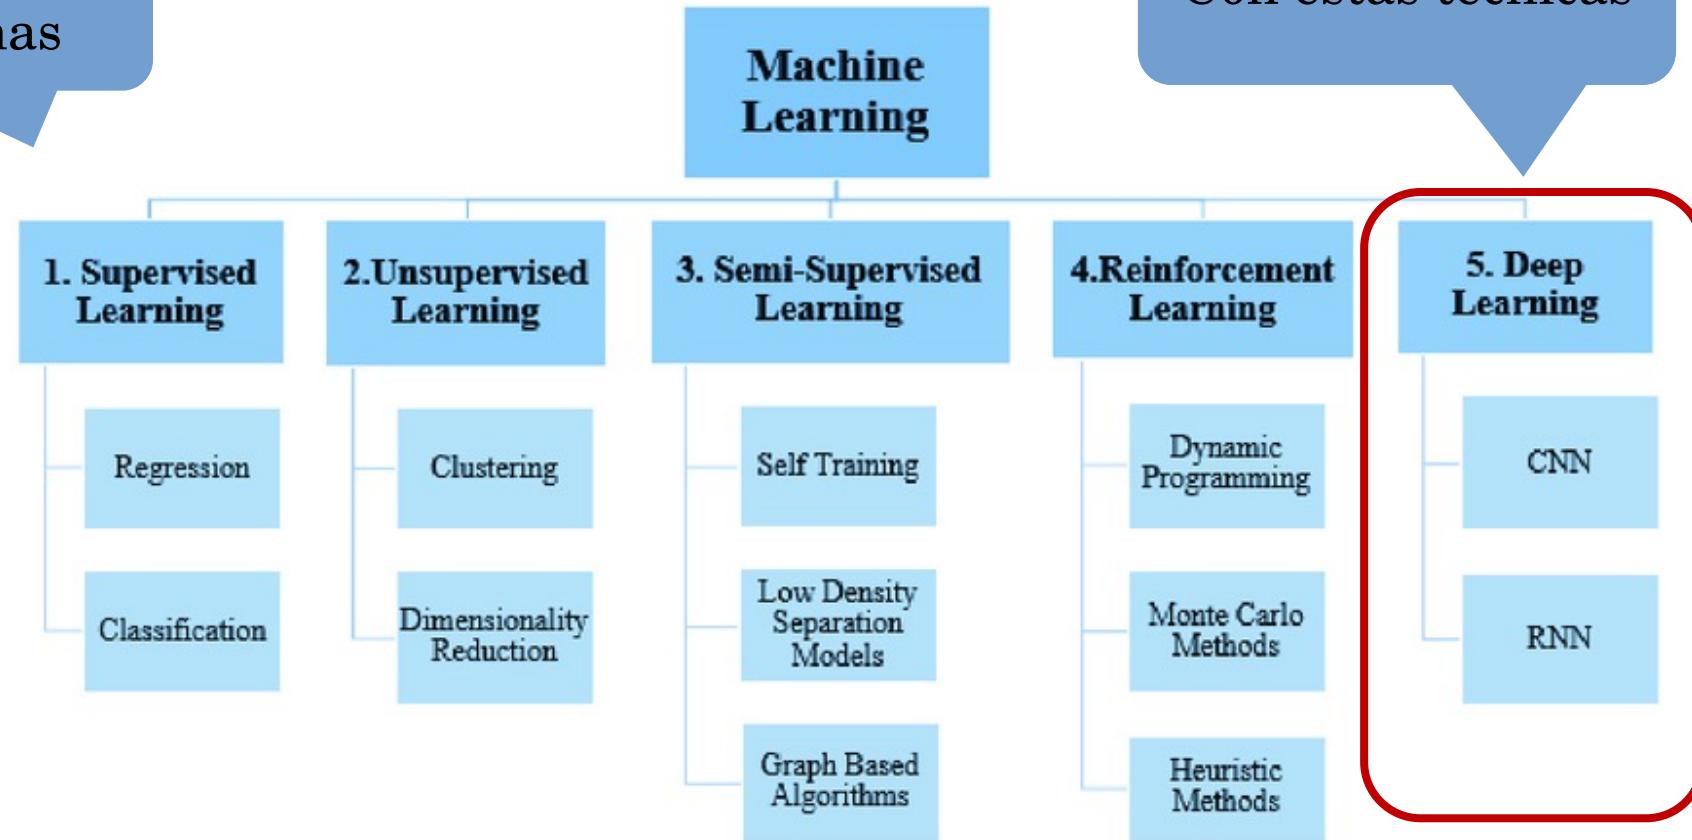


Machine Learning

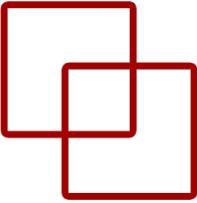


Vamos a resolver
estos problemas

Con estas técnicas

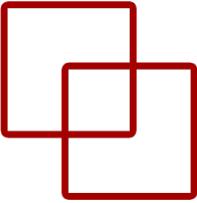


Problema de investigación abierto



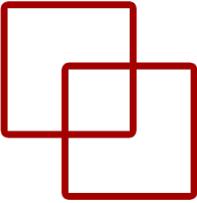
- Kadra et al. nombró datasets como “*last unconquered castle*” para modelos basados en Deep Neural Networks (DNN).
- La adaptación de las DNN a Datos Tabulares (TD) para tareas de inferencia o generación de datos sigue siendo un **gran desafío**.

Problema de investigación abierto



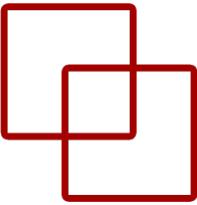
- Kadra et al. nombró datasets como “***last unconquered castle***” para modelos basados en Deep Neural Networks (DNN).
- La adaptación de las DNN a Datos Tabulares (TD) para tareas de inferencia o generación de datos sigue siendo un **gran desafío**.
- Vadim Borísov et al. hacen un benchmark de diferentes métodos/datasets entre ensembles vs. DNN y **ganar los ensembles**. De hecho, afirman:
 - “El progreso de la investigación sobre modelos competitivos de aprendizaje profundo para datos tabulares **se está estancando**”.
 - “Es un **área de investigación abierta**”.

Problema de investigación abierto



- Kadra et al. nombró datasets como “***last unconquered castle***” para modelos basados en Deep Neural Networks (DNN).
- La adaptación de las DNN a Datos Tabulares (TD) para tareas de inferencia o generación de datos sigue siendo un **gran desafío**.
- Vadim Borísov et al. hacen un benchmark de diferentes métodos/datasets entre ensembles vs. DNN y **ganar los ensembles**. De hecho, afirman:
 - “El progreso de la investigación sobre modelos competitivos de aprendizaje profundo para datos tabulares **se está estancando**”.
 - “Es un **área de investigación abierta**”.
- ShwartzZiv y Armon en su artículo “*Tabular data: Deep learning is not all you need*”, compararon enfoques de DNN vs. árbol de decisión de aumento de gradiente (GBDT). **Los GBDT cuestionaron los DNN**, lo que concluyeron que el modelado de datos tabulares utilizando DNN sigue siendo un **problema de investigación abierto**.

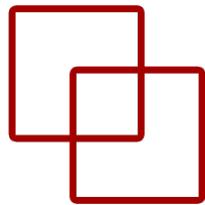
Problema de investigación abierto



- Kadra et al. nombró datasets como “***last unconquered castle***” para modelos basados en Deep Neural Networks (DNN).
- La adaptación de las DNN a Datos Tabulares (TD) para tareas de inferencia o generación de datos sigue siendo un **gran desafío**.
- Vadim Borísov et al. hacen un benchmark de diferentes métodos/datasets entre ensembles vs. DNN y **ganar los ensembles**. De hecho, afirman:
 - “El progreso de la investigación sobre modelos competitivos de aprendizaje profundo para datos tabulares **se está estancando**”.
 - “Es un **área de investigación abierta**”.
- ShwartzZiv y Armon en su artículo “*Tabular data: Deep learning is not all you need*”, compararon enfoques de DNN vs. árbol de decisión de aumento de gradiente (GBDT). **Los GBDT cuestionaron los DNN**, lo que concluyeron que el modelado de datos tabulares utilizando DNN sigue siendo un **problema de investigación abierto**.
- Las implementaciones exitosas de aplicaciones basadas en datos requieren resolver varias tareas, entre las cuales identificamos **3 desafíos centrales: (1) Inferencia; (2) Generación de datos; y (3) Interpretabilidad**.
 - La **tarea más crucial es la inferencia**, que se ocupa de hacer predicciones basadas en observaciones pasadas.

¿Por qué no se mejora con DNN?

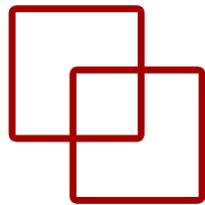
Cuatro posibles razones



- **Datos de entrenamiento de baja calidad:** valores faltantes, valores atípicos, corruptos y datos erróneos o inconsistentes, desequilibrio de clases. Los algoritmos basados en CART pueden manejar valores faltantes o rangos de variables.

¿Por qué no se mejora con DNN?

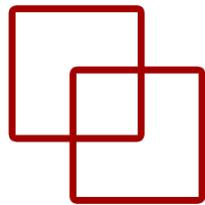
Cuatro posibles razones



- **Datos de entrenamiento de baja calidad:** valores faltantes, valores atípicos, corruptos y datos erróneos o inconsistentes, desequilibrio de clases. Los algoritmos basados en CART pueden manejar valores faltantes o rangos de variables.
- **Dependencias espaciales irregulares, faltantes o complejas:** inexistencia de correlación espacial entre las o las dependencias entre características son bastante complejas e irregulares. En datos tabulares, la estructura y las relaciones entre sus características deben aprenderse desde cero. Por lo tanto, los sesgos inductivos utilizados para datos homogéneos, e.g., CNN, no son adecuados para modelar este tipo de datos.

¿Por qué no se mejora con DNN?

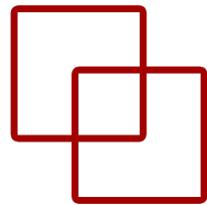
Cuatro posibles razones



- **Datos de entrenamiento de baja calidad:** valores faltantes, valores atípicos, corruptos y datos erróneos o inconsistentes, desequilibrio de clases. Los algoritmos basados en CART pueden manejar valores faltantes o rangos de variables.
- **Dependencias espaciales irregulares, faltantes o complejas:** inexistencia de correlación espacial entre las o las dependencias entre características son bastante complejas e irregulares. En datos tabulares, la estructura y las relaciones entre sus características deben aprenderse desde cero. Por lo tanto, los sesgos inductivos utilizados para datos homogéneos, e.g., CNN, no son adecuados para modelar este tipo de datos.
- **Dependencia del preprocessamiento:** Para datos tabulares y DNN, el rendimiento depende en gran medida de la estrategia de preprocessamiento. Así, los métodos de preprocessamiento para DNN pueden conducir a la pérdida de información, lo que lleva a una reducción en el rendimiento predictivo.

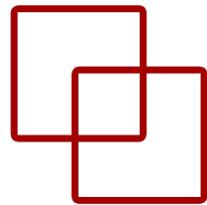
¿Por qué no se mejora con DNN?

Cuatro posibles razones



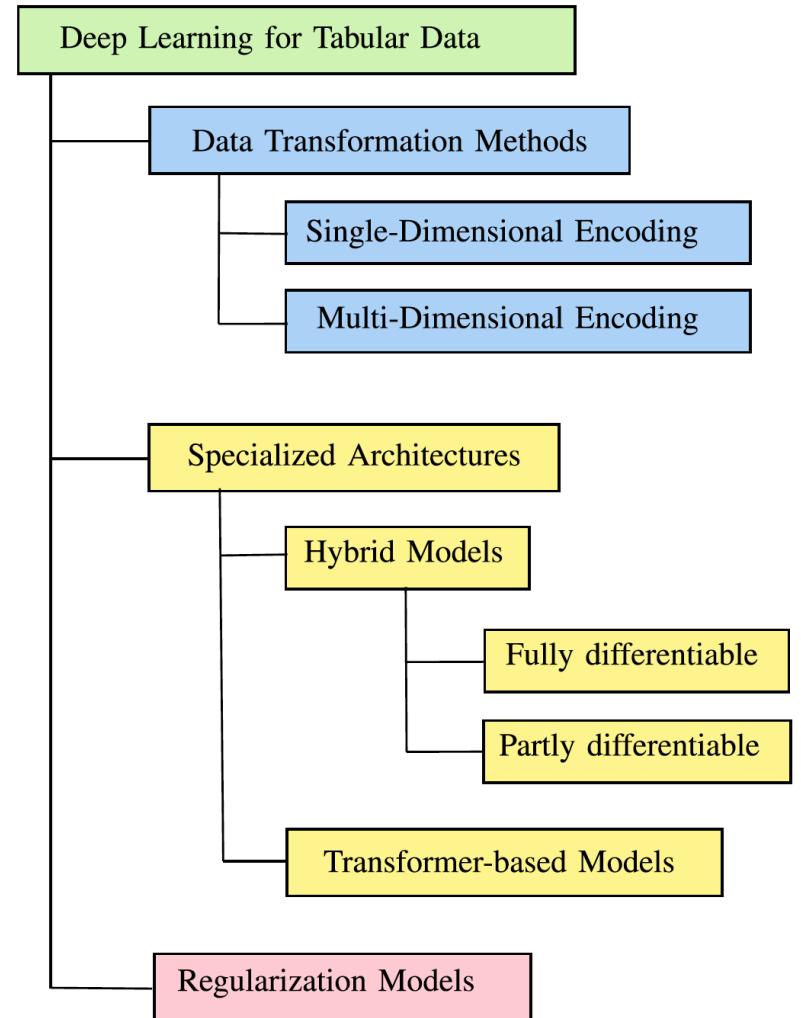
- **Datos de entrenamiento de baja calidad:** valores faltantes, valores atípicos, corruptos y datos erróneos o inconsistentes, desequilibrio de clases. Los algoritmos basados en CART pueden manejar valores faltantes o rangos de variables.
- **Dependencias espaciales irregulares, faltantes o complejas:** inexistencia de correlación espacial entre las o las dependencias entre características son bastante complejas e irregulares. En datos tabulares, la estructura y las relaciones entre sus características deben aprenderse desde cero. Por lo tanto, los sesgos inductivos utilizados para datos homogéneos, e.g., CNN, no son adecuados para modelar este tipo de datos.
- **Dependencia del preprocessamiento:** Para datos tabulares y DNN, el rendimiento depende en gran medida de la estrategia de preprocessamiento. Así, los métodos de preprocessamiento para DNN pueden conducir a la pérdida de información, lo que lleva a una reducción en el rendimiento predictivo.
- **Importancia de las características individuales:** Cambiar la clase de una imagen requiere un cambio coordinado en muchas características (píxeles). Sin embargo, el cambio más pequeño posible de una característica categórica (o binaria) puede invertir por completo una predicción en datos tabulares. [Shavitt y Segal](#) han argumentado que la regularización del peso individual puede mitigar este desafío.

Taxonomía en los enfoques

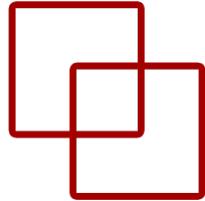


- **Métodos de transformación de datos:**

- Transforman datos categóricos y numéricos, así, las DNN extraen mejor la señal de información.
- No requieren nuevas arquitecturas ni adaptaciones de procesamiento de datos.
- Podemos subdividir aún más esta área en codificaciones unidimensionales (para transformar cada característica de forma independiente) y codificaciones multidimensionales (asignan un registro completo a otra representación).



Taxonomía en los enfoques

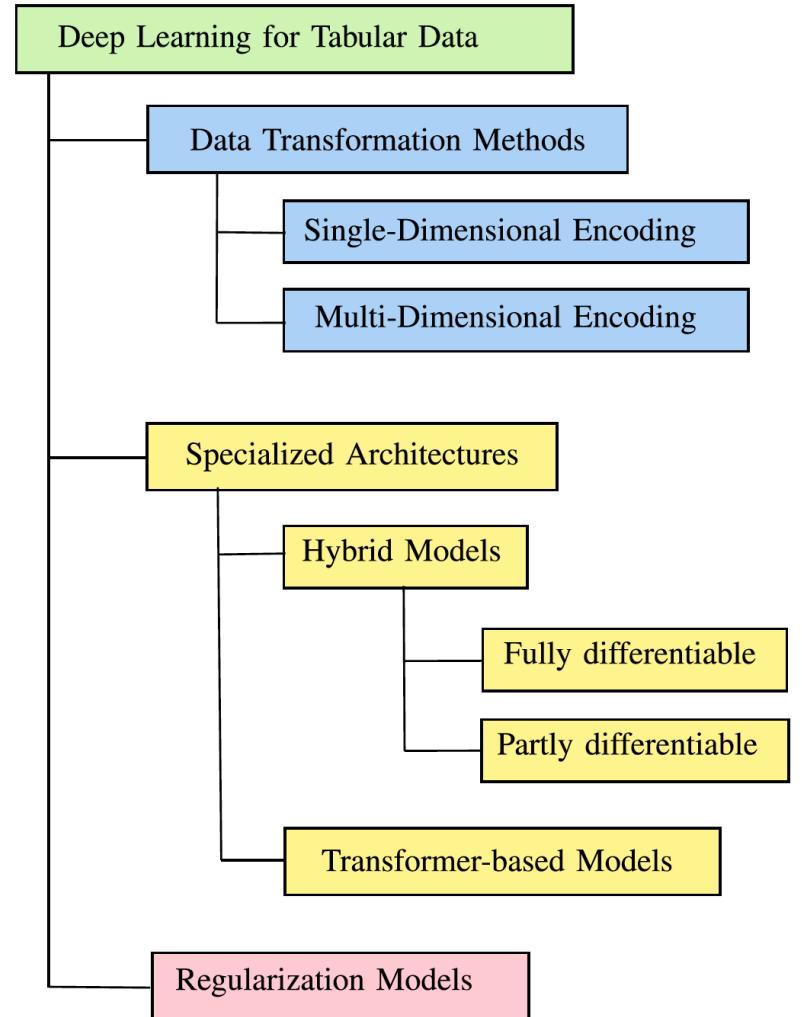


- **Métodos de transformación de datos:**

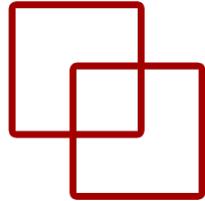
- Transforman datos categóricos y numéricos, así, las DNN extraen mejor la señal de información.
- No requieren nuevas arquitecturas ni adaptaciones de procesamiento de datos.
- Podemos subdividir aún más esta área en codificaciones unidimensionales (para transformar cada característica de forma independiente) y codificaciones multidimensionales (asignan un registro completo a otra representación).

- **Arquitecturas especializadas:**

- Se requiere una arquitectura de DNN diferente para los datos tabulares.
- Arquitecturas: (i) Modelos híbridos que fusionan enfoques clásicos de ML (e.g., árboles de decisión) con DNN; y (ii) Modelos basados en Transformers que se basan en mecanismos de atención a la pérdida de información.



Taxonomía en los enfoques



- **Métodos de transformación de datos:**

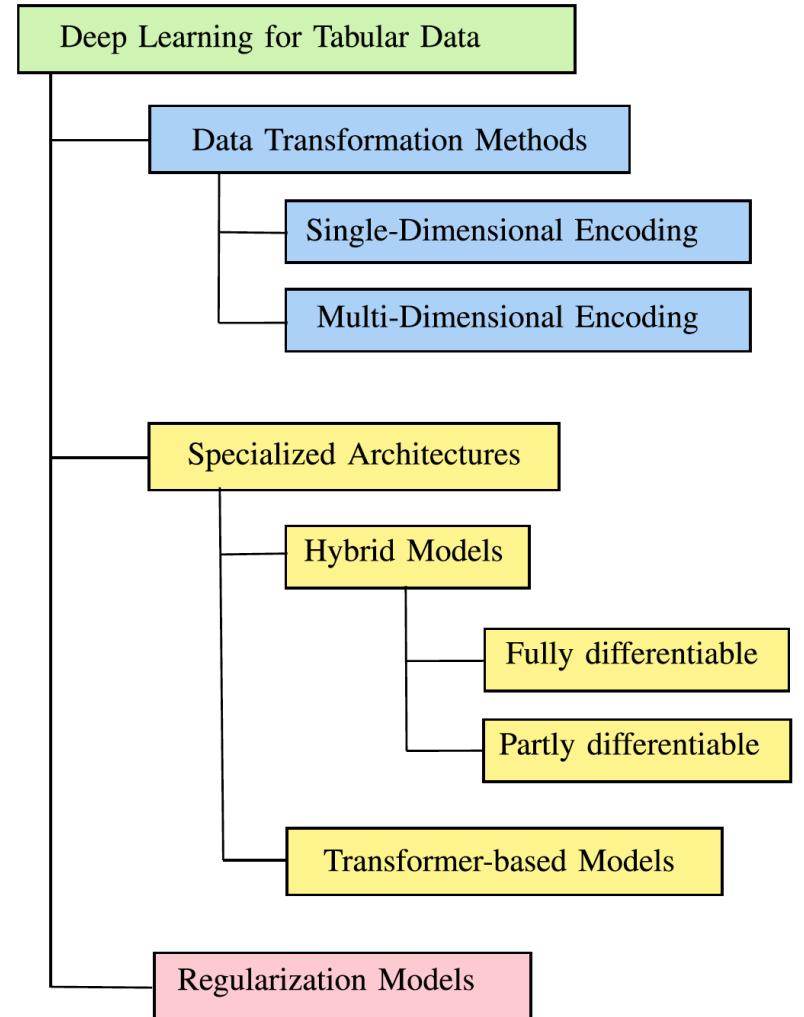
- Transforman datos categóricos y numéricos, así, las DNN extraen mejor la señal de información.
- No requieren nuevas arquitecturas ni adaptaciones de procesamiento de datos.
- Podemos subdividir aún más esta área en codificaciones unidimensionales (para transformar cada característica de forma independiente) y codificaciones multidimensionales (asignan un registro completo a otra representación).

- **Arquitecturas especializadas:**

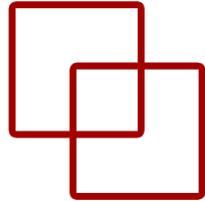
- Se requiere una arquitectura de DNN diferente para los datos tabulares.
- Arquitecturas: (i) Modelos híbridos que fusionan enfoques clásicos de ML (e.g., árboles de decisión) con DNN; y (ii) Modelos basados en Transformers que se basan en mecanismos de atención a la pérdida de información.

- **Modelos de regularización:**

- Afirma que el rendimiento moderado de las DNN en datos tabulares es su extrema no linealidad y complejidad del modelo.
- Por lo tanto, se proponen como solución fuertes esquemas de regularización.



Taxonomía en los enfoques



- **Métodos de transformación de datos:**

- Transforman datos categóricos y numéricos, así, las DNN extraen mejor la señal de información.
- No requieren nuevas arquitecturas ni adaptaciones de procesamiento de datos.
- Podemos subdividir aún más esta área en codificaciones unidimensionales (para transformar cada característica de forma independiente) y codificaciones multidimensionales (asignan un registro completo a otra representación).

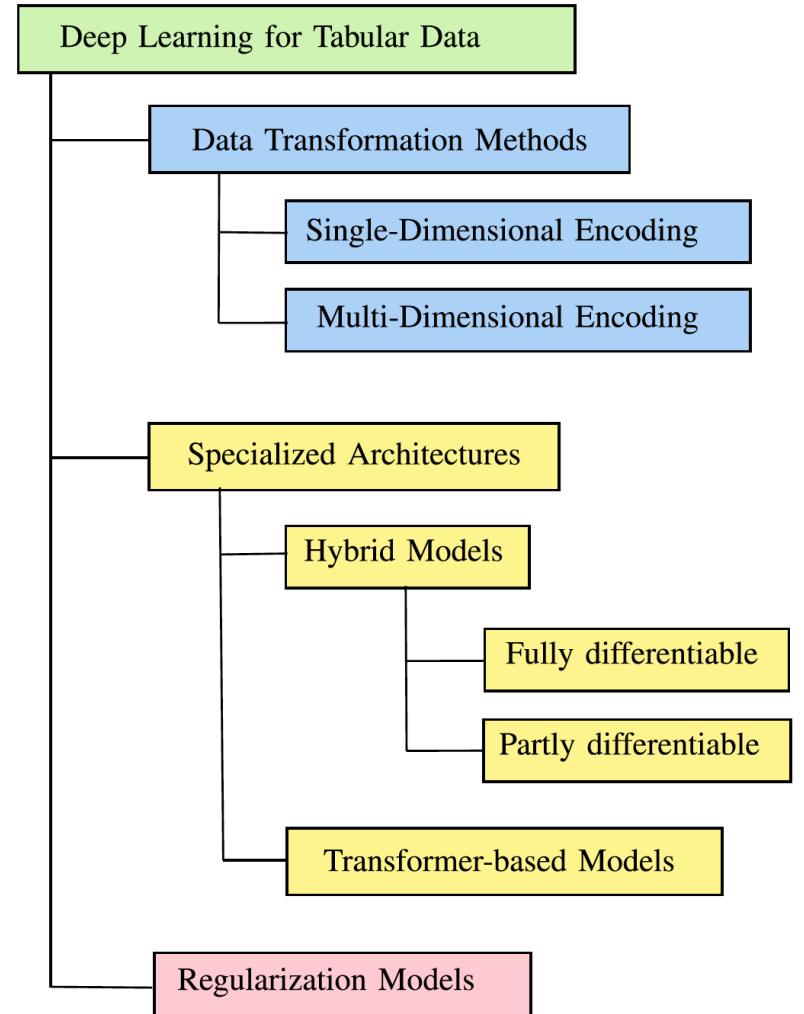
- **Arquitecturas especializadas:**

- Se requiere una arquitectura de DNN
- Arquitecturas: (i) Modelos híbridos que combinan DNN con otros modelos (e.g., árboles de decisión) con DNN, (ii) Modelos basados en Transformers que se basan en mecanismos de atención a la pérdida de información.

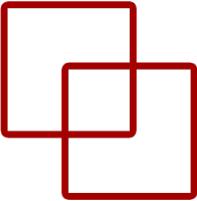
- **Modelos de regularización:**

- Afirma que el rendimiento moderado de las DNN en datos tabulares es su extrema no linealidad y complejidad del modelo.
- Por lo tanto, se proponen como solución fuertes esquemas de regularización.

Desechamos esta
para nuestros
fines

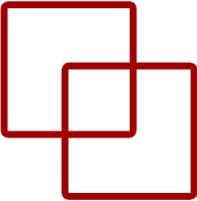


Taxonomía en los enfoques



	Method	Interpretability	Key Characteristics
Encoding	SuperTML [78]		Transform tabular data into images for CNNs
	VIME [79]		Self-supervised learning and contextual embedding
	IGTD [72]		Transform tabular data into images for CNNs
	SCARF [80]		Self-supervised contrastive learning
Architectures, Hybrid	Wide&Deep [81]		Embedding layer for categorical features
	DeepFM [15]		Factorization machine for categorical data
	SDT [82]	✓	Distill neural network into interpretable decision tree
	xDeepFM [83]		Compressed interaction network
	TabNN [84]		DNNs based on feature groups distilled from GBDT
	DeepGBM [62]		Two DNNs, distill knowledge from decision tree
	NODE [7]		Differentiable oblivious decision trees ensemble
	NAM [85]	✓	Separate neural networks for each input variable
	NON [86]		Network-on-network model
	DNN2LR [87]		Calculate cross feature yields with DNNs for LR
	Net-DNF [50]		Structure based on disjunctive normal form
	Boost-GNN [88]		GNN on top decision trees from the GBDT algorithm
	SDTR [89]		Hierarchical differentiable neural regression model
	TabNet [6]	✓	Sequential attention structure
Architectures, Transformer	TabTransformer [90]	✓	Transformer network for categorical data
	SAINT [9]	✓	Attention over both rows and columns
	ARM-Net [91]		Adaptive relational modeling with multi-headgated attention network
	Non-Param. Transformer [92]		Process the entire data set at once, use attention between data points
	RLN [63]	✓	Hyperparameters regularization scheme
Regul.	STG [93]		Stochastic gate regularization
	Regularized DNNs [10]		A "cocktail" of regularization techniques

Taxonomía en los enfoques

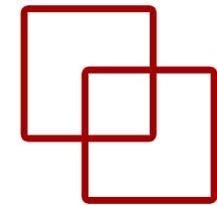


	Method	Interpretability	Key Characteristics
Encoding	SuperTML [78]		Transform tabular data into images for CNNs
	VIME [79]		Self-supervised learning and contextual embedding
	IGTD [72]		Transform tabular data into images for CNNs
	SCARF [80]		Self-supervised contrastive learning
Architectures, Hybrid	Wide&Deep [81]		Embedding layer for categorical features
	DeepFM [15]		Factorization machine for categorical data
	SDT [82]	✓	Distill neural network into interpretable decision tree
	xDeepFM [83]		Compressed interaction network
	TabNN [84]		DNNs based on feature groups distilled from GBDT
	DeepGBM [62]		Two DNNs, distill knowledge from decision tree
	NODE [7]		Differentiable oblivious decision trees ensemble
	NAM [85]	✓	Separate neural networks for each input variable
	NON [86]		Network-on-network model
	DNN2LR [87]		Calculate cross feature yields with DNNs for LR
	Net-DNF [50]		Structure based on disjunctive normal form
	Boost-GNN [88]		GNN on top decision trees from the GBDT algorithm
	SDTR [89]		Hierarchical differentiable neural regression model
Architectures, Transformer	TabNet [6]	✓	Sequential attention structure
	TabTransformer [90]	✓	Transformer network for categorical data
	SAINT [9]	✓	Attention over both rows and columns
	ARM-Net [91]		Adaptive relational modeling with multi-headgated attention network
	Non-Param. Transformer [92]		Process the entire data set at once, use attention between data points
Regul.	RLN [63]	✓	Hyperparameters regularization scheme
	STG [93]		Stochastic gate regularization
	Regularized DNNs [10]		A "cocktail" of regularization techniques

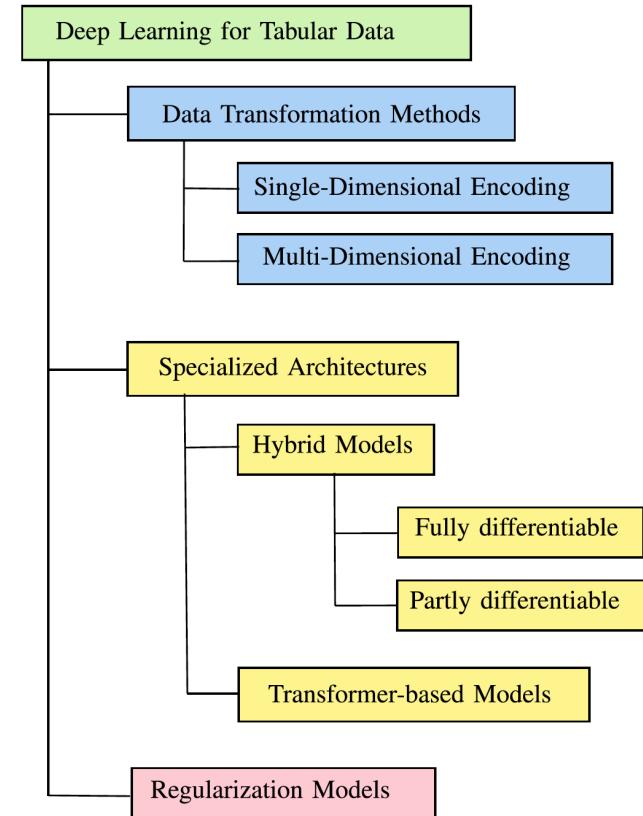
Nos centramos en estos

Taxonomías

Arquitecturas especializadas

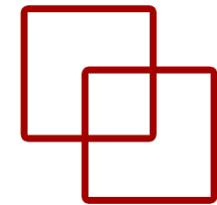


- Se centra en el desarrollo de nuevas arquitecturas DNN diseñadas específicamente para datos tabulares heterogéneos.
- Dos grupos: (i) : Modelos híbridos; y (ii) Modelos basados en Transformers.
- **Modelos híbridos:** Integran diferentes tipos de algoritmos y DNN, e.g., árboles de decisión para variables categóricas y MLP para numéricas que son finalmente unidas dando una predicción final.
- **Modelos basados en Transformers:** Utilizan mecanismos de atención para datos tabulares heterogéneos.
 - En [TabNet](#) este mecanismo selecciona los atributos más relevantes en cada paso del proceso de modelado, mejorando la métrica y agregando **explicabilidad** en las predicciones.
 - Pero hay más, [Tab-Transformers](#), [ARM-NET](#)...

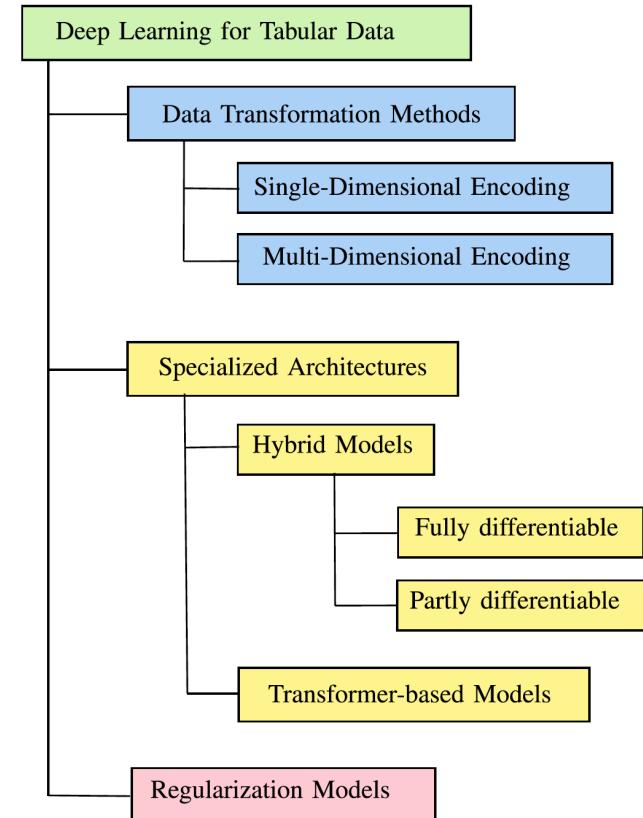


Taxonomías

Métodos de transformación de datos

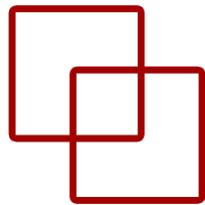


- **Codificación unidimensional:** uno de los obstáculos críticos para el aprendizaje profundo con datos tabulares son las variables categóricas.
 - Las DNN solo aceptan vectores de números reales, se deben transformar antes de usarlos, e.g., {Apple, Banana} = {0, 1} o con OHE.
- **Codificación multidimensional:** Varias aproximaciones
 - Red *Value Imputation and Mask Estimation* (VIME) que entrena un codificador que transforma las características categóricas y numéricas en una nueva representación homogénea e informativa.



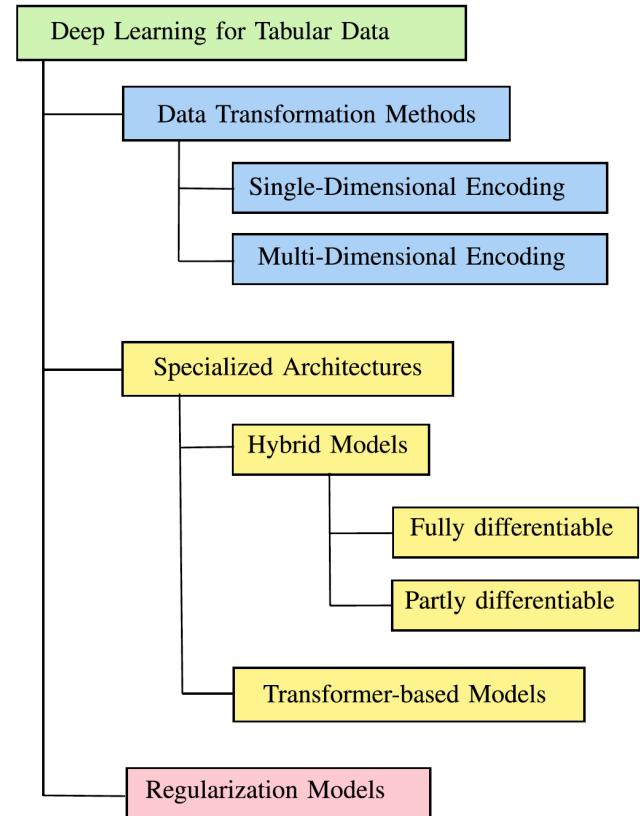
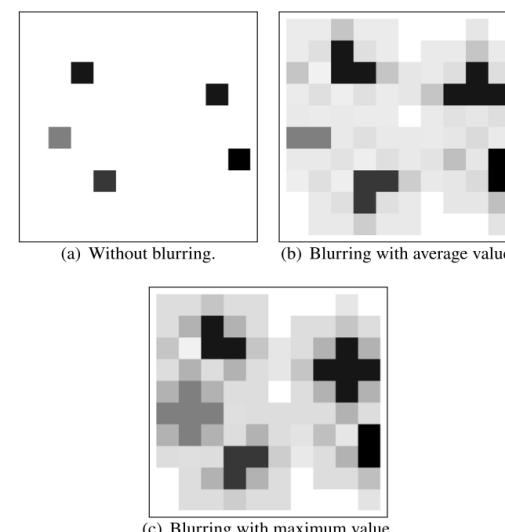
Taxonomías

Métodos de transformación de datos



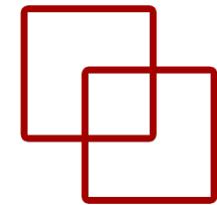
- **Codificación unidimensional:** uno de los obstáculos críticos para el aprendizaje profundo con datos tabulares son las variables categóricas.
 - Las DNN solo aceptan vectores de números reales, se deben transformar antes de usarlos, e.g., {Apple, Banana} = {0, 1} o con OHE.
- **Codificación multidimensional:** Varias aproximaciones
 - Red *Value Imputation and Mask Estimation* (VIME) que entrena un codificador que transforma las características categóricas y numéricas en una nueva representación homogénea e informativa.
 - **Transformar datos tabulares a un formato más homogéneo, i.e., imágenes sintéticas**, i.e., TINTO, IGTD, REFIND, etc.

Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15



Taxonomías

Métodos de transformación de datos

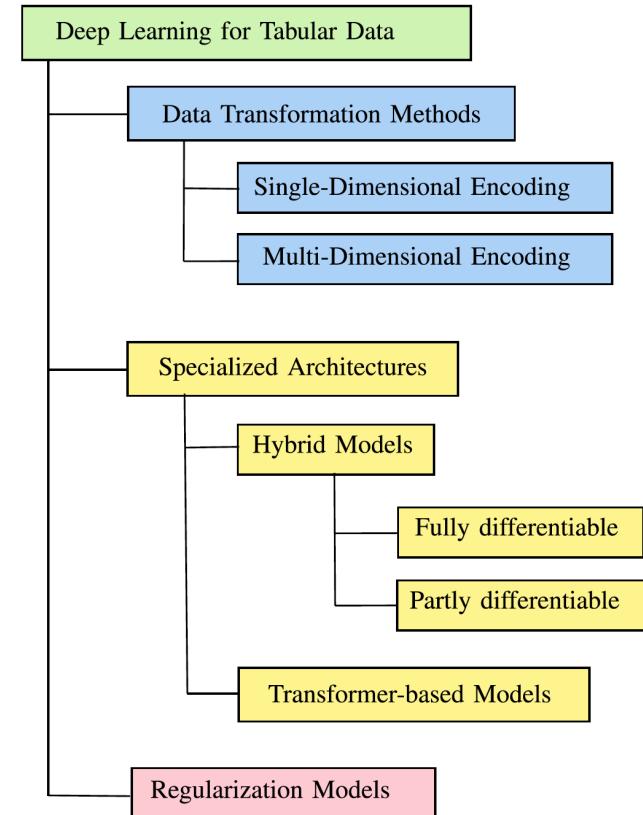
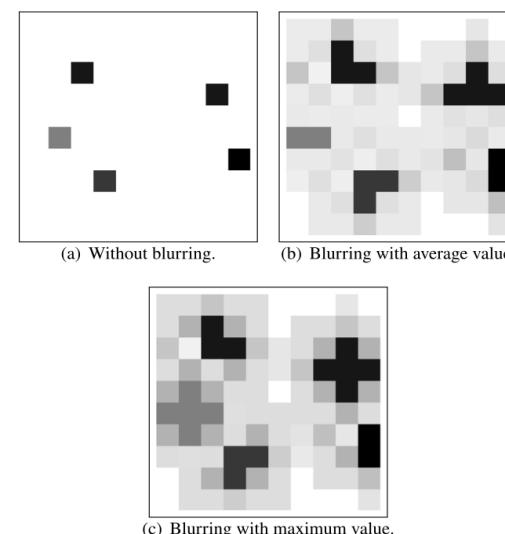


- **Codificación unidimensional:** uno de los obstáculos más profundo con datos tabulares son las variables categóricas. • Las DNN solo aceptan vectores de números reales. Una forma de usarlos, e.g., {Apple, Banana} = {0, 1} o con One-Hot Encoding.

¡Por fin nuestro área!

- **Codificación multidimensional:** Varias aproximaciones:
 - Red Value Imputation and Mask Estimation (VIME) que entrena un codificador que transforma las características categóricas y numéricas en una nueva representación homogénea e informativa.
 - **Transformar datos tabulares a un formato más homogéneo, i.e., imágenes sintéticas**, i.e., TINTO, IGTD, REFIND, etc.

Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15



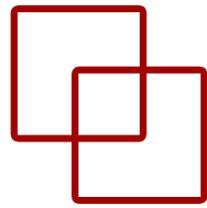
\Arquitecturas unitarias

ETS de
Ingeniería
Informática

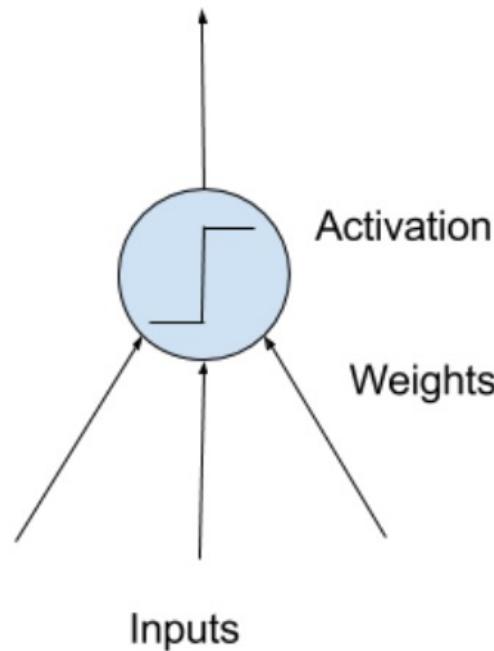


UNED

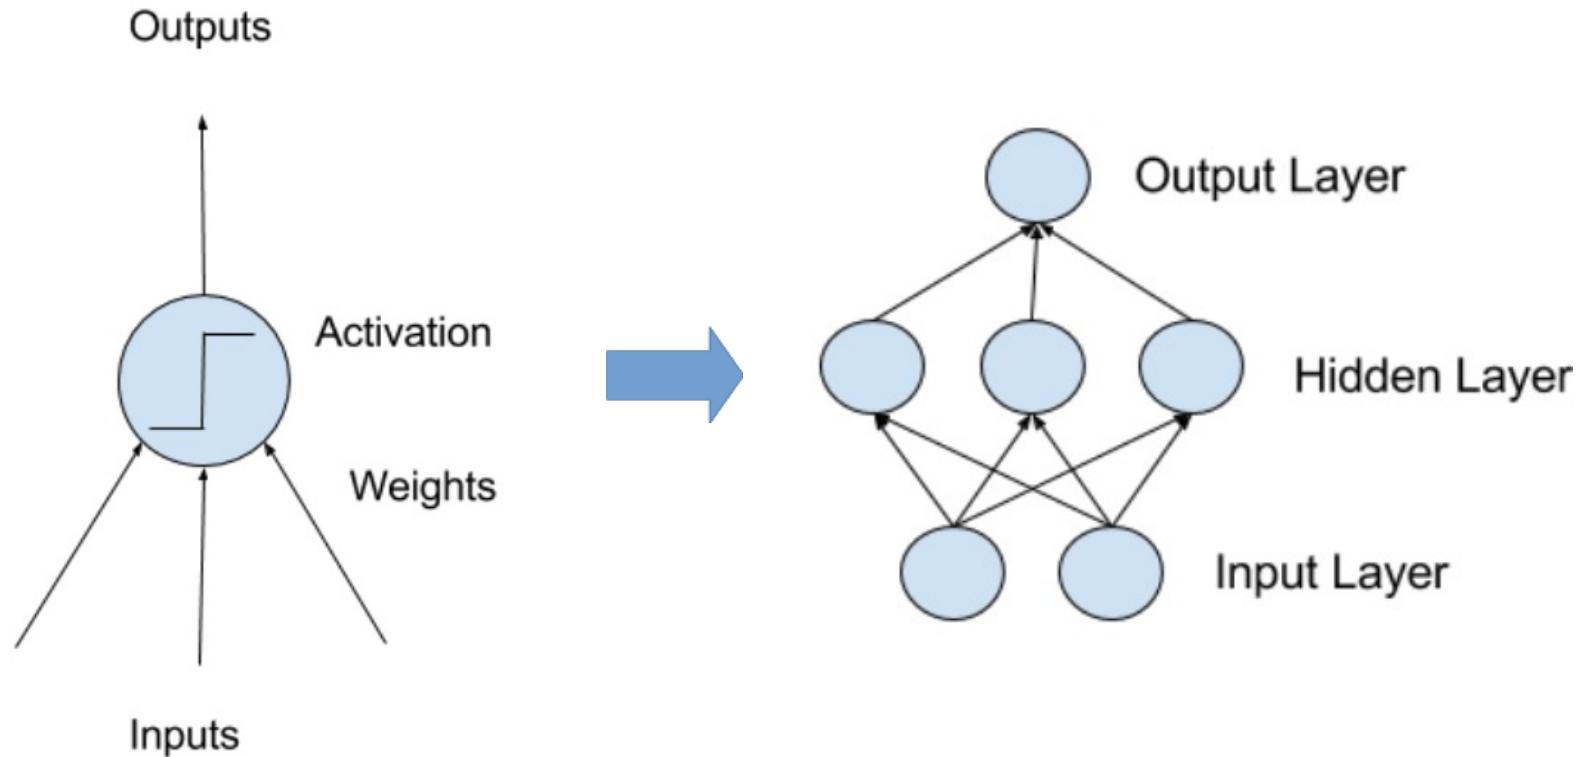
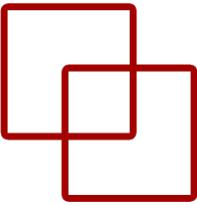
Multilayer Perceptrón



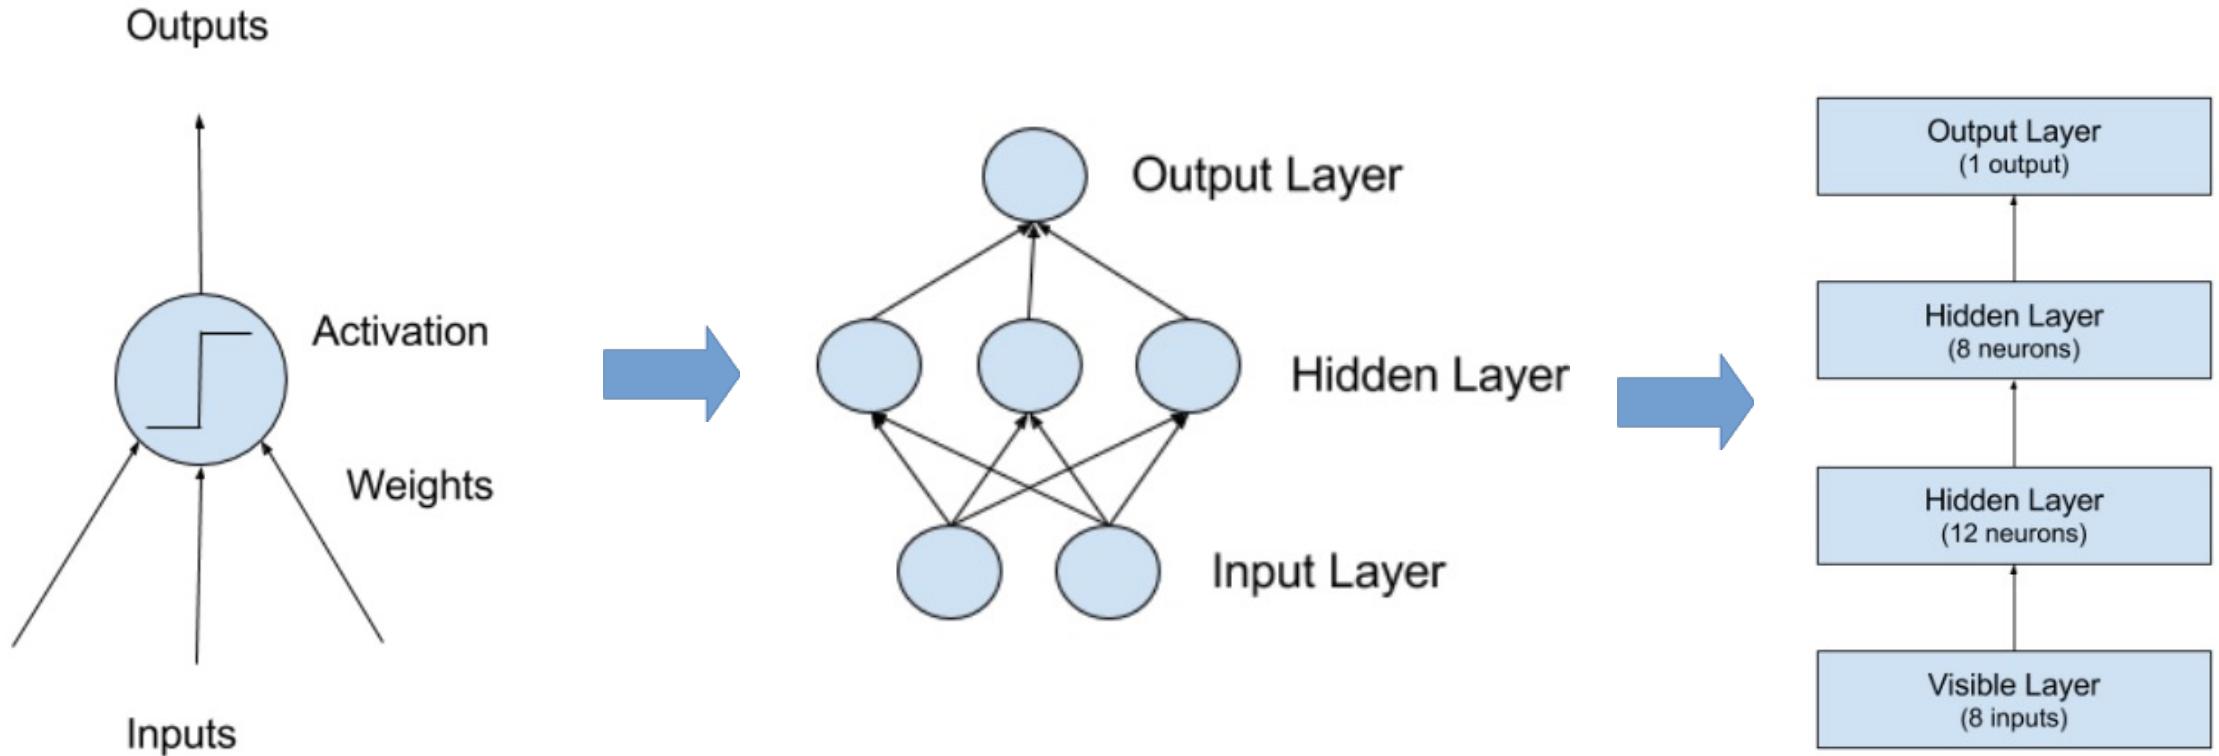
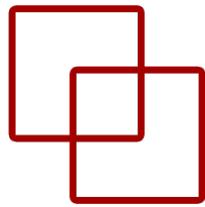
Outputs



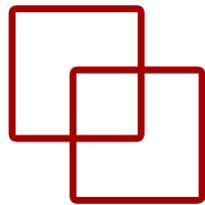
Multilayer Perceptrón



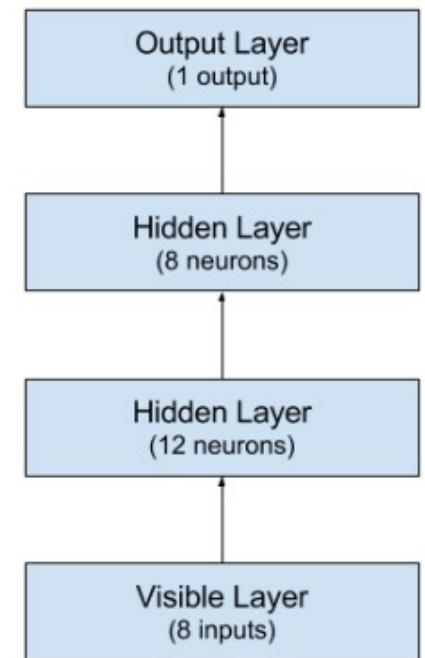
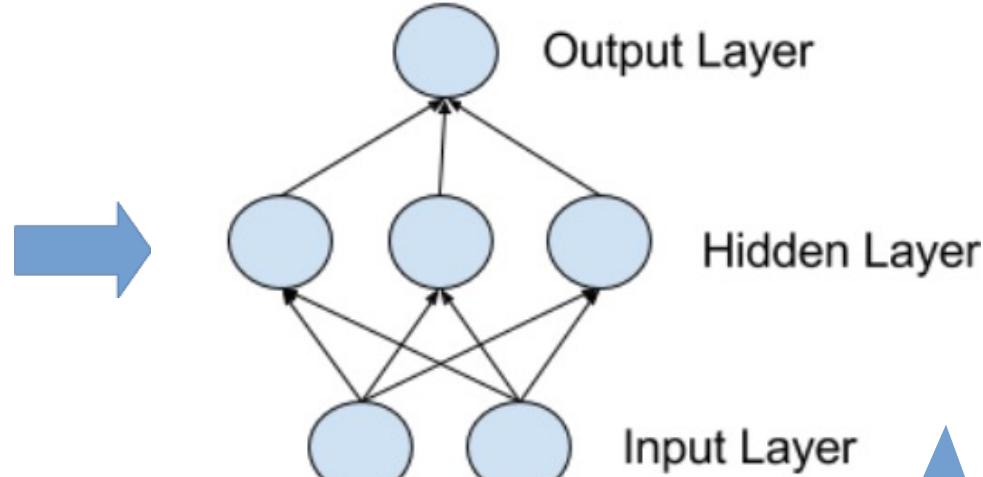
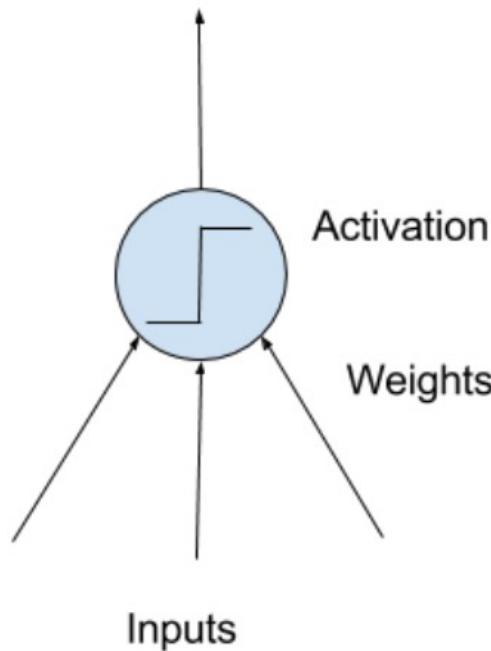
Multilayer Perceptrón



Multilayer Perceptrón

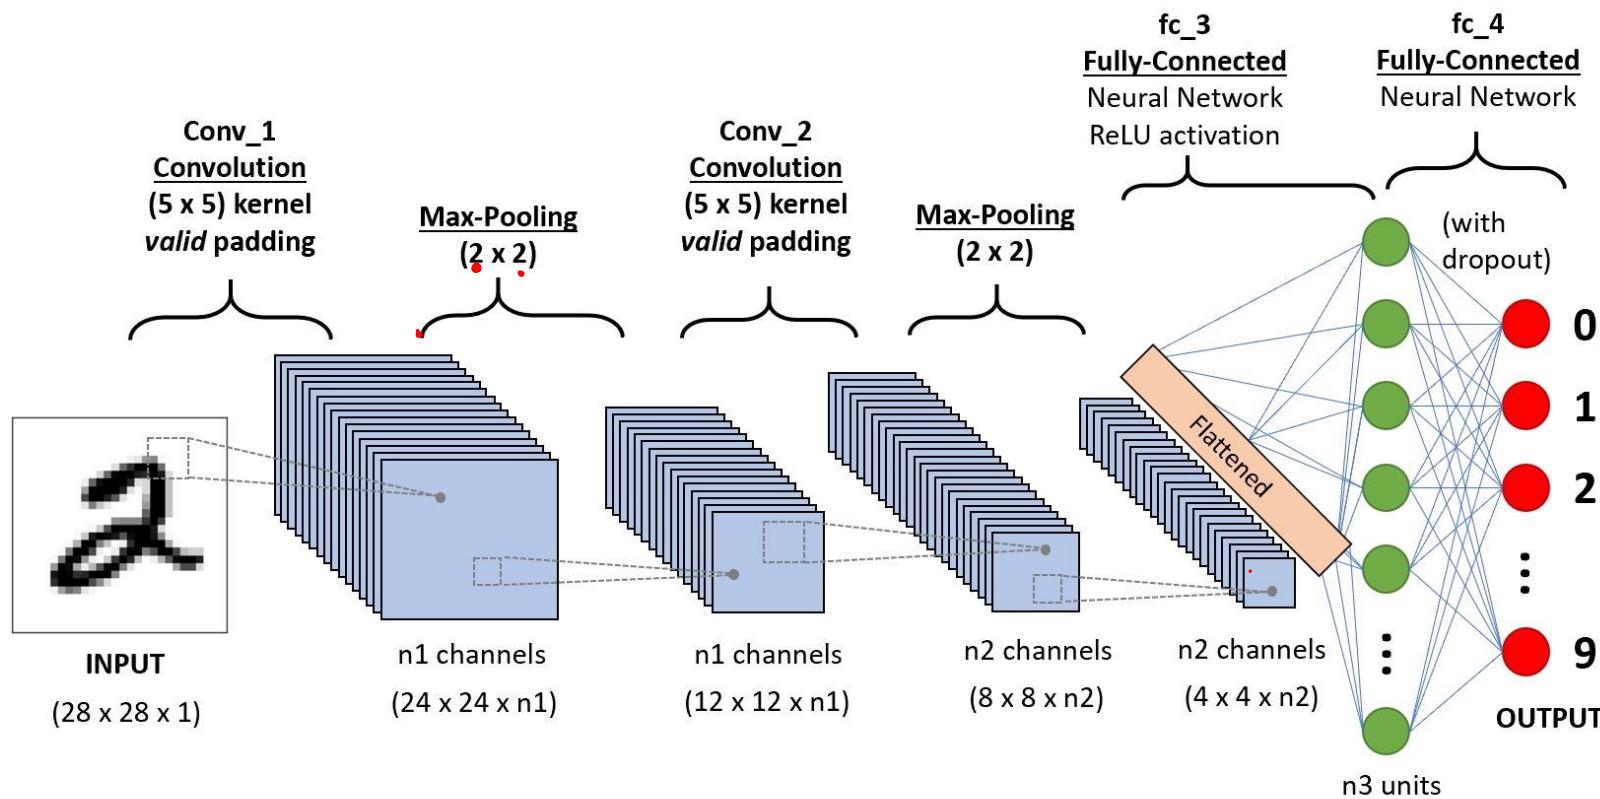
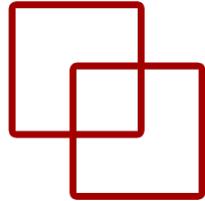


Outputs

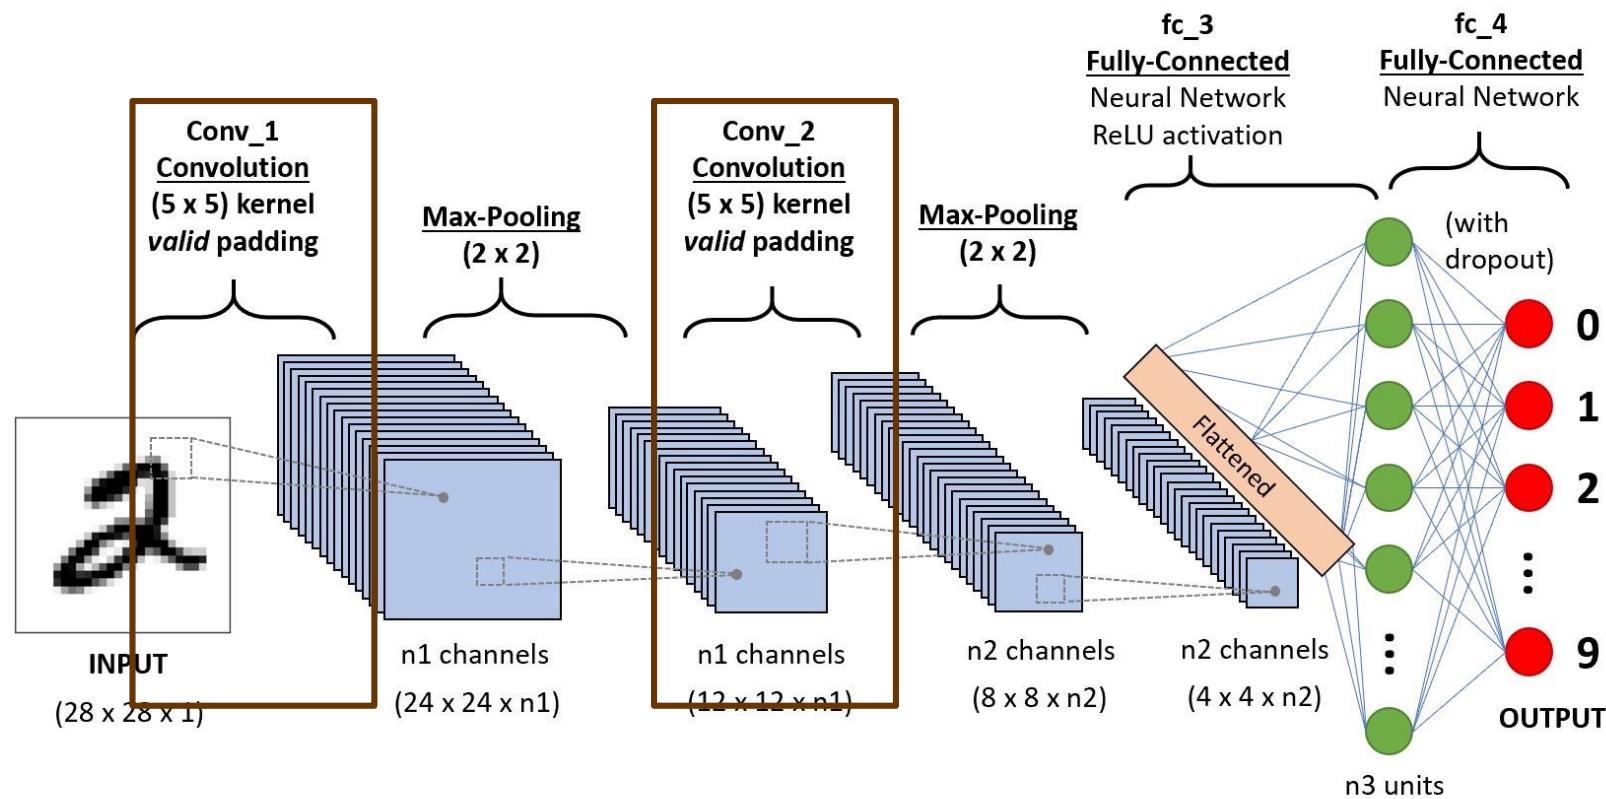
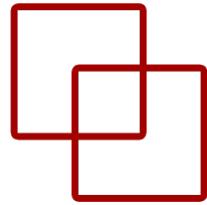


¡Para datos tabulares!

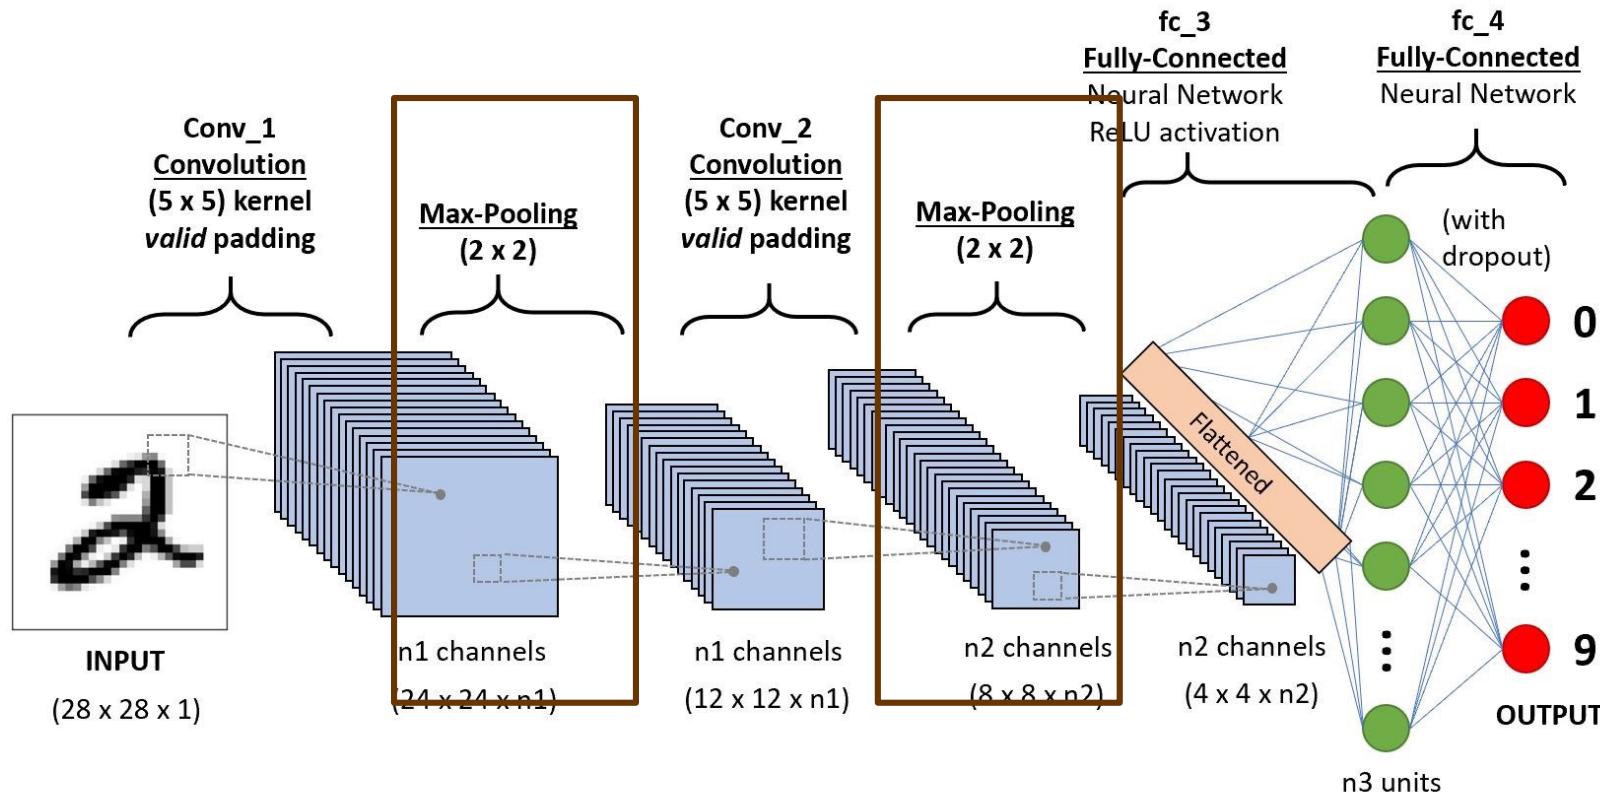
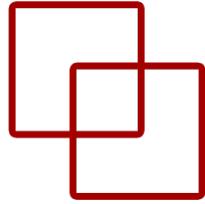
Redes Neuronales Convolucionales



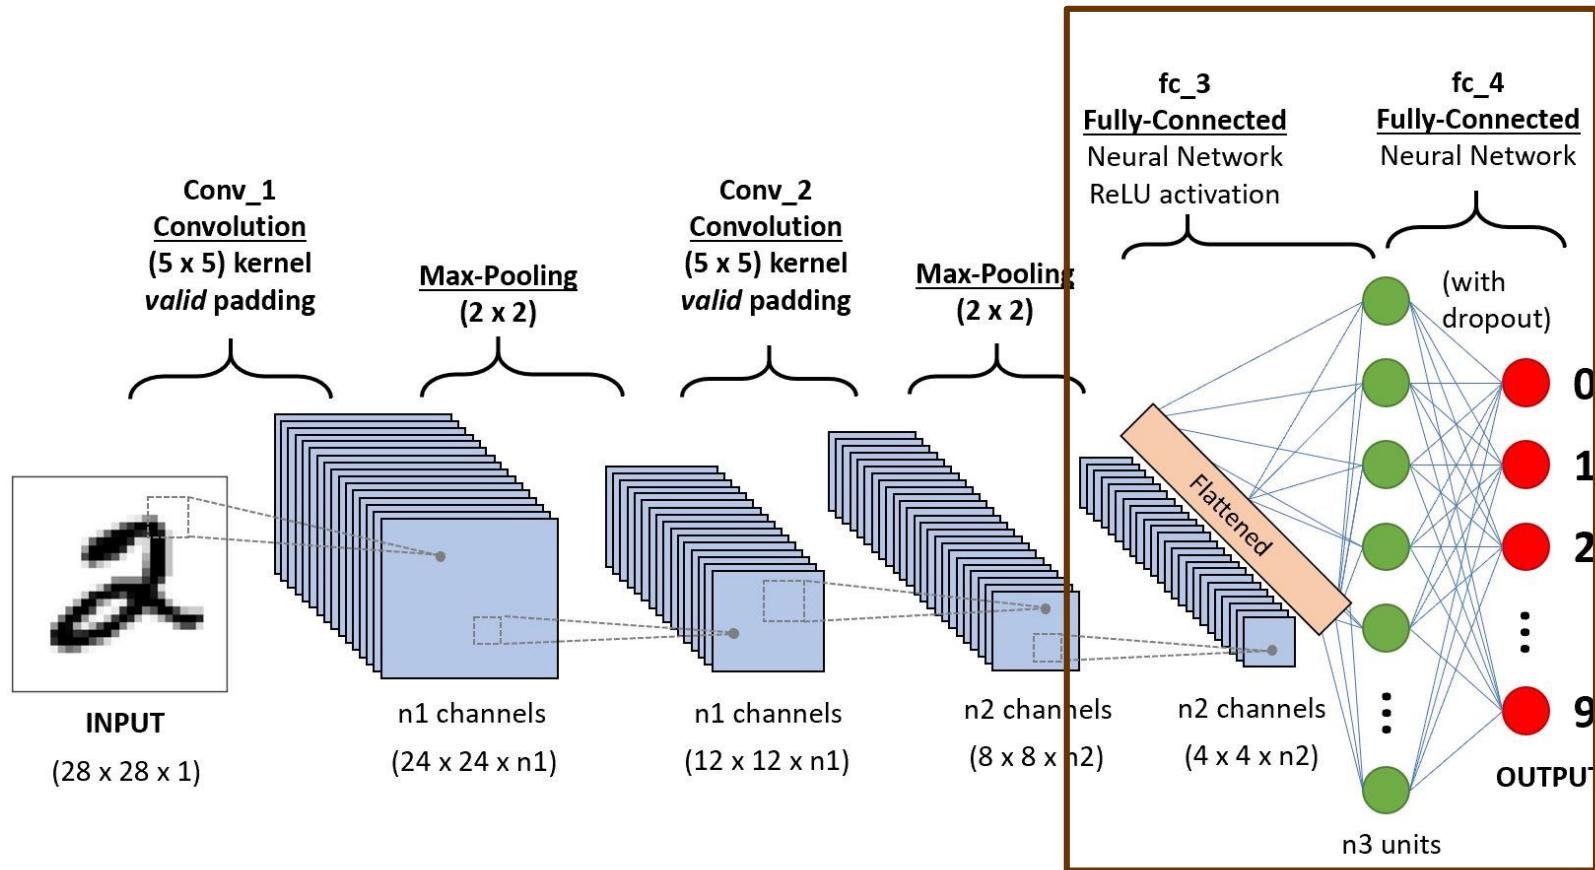
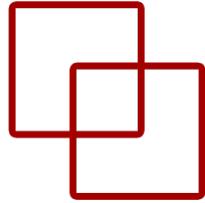
Capas convolucionales



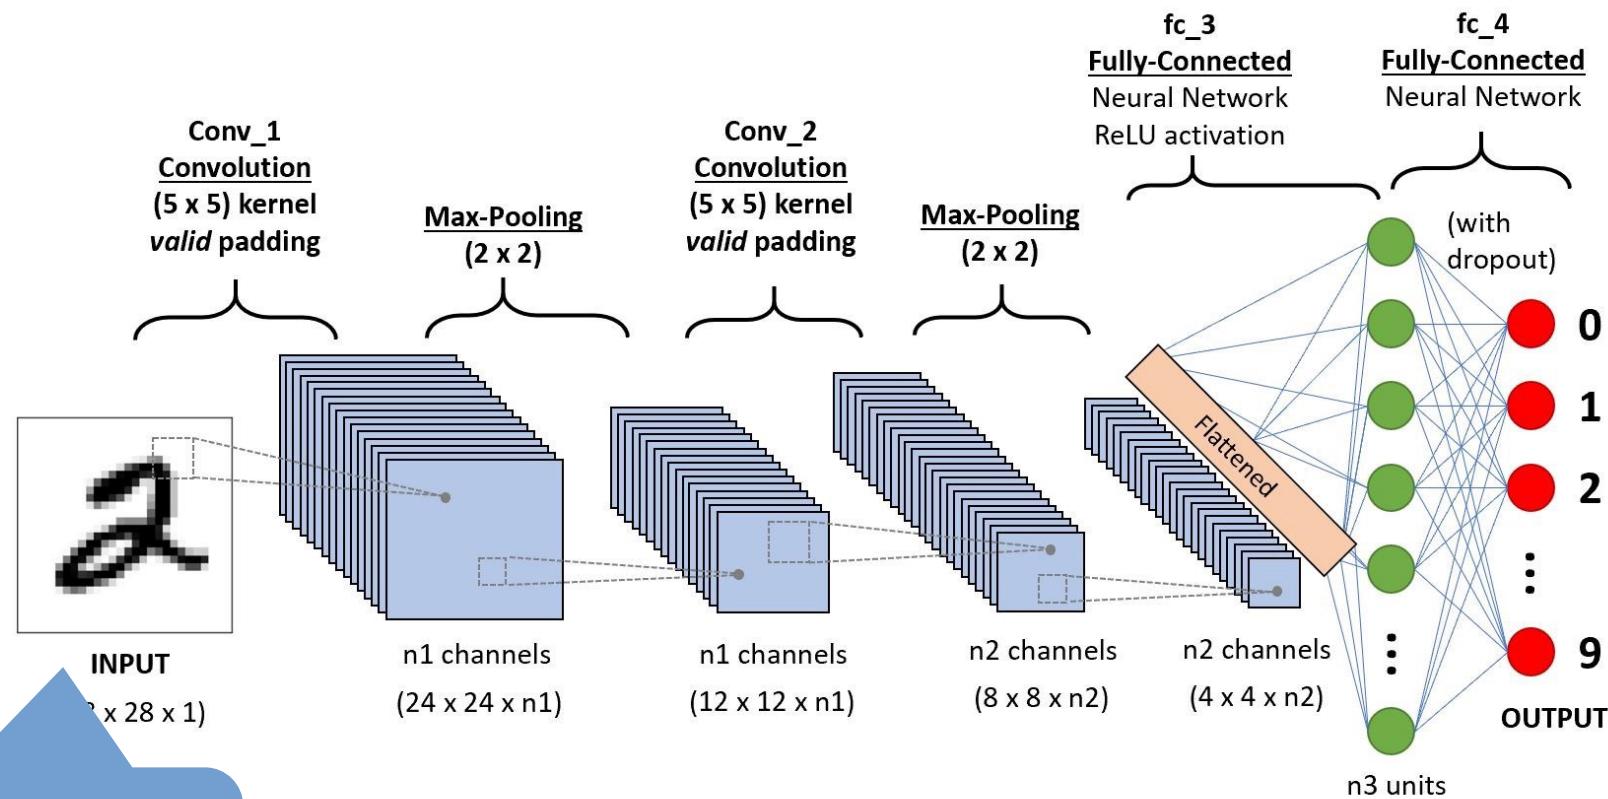
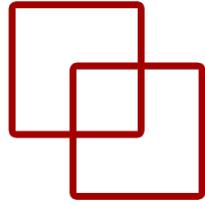
Capas de agrupación (*pooling*)



Capas completamente conectadas



Capas completamente conectadas



¡Para imágenes!



Vision Transformer (ViT)





Vision Transformer (ViT)



¡Para imágenes!

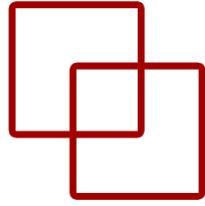
Assesment Criteria

ETS de
Ingeniería
Informática



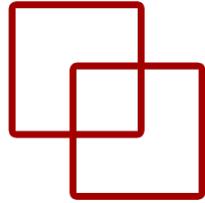
UNED

Transformación de datos

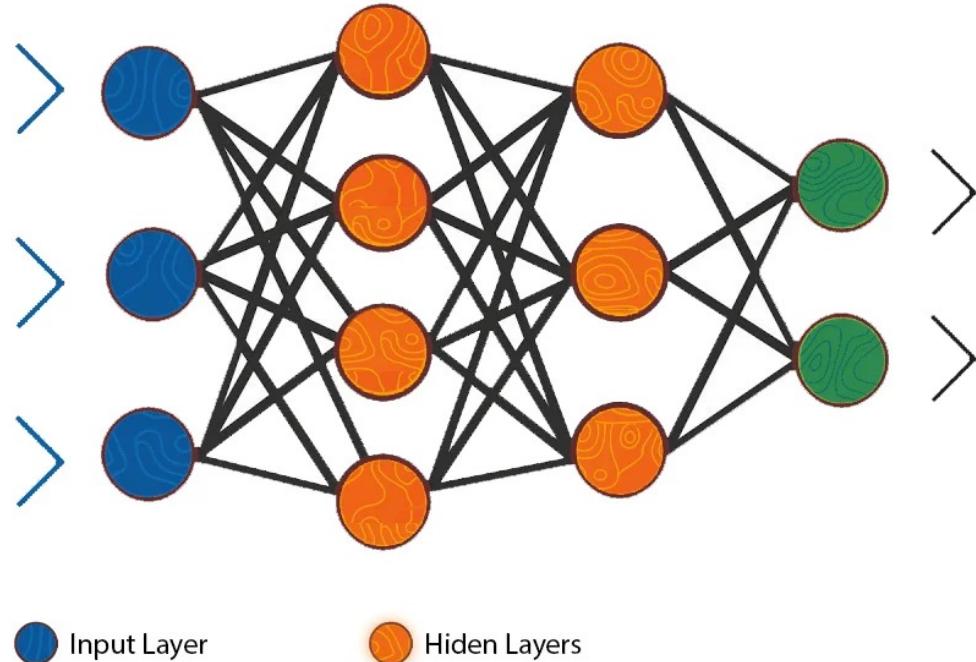
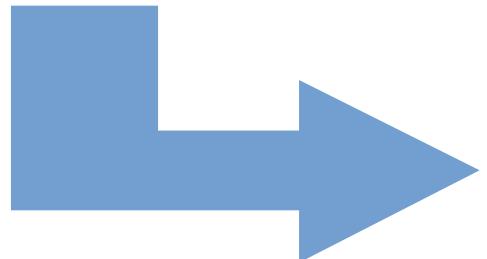


Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15

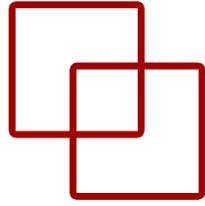
Transformación de datos



Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15

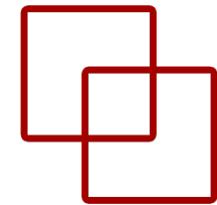


Transformación de datos

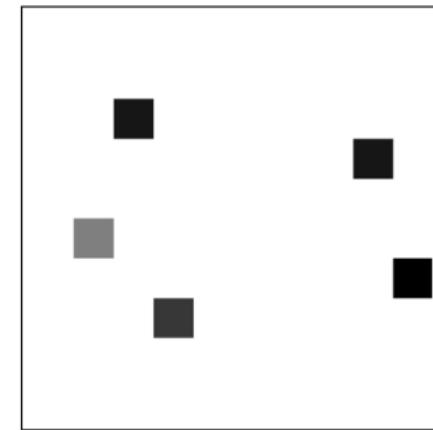
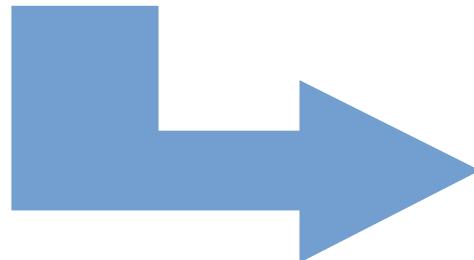


Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15

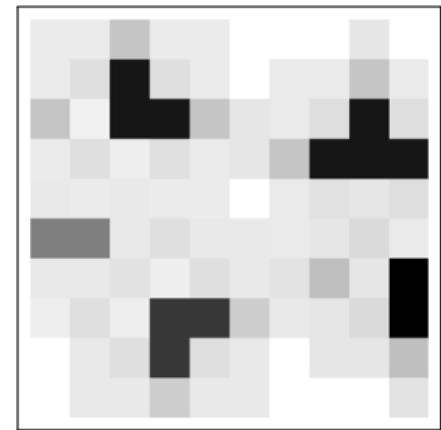
Transformación de datos



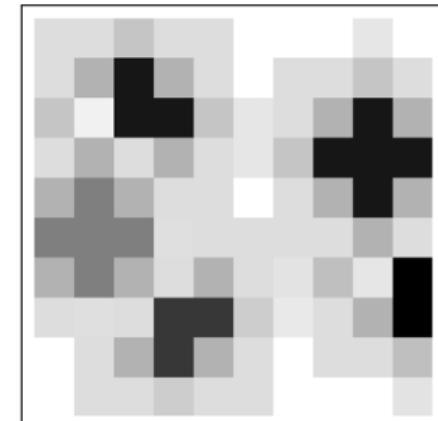
Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15



(a) Without blurring.

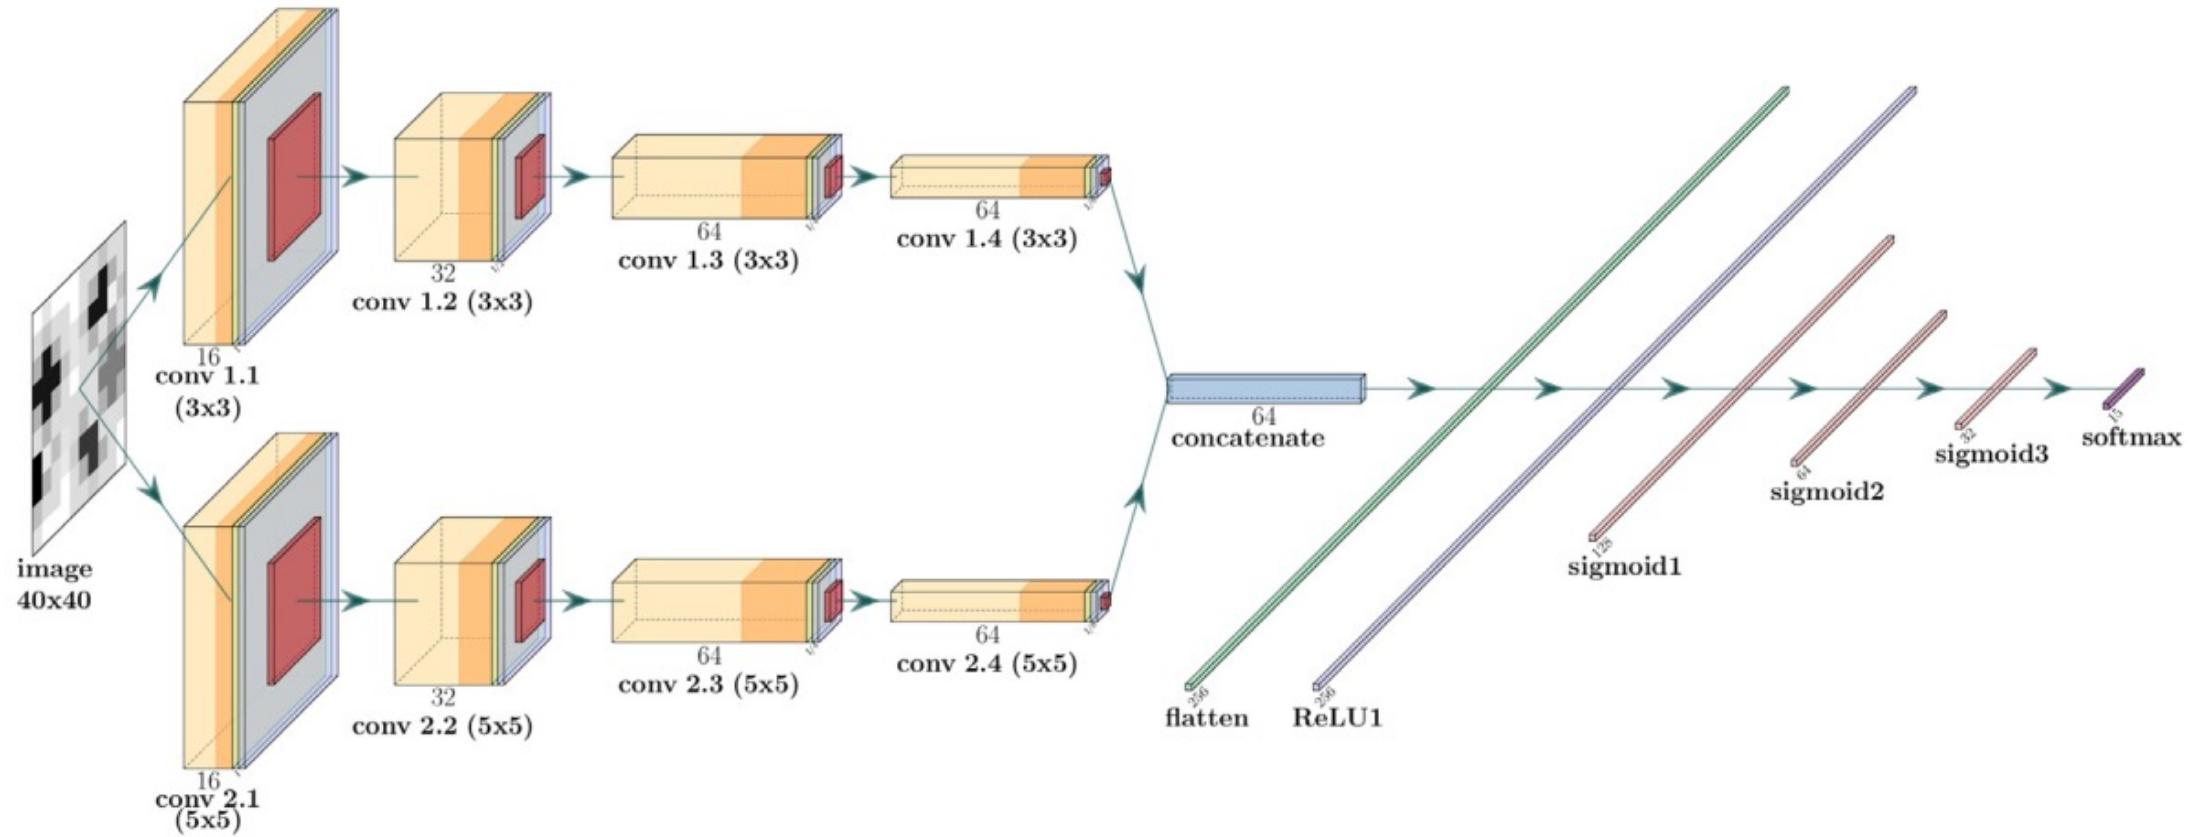
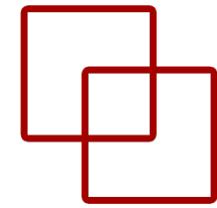


(b) Blurring with average value.

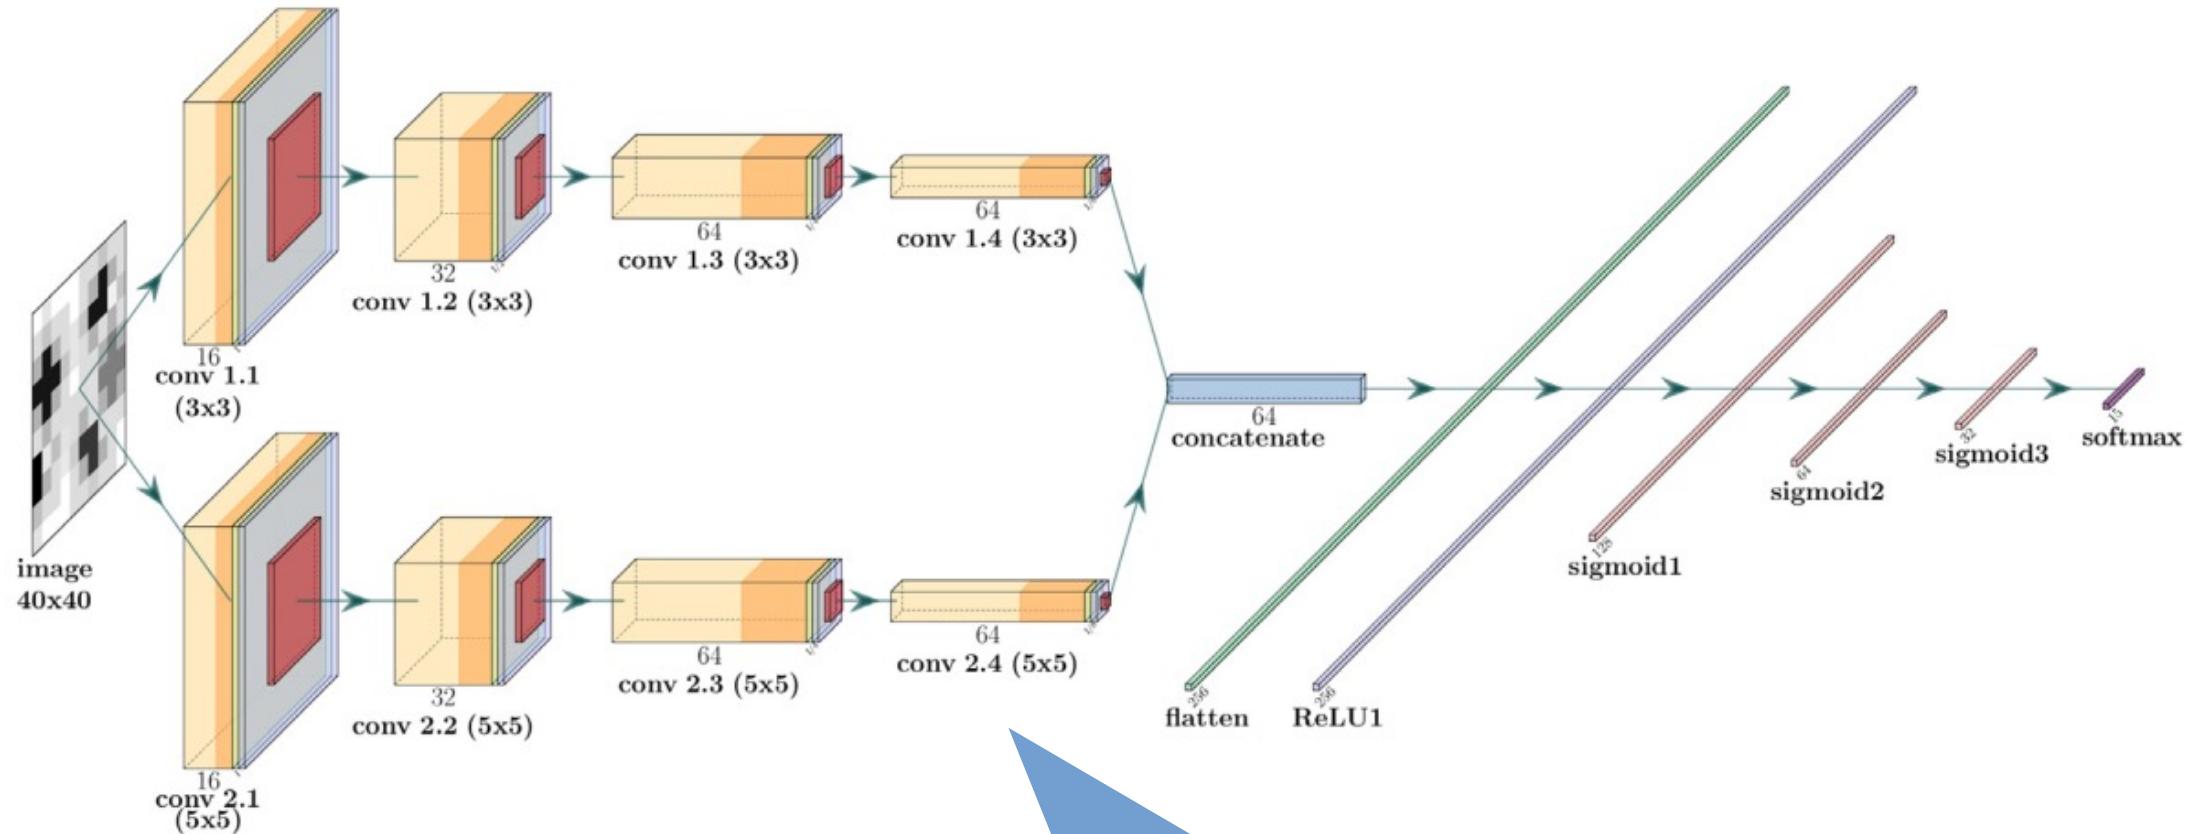
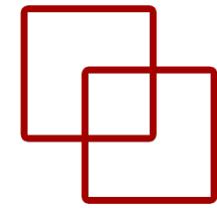


(c) Blurring with maximum value.

CNN Puras

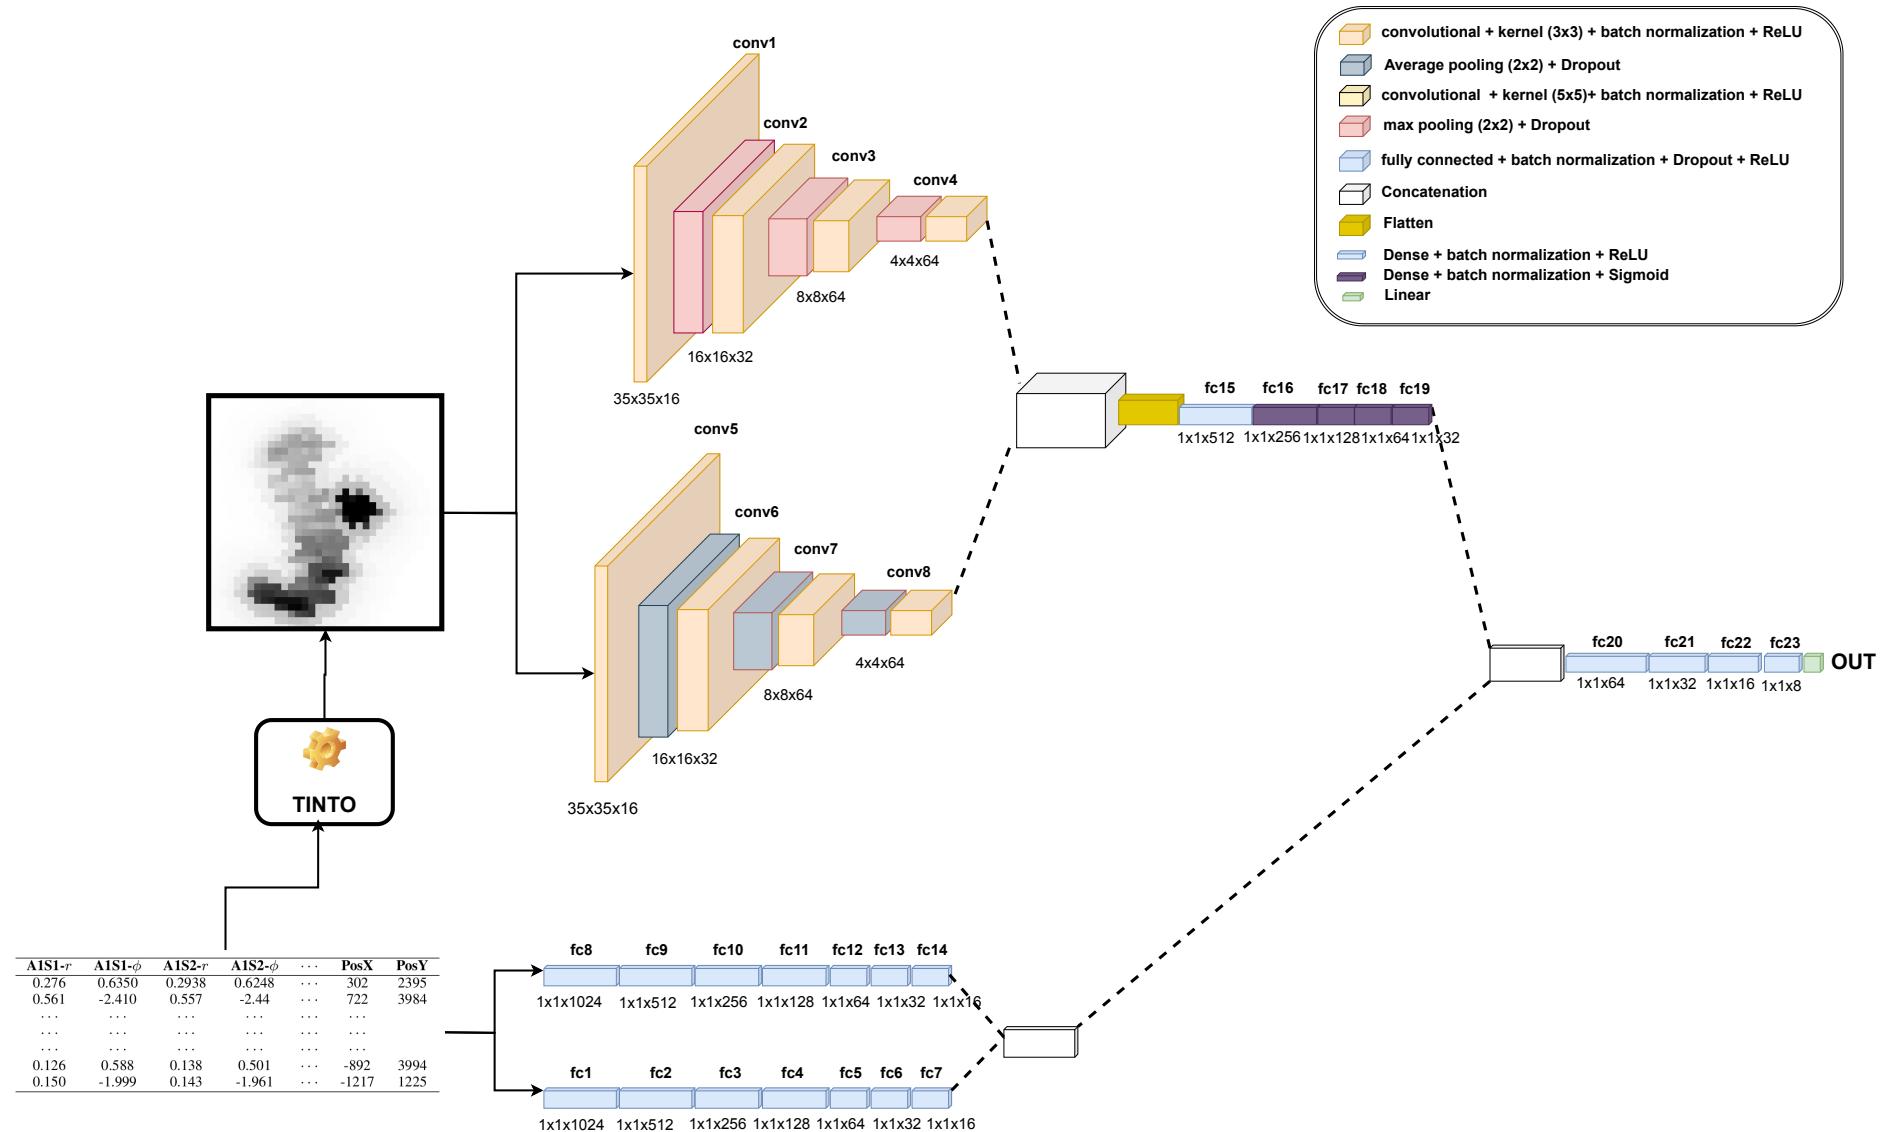
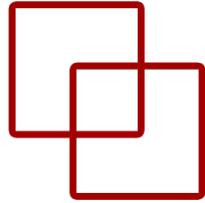


CNN Puras

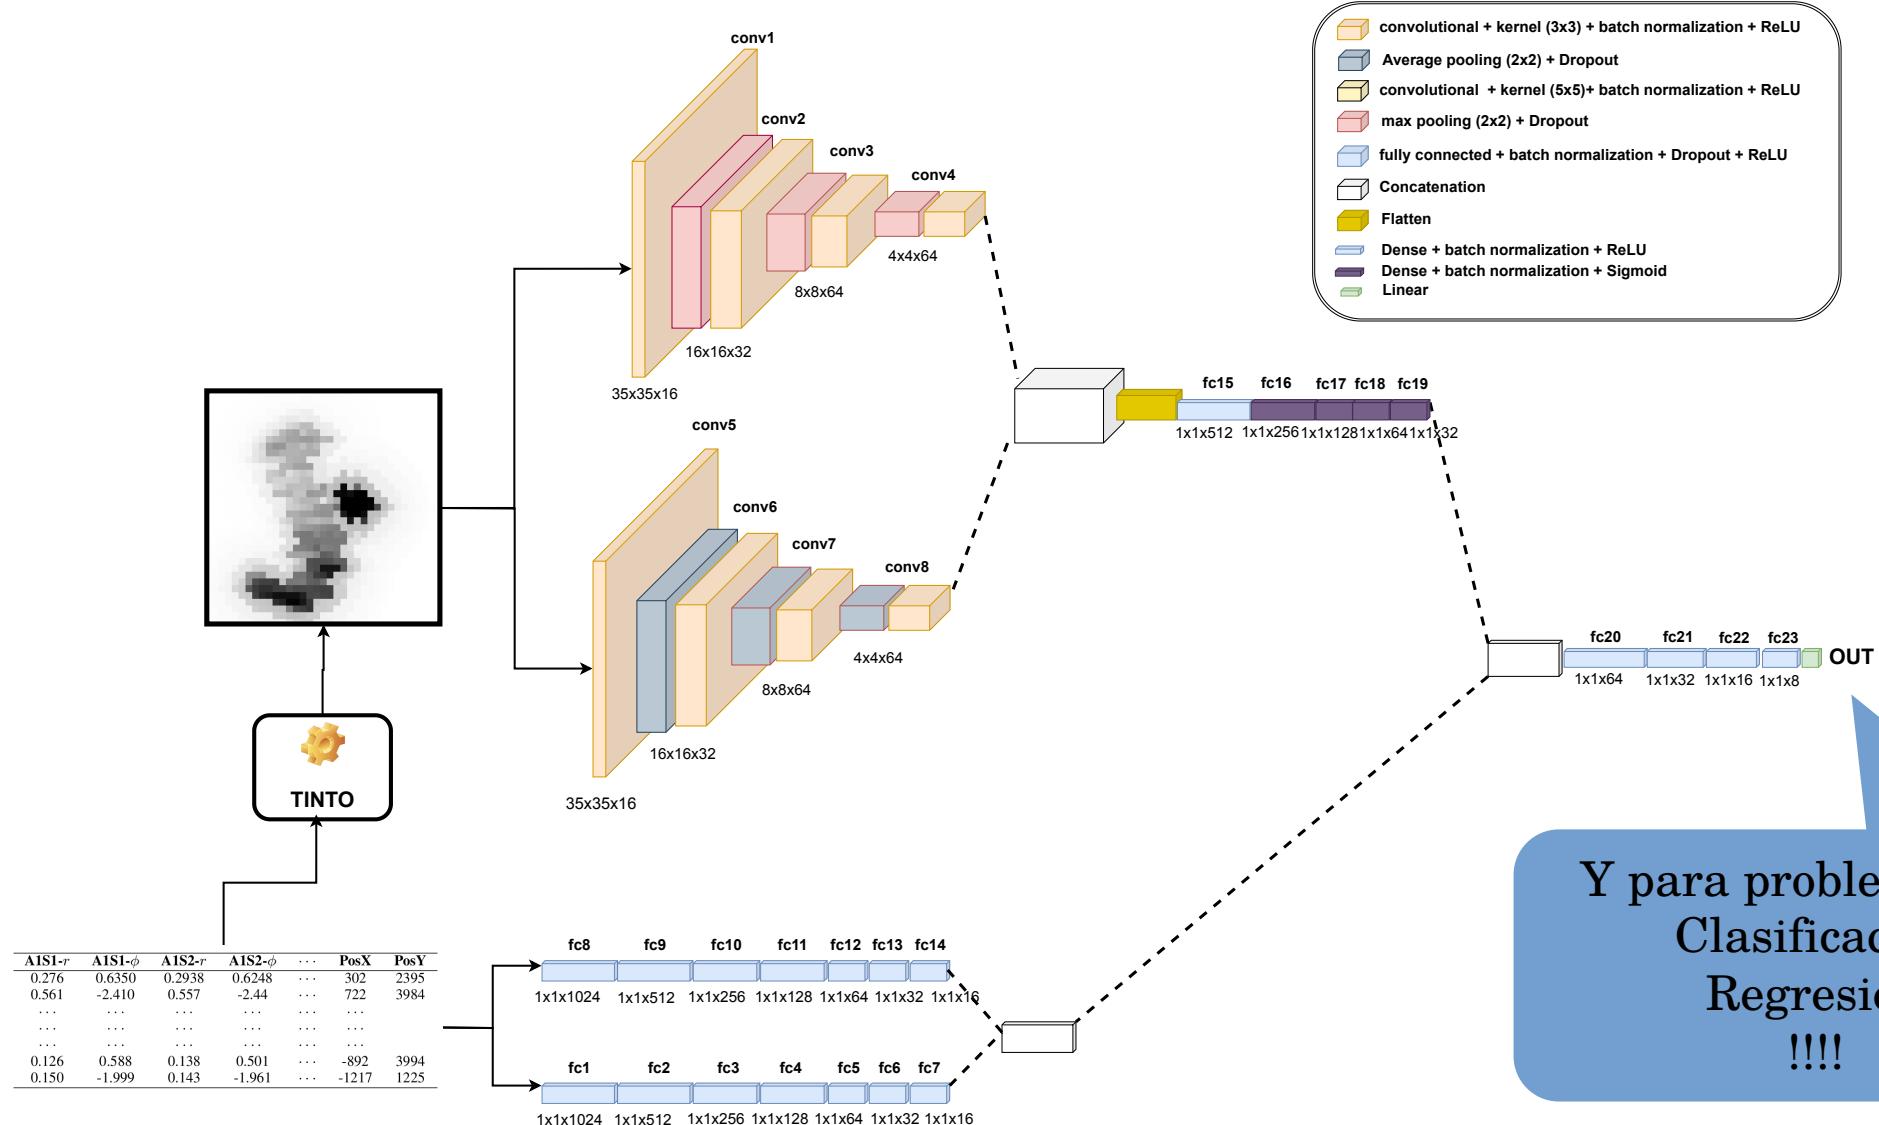
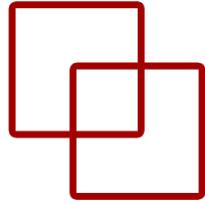


Pero no sólo
CNNs

Hybrid Neural Network



Hybrid Neural Network



Y para problemas de:
Clasificación
Regresión
!!!!

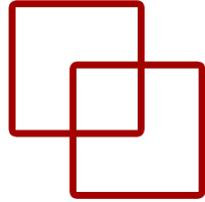
Métodos de conversión

ETS de
Ingeniería
Informática



UNED

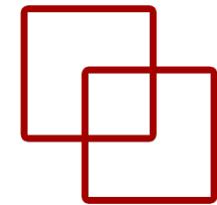
TINTOlib



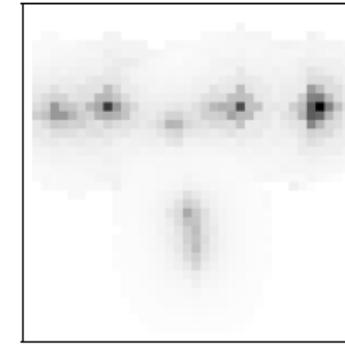
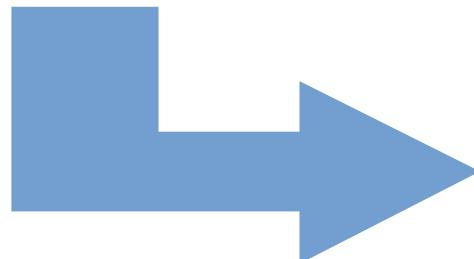
POLITÉCNICA



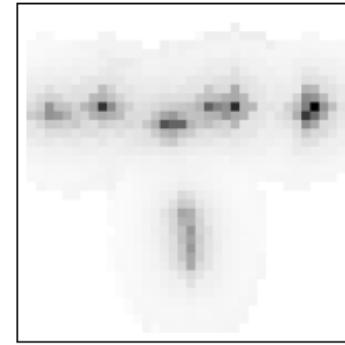
Transformación de datos



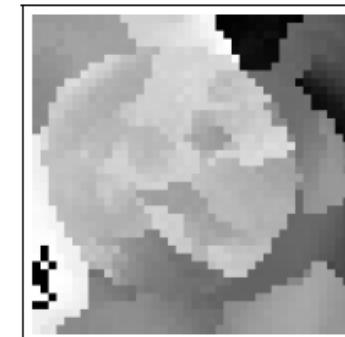
Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15



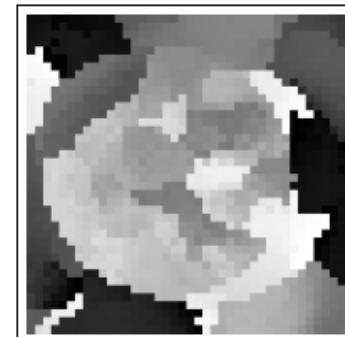
(a) TINTO - Sample 1.



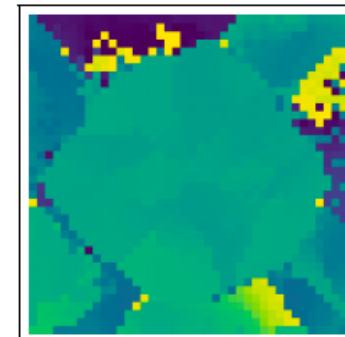
(b) TINTO - Sample 50,000.



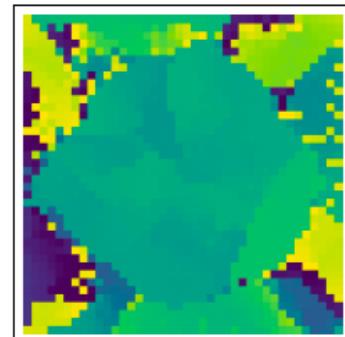
(c) IGTD - Sample 1.



(d) IGTD - Sample 50,000.

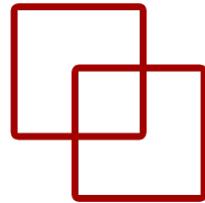


(e) REFINED - Sample 1.



(f) REFINED - Sample 50,000.

Métodos de transformación



Technique	Field	Basis
TINTO [1], [11]	General	PCA or t -SNE + blurring
DeepInsight [15]	General	PCA or t -SNE
IGTD [12]	General	Permutations between pixels
REFINED [9]	General	MDS + permutations between pixels
SuperTML [6]	General	Draw the values in the image
BarGraph [13]	General	Bar representation of the features
DistanceMatrix [13]	General	Matrix of distances between features
Combination [13]	General	BarGraph and DistanceMatrix combination
OmicsMapNet [10]	Omics	Treemaps using hierarchical data
Signal Fingerprint [2]	Fingerprinting	Use of eigenvector as image

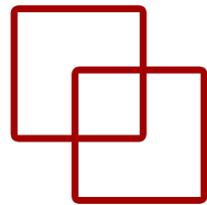
BarGraph,
DistanceMatrix y
Combination

ETS de
Ingeniería
Informática

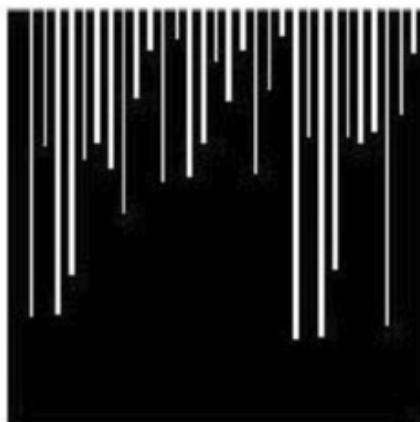


UNED

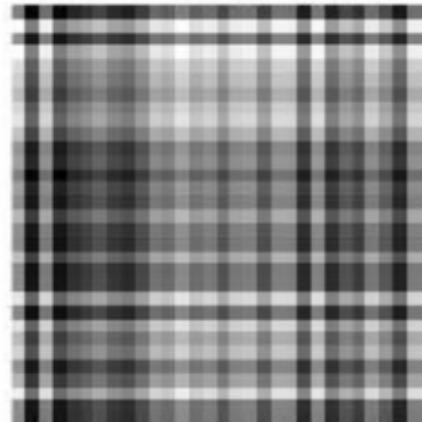
BarGraph, DistanceMatrix y Combination



Technique	Field	Basis
TINTO [1], [11]	General	PCA or <i>t</i> -SNE + blurring
DeepInsight [15]	General	PCA or <i>t</i> -SNE
IGTD [12]	General	Permutations between pixels
REFINED [9]	General	MDS + permutations between pixels
SuperTML [6]	General	Draw the values in the image
BarGraph [13]	General	Bar representation of the features
DistanceMatrix [13]	General	Matrix of distances between features
Combination [13]	General	BarGraph and DistanceMatrix combination
OmicsMapNet [10]	Omics	Treemaps using hierarchical data
Signal Fingerprint [2]	Fingerprinting	Use of eigenvector as image



(a) BarGraph



(b) DistanceMatrix

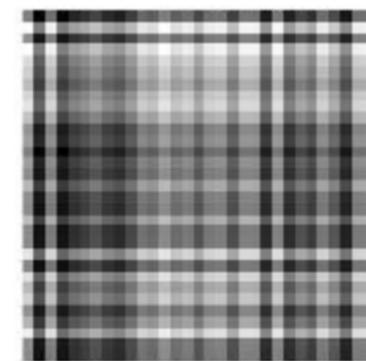
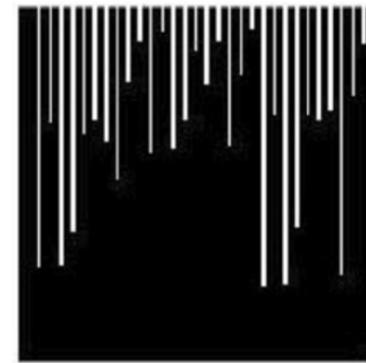


(c) Combination

BarGraph, DistanceMatrix y Combination

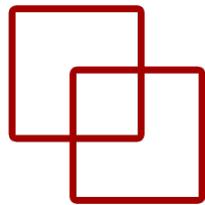
Metodología

- Representan las características normalizadas y las relaciones entre sí:
- **Equidistant Bar Graph:**
 - Se representan los valores de las variables normalizadas entre [0,1] en un **gráfico de barras**.
 - Sus hiperparámetros permiten ajustar el grosor de las barras y la distancia entre las mismas.
 - Las imágenes resultantes están dadas en 1 canal (W/B).
- **Normalized Distance Matrix:**
 - Representa una **matriz de distancias** de todas las variables normalizadas entre [0,1].
 - Los valores se muestran en escala de grises.
 - Las imágenes resultantes están dadas en 1 canal (W/B).
- **Combination of option:**
 - Este método es una **combinación de los dos anteriores**.
 - Las imágenes resultantes están dadas en 3 canales (RGB).
- Realizan cálculos muy **sencillos** con coste **computacional muy bajo**.
- Sin embargo, **no** tiene en cuenta la **distribución espacial** de las variables.



BarGraph

Algoritmo



- El tamaño de las imágenes viene dado por la multiplicación entre $varN$ y la suma de las variables $pixel_width$ y gap .

$$H = (pixel_width + gap) * varN$$

- Cada barra del gráfico de barras representa una característica de X_i donde $i \in [1, N]$.
- Para calcular el tamaño de cada barra de cada característica hay que multiplicar la altura de la imagen con el valor normalizado de $X_i(j)$ donde $j \in [1, varN]$.
- Cada instancia viene definida por un vector B_i que contiene la altura de cada característica.

$$B_i = [H * X_i]$$

- Una vez calculadas las alturas de todas las instancias de X se crean las imágenes dejando un espacio entre las barras igual a gap .

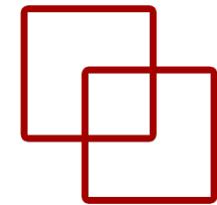
Algorithm 4: BarGraph

Data: $pixel_width$, gap
Result: Monochrome images with bar graphs

Define image height/width:
 $H = (pixel_width + gap) * varN;$
for $i = 0 : N$ **do**
 Initialize an empty image M_i of size $(H \times H)$;
 Compute the bar heights of the image:
 $B_i = [H * X_i];$
 Initialize Bar counter: $k = 0$;
 for $j = 0 : H$ with increment $gap+pixel_width$ **do**
 Incorporate the bar into the image:
 $M_i[B_i(k), j : (j + pixel_width)] = 1;$
 Increment counter: $k + 1$;
 if $k < varN$ **then**
 | break;
 end
 end
end

DistanceMatrix

Algoritmo



1. Crea las imágenes tras calcular la matriz de distancias normalizadas de las características de la instancia.

2. Tras normalizar las instancias X a $[0,1]$, se calcula la matriz de distancias entre las características para todo X_k donde $k \in [1, N]$.

3. El cálculo de la matriz de distancias se realiza mediante la siguiente ecuación:

$$M_k = [X_k(i) - X_k(j)]; \forall (i, j) \in varN, \forall k \in N$$

4. Una vez calculadas todas las matrices de distancias de X , se debe aplicar una normalización para establecer una escala en blanco/negro $[0, 255]$.

$$norm_grey(M_k) = [| 255 \times m_{kij} |]$$

Algorithm 5: DistanceMatrix

Data: scale

Result: B/W images with

Normalise features: $X = norm01(X)$;

for $k = 0 : N$ **do**

 Create an empty 2D matrix M_k of size
 $(varN \times varN)$;

for $i = 0 : varN$ **do**

for $j = 0 : varN$ **do**

 Calculate distance between variables:
 $M_k(i, j) = X_k(i) - X_k(j)$;

end

end

end

 Normalize M_k : $M_k = norm_grey(M_k)$;

 Expand pixels according to scale:

$M_k(i, j) = M_k(i, j) * scale$;

 Save M_k as a grayscale image

end

Combination Algoritmo

1. Combina BarGraph y DistanceMatrix en un solo método algorítmico.
2. Para este caso, la imagen resultante se compone de 3 capas de color:
 - Capa de DistanceMatrix
 - Capa de BarGraph
 - Capa que contiene una matriz en la que cada fila contiene el valor normalizado de cada característica de X . La fila 1 contendrá el valor normalizado de la característica 1, la fila 2 el valor 2, etc.
3. Para calcular la Capa 3, de color, se utiliza la siguiente Ecuación, donde $k \in X$ e $i, j \in [1, varN]$.

$$M_k(i, j) = X_k(i)$$

Algorithm 6: Combination

Data: pixel_width, gap
Result: B/W images

Define bar height/width:
 $H = (\text{pixel_width} + \text{gap}) * \text{varN};$
Normalise features: $X = \text{norm01}(X);$

for $i = 0 : N$ **do**

\\STEP 1: DistanceMatrix;
Create a zero matrix $M1_i$ of size $(\text{varN} \times \text{varN});$
for $z = 0 : \text{varN}$ **do**
 for $w = 0 : \text{varN}$ **do**
 | Calculate distance between variables:
 | $M1_k(z, w) = X_k(z) - X_k(w);$
 end
end
Normalise $M1_k$: $M1_k = \text{norm_grey}(M1_k);$
Expand pixels:
 $M1_k(i, j) = M1_k(i, j) * (\text{pixel_width} + \text{gap});$

\\STEP 2: BarGraph;
Create a zero matrix $M2_i$ of size $(H \times H);$
Create the height of the image bars: $B_i = [H * X_i];$
Bar counter: $k = 0;$
for $j = 0 : H$ with increment $\text{gap} + \text{pixel_width}$ **do**
 Add the bar to the image:
 $M2_i[B_i(k), j : (j + \text{pixel_width})] = 1;$
 $k + 1;$
 if $k < \text{varN}$ **then**
 | **break**;
 end
end

\\STEP 3: Feature by row;
Create a zero matrix $M3_i$ of size $(\text{varN} \times \text{varN});$
for $m = 0 : \text{varN}$ **do**
 for $n = 0 : \text{varN}$ **do**
 | $M3_i(m, n) = X_i(m)$
 end
end
Normalise: $M3_i$: $M3_i = \text{norm01}(M3_i);$
Expand pixels:
 $M3_i(m, n) = M3_i(m, n) * (\text{pixel_width} + \text{gap});$

\\STEP 4: Create image;
Join matrices and save in RGB ($M1_i, M2_i, M3_i$);

end



SuperTML

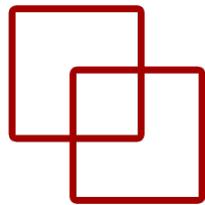


ETS de
Ingeniería
Informática



UNED

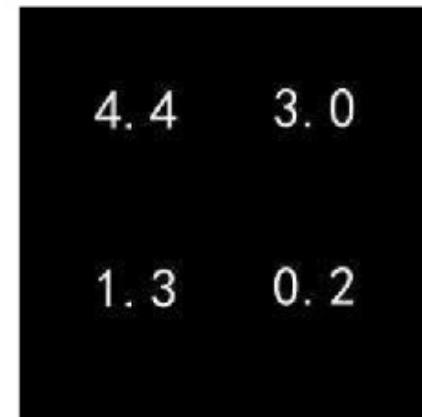
SuperTML



Technique	Field	Basis
TINTO [1], [11]	General	PCA or t -SNE + blurring
DeepInsight [15]	General	PCA or t -SNE
IGTD [12]	General	Permutations between pixels
REFINED [9]	General	MDS + permutations between pixels
SuperTML [6]	General	Draw the values in the image
BarGraph [13]	General	Bar representation of the features
DistanceMatrix [13]	General	Matrix of distances between features
Combination [13]	General	BarGraph and DistanceMatrix combination
OmicsMapNet [10]	Omics	Treemaps using hierarchical data
Signal Fingerprint [2]	Fingerprinting	Use of eigenvector as image



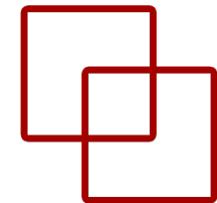
(a) SuperTML_VF



(b) SuperTML_EF

SuperTML

Metodología



- Se dibujan los valores de los datos directamente en la imagen de 1 canal (W/B).
- Se le asigna una **región de la imagen** y un tamaño para representar cada característica en formato de texto o número escrito.
- Dos enfoques:
 - *SuperTML_VF*: Cada característica dispone de una región y fuente de diferente tamaño en función de su **relevancia**. Cuanta **más importancia** tenga la característica, **más grande** será su tamaño de fuente y región.
 - *SuperTML_EF*: En este enfoque cada característica dispone de una región y fuente del **mismo tamaño**.
- El método **no tiene en cuenta la distribución espacial** de las variables, más allá de la variación de tamaño y fuente en *SuperTML_VF*.
- Otro de los **inconvenientes** son las pequeñas variaciones en las variables.
 - Por ejemplo, tiene dificultades en entender que 3,9999 y 4,0 son valores casi idénticos numéricamente.



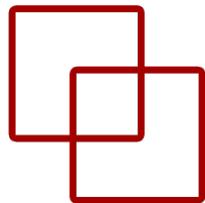
(a) SuperTML_VF



(b) SuperTML_EF

SuperTML

Algoritmo



1. Para definir las secciones de la imagen en las que se escribirán las características que debemos tener en cuenta los parámetros *columns* (número de columnas en las que se escribirán las características) e *image_size* (píxeles de anchura y altura).
2. La anchura de las secciones viene definida por: $\text{column_size} = \frac{\text{image_size}}{\text{columns}}$
3. Para calcular la posición x_j e y_j , donde $j \in [1, \text{varN}]$, en la que se escribirá cada característica, hay que realizar los siguientes cálculos.
 - Para calcular x_j primero hay que definir la columna a la que pertenece la instancia x_j , dado por la Ecuación donde se aplica el módulo de *columns* sobre la posición j de la variable X_j .
$$\text{column}_j = j \mod \text{columns}$$
4. Una vez calculada column_j se puede obtener x_j por la Ec. donde p es un margen izquierdo.
$$x_j = p + \text{column}_j \times \text{column_size}$$
5. Para obtener y_j hay que calcular previamente el número de filas que contiene la imagen. Se realiza mediante la división redondeada hacia arriba del número de variables entre el número de columnas.
$$\text{rows} = \left\lceil \frac{\text{varN}}{\text{columns}} \right\rceil$$
6. Se calcula el tamaño de las filas mediante $\text{row_size} = \frac{\text{image_size}}{\text{rows}}$
7. Se calcula la fila correspondiente de cada característica mediante $\text{row}_j = j \mod \text{rows}$
8. Se calcula y_j aplicando un margen de $\text{row_size}/2$ para centrar el texto en el medio de la fila
$$y_j = \frac{\text{row_size}}{2} + \text{row}_j \times \text{row_size}$$

Algorithm 7: SuperTML

Data: columns, image_size, font_size
Result: Imágenes con los valores de las instancias
Calcular el tamaño de cada columna:
 $\text{column_size} = \frac{\text{image_size}}{\text{columns}}$;
Calcular el tamaño de cada fila:
 $\text{row_size} = \frac{\text{image_size}}{\text{rows}}$;
for $i = 0 : N$ **do**
 Crear una imagen vacía de tamaño *image_size*;
 for $j = 0 : \text{varN}$ **do**
 $x = \frac{\text{column_size}}{10} + (j \mod \text{columns}) \times \text{column_size}$;
 $y = \frac{\text{row_size}}{2} + (j \mod \text{rows}) \times \text{row_size}$;
 Dibujar el texto en la posición (x, y) con el valor $X_i(j)$;
 end
end

$$y_j = \frac{\text{row_size}}{2} + \text{row}_j \times \text{row_size}$$

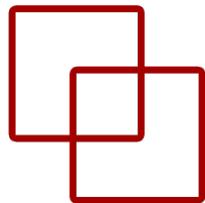
IGTD

ETS de
Ingeniería
Informática

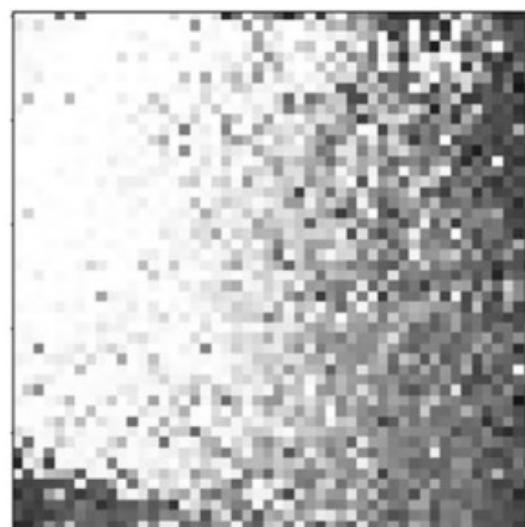


UNED

Image Generator for Tabular Data (IGTD)

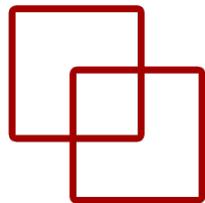


Technique	Field	Basis
TINTO [1], [11]	General	PCA or <i>t</i> -SNE + blurring
DeepInsight [15]	General	PCA or <i>t</i> -SNE
IGTD [12]	General	Permutations between pixels
REFINED [9]	General	MDS + permutations between pixels
SuperTML [6]	General	Draw the values in the image
BarGraph [13]	General	Bar representation of the features
DistanceMatrix [13]	General	Matrix of distances between features
Combination [13]	General	BarGraph and DistanceMatrix combination
OmicsMapNet [10]	Omics	Treemaps using hierarchical data
Signal Fingerprint [2]	Fingerprinting	Use of eigenvector as image

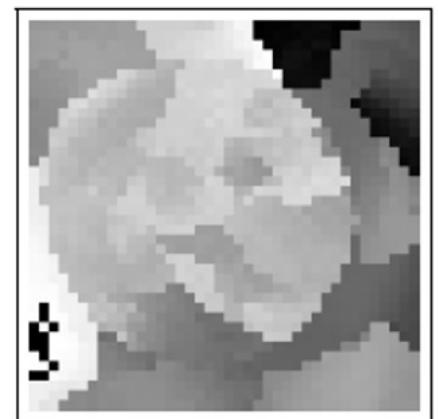


IGTD

Metodología



- Asigna **una variable por píxel** y realiza **permutaciones** en la distribución de los píxeles hasta encontrar una **distribución óptima**.
- Las distancias se calculan en función de sus **coordenadas** en la imagen.
- En cada iteración se permuta el píxel que más tiempo lleve sin ser permutado con el píxel que **minimiza** la diferencia entre los rankings.
- El algoritmo **terminará** cuando alcance en **número máximo de pasos** predefinidos como hiperparámetro.
- Las imágenes resultantes están dadas en 1 canal (W/B).
- Tiene en cuenta la **distribución espacial** de las características.
- Gracias a la permutación de características se pueden obtener imágenes que **agrupen las características similares entre sí y separen las dispares**.
- La selección de los **hiperparámetros** de IGTd tiene un papel fundamental y su efectividad dependerá de ello.



IGTD Algoritmo

1. R a matrix of the ranking of pairwise distances of the normalised features, where $r_{i,j}$ is the ranking value of the distance between feature X_i and feature X_j .
 - The distance function could be Pearson, Spearman, Euclidean or set.
2. Q a matrix of the ranking of pairwise distances of the feature positions in the image, where $q_{i,j}$ is the ranking value of the distance between feature X_i and feature X_j .
 - The distance function is given by the parameter could be Euclidean or Manhattan.
3. The size of R and Q is given by the variable scale ($M \times N$) that defines the number of rows and columns of the ranking.
 - In case the total pixels ($M * N$) is greater than the number of $varN$, padding p will be added so that $M * N + p = varN$ is met.
 - In case the total pixels ($M * N$) is less than the number of $varN$, w variables will be eliminated so that $M * N + p = varN$ is met.
 - No criterion is defined to select the features, so the last w features will be eliminated.
4. Rankings are ascending, small distances are assigned a small ranking value and viceversa.
 - The main idea is to achieve that the most similar variables (ranking R) are also the closest ones (ranking Q).
 - For this, an error function is defined that must be minimised

$$\text{err}(R, Q) = \sum_{i=2}^N \sum_{j=1}^{i-1} \text{diff}(r_{i,j}, q_{i,j})$$

where diff is the function to evaluate the difference between $(r_{i,j}, q_{i,j})$ and is given by the variable error (square or absolute error).

Algorithm 2: IGT

Data: scale, fea_dost_method, image_dist_method, save_image_size, max_step, val_step, error, switch_t, min_gain

Result: Grayscale images with one pixel / feature

Calculate initial R by fea_dist_method ;

Calculate initial Q by image_dist_method;

while $s = 0 < max_step$ **do**

- \\Select feature with the longest time without being evaluated;
- $n^* = \underset{n \in \{1, 2, \dots, N\}}{\operatorname{argmin}} h_n$;
- \\Select feature that by permuting reduces error;
- $l^* = \underset{l \in \{1, \dots, n^*-1, n^*+1, \dots, N\}}{\operatorname{argmax}} (\text{err}(R, Q) - \text{err}(R_{n^* \sim l}, Q))$;
- \\If $\text{err} > switch_t \Rightarrow$ perform permutation ;
- If** $\frac{\text{err}(R, Q) - \text{err}(R_{n^* \sim l}, Q)}{\text{err}(R, Q)} > switch_t$ **then**

 - $k_s = k_{s-1}$;
 - Permute n^* and l^* in k_s ;
 - $e_s = \text{err}(R_{n^* \sim l}, Q)$;
 - $h_{n^*}, h_{l^*} = s$;
 - $R = R_{n^* \sim l}$;

- else**

 - $h_{n^*} = s$;
 - $e_s = e_{s-1}$;
 - $k_s = k_{s-1}$;

- end**
- If** $s < val_step$ **then**

 - \\Evaluate gain once the val_step iterations are reached;
 - $gain = \frac{e_s - val_step - e_u}{e_s - val_step} \forall u \in \{s - val_step + 1, \dots, s\}$;
 - \\If min gain is not reached the algorithm is stopped. ;
 - If** $gain < min_gain$ **then**

 - | break

 - end**

- end**

Find the iteration with the least error:

$v^* = \underset{v \in \{1, \dots, s\}}{\operatorname{argmin}} e_v$;

Transform the images using the distribution k_{v^*} ;

Save the scaled images in a save_image_size

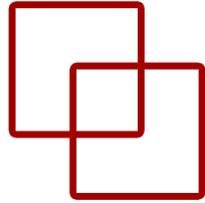
REFINED

ETS de
Ingeniería
Informática

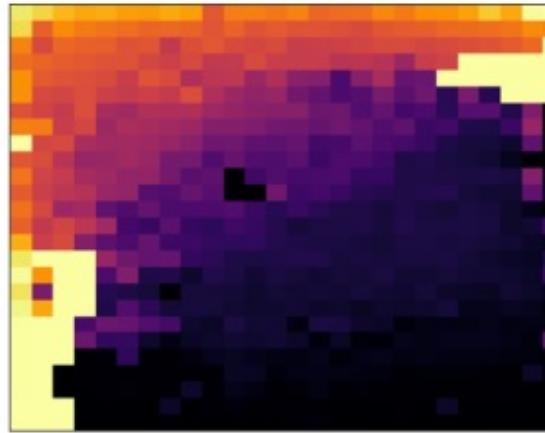


UNED

REFINED

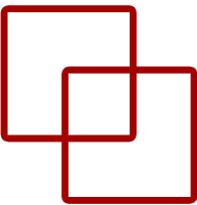


Technique	Field	Basis
TINTO [1], [11]	General	PCA or t -SNE + blurring
DeepInsight [15]	General	PCA or t -SNE
IGTD [12]	General	Permutations between pixels
REFINED [9]	General	MDS + permutations between pixels
SuperTML [6]	General	Draw the values in the image
BarGraph [13]	General	Bar representation of the features
DistanceMatrix [13]	General	Matrix of distances between features
Combination [13]	General	BarGraph and DistanceMatrix combination
OmicsMapNet [10]	Omics	Treemaps using hierarchical data
Signal Fingerprint [2]	Fingerprinting	Use of eigenvector as image

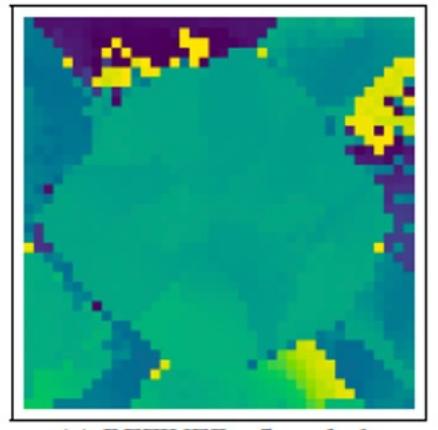


REFINED

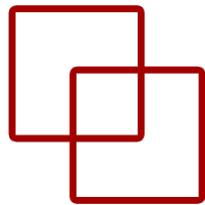
Metodología



- *REpresentation of Features as Images with NEighborhood Dependencie* (REFINED) está basado en el algoritmo de reducción de dimensionalidad **MDS**.
- Esta técnica **calcula la matriz de distancias** de las características.
- Después se aplica MDS para crear un **mapa de características inicial**.
- Aplicando MDS no se puede garantizar que cada punto mapeado esté vinculado a un píxel característico y pueden generarse imágenes dispersas.
 - Es por ello, que el siguiente paso es aplicar una variación Bayesiana del MDS (BMDS) que permite **compactar la imagen** y asignar **una característica a cada píxel**.
- Esta variación hace uso de un algoritmo *hill climbing* con una función de coste que mide la diferencia entre:
 - La **distancia euclídea** de las nuevas localizaciones de las características y las distancias reales estimadas.
- Se realizan permutaciones iterativamente entre un píxel central y su vecino que **minimice esa función de coste**.
- Las imágenes resultantes están dadas en 3 canales (RGB).
- Tiene cuenta **la distribución espacial** de las variables.



REFINED Algoritmo



1. Crear una matriz D de distancias euclídeas de las características donde $D \in IR^{varN \times varN}$.

$$D = \begin{bmatrix} d_{11} & \dots & d_{1varN} \\ d_{21} & \dots & d_{2varN} \\ \vdots & \ddots & \vdots \\ d_{N1} & \dots & d_{varNvarN} \end{bmatrix}$$

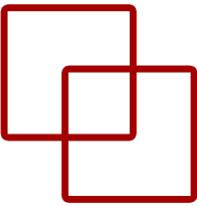
donde, $d_{ij} = x_i - x_j$ y x_i representa el valor de la característica i de X y x_j representa el valor de la característica j de X .

2. Crear un mapa de características inicial que preserve las distancias de las características en un espacio 2D mediante el método MDS.
 - Se crea la matriz $S \in IR^{varN \times 2}$ donde el valor b_{i1} es la coordenada en el eje x de la variable i y b_{i2} es la coordenada en el eje y de la variable i , donde $i \in [1, varN]$.

$$MDS(D, 2) = S = \begin{bmatrix} b_{11} & b_{12} \\ \vdots & \vdots \\ b_{varN1} & b_{varN2} \end{bmatrix}$$

3. Aplicar el método BMDS propuesto por los autores para estimar la localización de las características, con la condición de que exista una característica por píxel.
 - Para la localización de los píxeles característicos se define un proceso homogéneo de Poisson (HPP) con una $\lambda = varN / [0, 1]^2$.
 - Dada la matriz de instancias D se define d_{jk} distancias observadas entre la variable j y k , donde $j, k \in [1, varN]$.

REFINED Algoritmo



3. (continuación) Aplicar el método BMDS propuesto por los autores para estimar la localización de las características, con la condición de que exista una característica por píxel.

- Las distancias reales no observadas son definidas como:

$$\delta_{jk} = \sqrt{\sum_l (s_{j,l} - s_{k,l})^2}$$

- donde s es un sistema de coordenadas 2D dado S que denota la localización real de las variables predictoras j y k , donde $l \in [1,2]$.
- El modelo queda descrito por la siguiente ecuación

$$f(d-s, \sigma^2) \propto (\sigma^2)^{-\frac{q}{2}} \exp[-\frac{1}{2\sigma^2} \sum_{j>k} (d_{jk} - \delta_{jk})^2 - \sum_{i>k} \log \Phi(\frac{\delta_{jk}}{\sigma})]$$

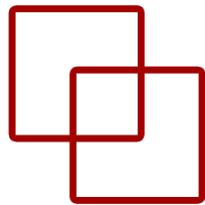
- donde $q = \binom{varN}{2}$ es el número total de distancias y $\Phi(\cdot)$ es la función de distribución acumulada (CDF) de la distribución normal estándar. La distribución a priori está dada por una distribución Gamma inversa $\sigma^2 \sim IG(a, b)$ con $a > 2$ y $b > 0$. La distribución a posteriori queda de la siguiente manera:

$$[s, \sigma^2 | d] \propto (\sigma^2)^{-\frac{q}{2} + a + 1} \exp[-\frac{1}{2\sigma^2} \sum_{j>k} (d_{jk} - \delta_{jk})^2 - \sum_{i>k} \log \Phi(\frac{\delta_{jk}}{\sigma}) - \frac{b}{\sigma^2}]$$

- Finalmente, hace uso del muestreador *Metropolis-in-Gibbs* para calcular las localizaciones a posteriori de las características. En este punto se obtiene la matriz M que contiene la distribución inicial de las características en una imagen 2D.

REFINED

Algoritmo



4. Aplicar el algoritmo *hill climbing* para reducir la diferencia entre la matriz de distancias D y el mapa de características inicial M .
 - Para ello se permuta un centroide (píxel característico que se está evaluando en esa iteración) con el vecino que más disminuya la función de coste.
 - Se evalúan todos los píxeles característicos en cada paso del algoritmo *hill climbing*.
 - El resultado de este paso es la matriz C que contiene la posición final de cada característica en la imagen.
5. Una vez optimizada la posición de cada píxel característico, se realiza la transformación de las instancias X y se guardan las imágenes.

Algorithm 3: REFINED

Data: hcIterations

Result: Images with instance values

Create a distance matrix:

$D = \text{euclidean_distances}(X);$

Reduce the dimensionality of X with MDS:

$M = MDS(X);$

Calculate non-overlapping coordinates:

$B = BMDS(D, M);$

Hill Climbing with hcIterations iterations:

$C = HC(D, B);$

Apply transformation C to X ;

for $i = 0 : N$ **do**

$img_i = \text{transform}(C, X_i);$

 Save image img_i ;

end

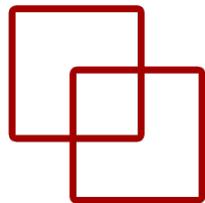
TINTO

ETS de
Ingeniería
Informática

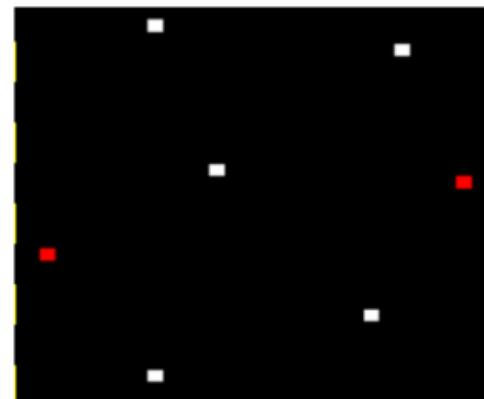


UNED

DeepInsight – TINTO



Technique	Field	Basis
TINTO [1], [11]	General	PCA or t -SNE + blurring
DeepInsight [15]	General	PCA or t -SNE
IGTD [12]	General	Permutations between pixels
REFINED [9]	General	MDS + permutations between pixels
SuperTML [6]	General	Draw the values in the image
BarGraph [13]	General	Bar representation of the features
DistanceMatrix [13]	General	Matrix of distances between features
Combination [13]	General	BarGraph and DistanceMatrix combination
OmicsMapNet [10]	Omics	Treemaps using hierarchical data
Signal Fingerprint [2]	Fingerprinting	Use of eigenvector as image



(a) DeepInsight.



(b) TINTO.

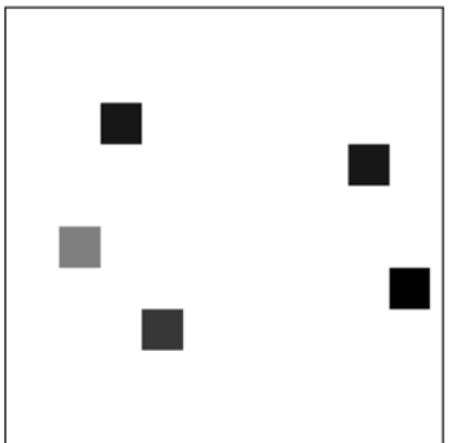
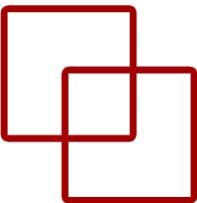
1. Talla-Chumpitaz, Ret al. (2023). A novel deep learning approach using blurring image techniques for Bluetooth-based indoor localisation. *Information Fusion*, 91, 173-186.
2. Castillo-Cara, Manuel, et al (2023). TINTO: Converting Tidy Data into image for classification with 2-Dimensional Convolutional Neural Networks. *SoftwareX*, 22, 101391.
3. A. Sharma, et al. "Deepinsight: A methodology to transform a non-image data to an image for convolution neural network architecture," *Scientific Reports*, vol. 9, 2019.

DeepInsight – TINTO

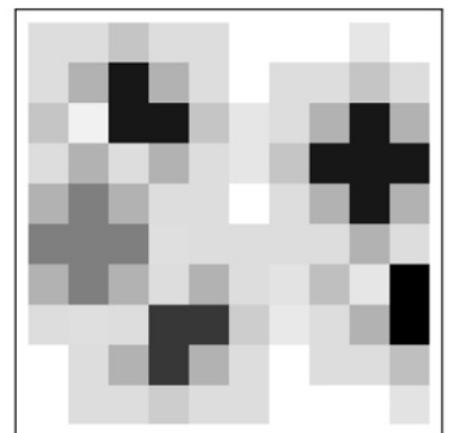
Metodología

- DeepInsight se basa en algoritmos *t-SNE* o PCA.
- Tras aplicar el DRA se obtiene una **representación 2D** de la distribución de las características en función de su similitud.
- Al realizar la transformación puede existir **solapamiento** entre píxeles característicos y se aborda realizando la media de los valores.
- El siguiente paso es aplicar el algoritmo *hull convexo*, que se encarga de **agrupar las características** en el menor rectángulo posible.
- El último paso es realizar una rotación de la imagen resultante.

- TINTO es una ampliación de DeepInsight pero escrito en Python.
- Este método proporciona la **especificación formal** de los pasos para obtener la posición de los píxeles característicos y **soluciona el problema de solapamiento** que existe en DeepInsight.
- Además, se propone el uso de un método de **Blurring** o difuminado en los píxeles característicos que simula el desvanecimiento de la señal.
- Las imágenes resultantes **están dadas en 1 canal** (B/W).



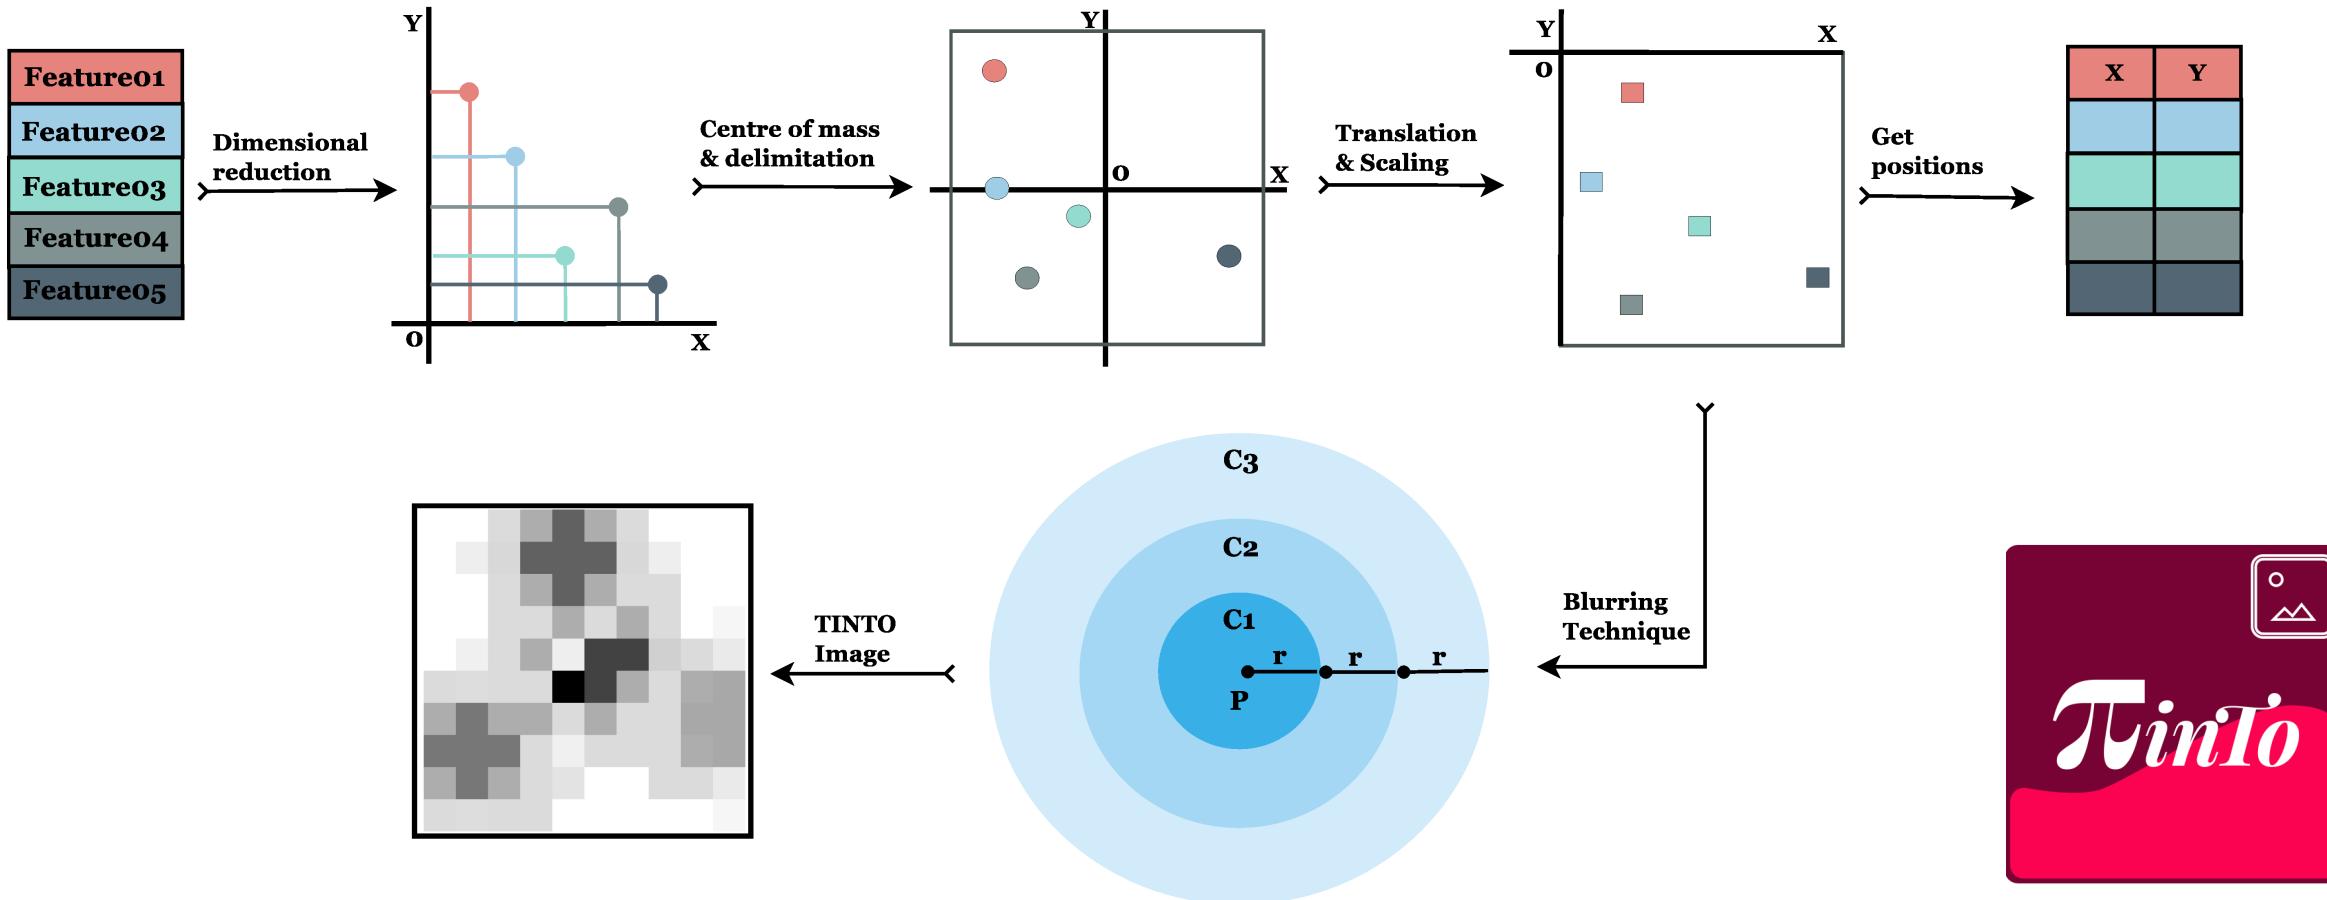
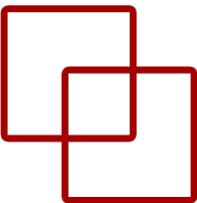
(a) Without blurring.



(c) Blurring with maximum value.

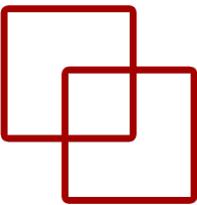
TINTO

Metodología



TINTO

Algoritmo



1. Reducción de la dimensionalidad de los datos: La matriz inicial se transpone. Obsérvese que cada característica se representa con un color diferente a efectos de presentación, aunque la figura resultante constará de dos canales, es decir, blanco y negro. Esta tarea utiliza un algoritmo de reducción de la dimensionalidad. En este caso, TINTO exploró dos de estos algoritmos: PCAy t-SNE.
2. Centro de masa y delimitación: Una vez obtenidas las coordenadas, se determina el centro de gravedad de los puntos y, a continuación, se delimita la zona.
3. Escalado y posición de los píxeles. La matriz se transpone, se escala y los valores se redondean a valores enteros.
4. Posiciones características de los píxeles: Los valores obtenidos serían las posiciones de los píxeles característicos para la creación del patrón de la imagen.
5. Por último, la técnica de difuminado permite expandir y difuminar el valor característico del píxel a sus píxeles vecinos, enriqueciendo así la información de la imagen. Puede hacer un blurring max o mean si se superponen dos píxeles.

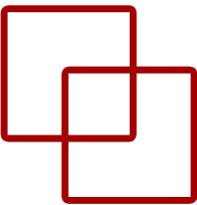
Algorithm 1: TINTO

Data: algorithm, pixels, blur, amplification, distance, steps, option, seed, times
Result: Grayscale images

Normalize features: $X = \text{norm01}(X)$;
Apply dimensionality reduction: $B = \text{DRA}(X^t, 2)$;
Calculate characteristic points: $P = \{p_1, \dots, p_{varN}\}$ where $p_i = (b_{i1}, b_{i2}) \forall i \in varN$;
Scale and define pixel positions: $C = G(X)$;
Calculate characteristic points: $Q = F_2(F_1(p_i))$;
for $i = 0 : N$ **do**
 $img = H(C, Q)$;
 Save image img ;
end

TINTO

Algoritmo



1. Reducción de la dimensionalidad de los datos: La matriz inicial se transpone. Obsérvese que cada característica se representa con un color diferente a efectos de presentación, aunque la figura resultante constará de un solo color.
2. Centro de masa y desviación estándar: se determina el centro de masa y se delimita la zona de interés.
3. Escalado y posición: se escala la imagen y los valores se redondean.
4. Posiciones características: serían las posiciones de los píxeles del patrón de la imagen.
5. Por último, la técnica de fusionamiento de información (Information Fusion) aplica el valor característico del píxel a sus píxeles vecinos, enriqueciendo así la información de la imagen. Puede hacer un blurring max o mean si se superponen dos píxeles.

Código y formulización matemática muy compleja. Podéis verlo en estos dos artículos:

Information Fusion
SoftwareX

blur, amplification, distance, times

*norm01(X);
function: $B = DRA(X^t, 2);$
points: $P =$
 $p_i = (b_{i1}, b_{i2}) \forall i \in varN;$
positions: $C = G(X);$
points: $Q = F_2(F_1(p_i));$*



TINTOlib

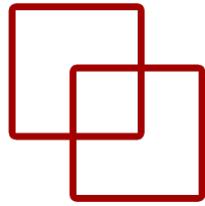


**ETS de
Ingeniería
Informática**



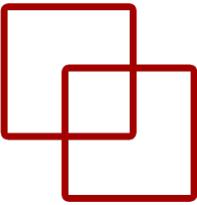
UNED

Métodos TINTOlib



Método	Importar	Declarar
TINTO	from TINTOlib.tinto import TINTO	TINTO(*parameters*)
REFINED	from TINTOlib.refined import Refined	REFINED(*parameters*)
IGTD	from TINTOlib.igtd import IGTd	IGTD(*parameters*)
SuperTML	from TINTOlib.supertml import SuperTML	SuperTML(*parameters*)
DistanceMatrix	from TINTOlib.distanceMatrix import DistanceMatrix	DistanceMatrix(*parameters*)
BarGraph	from TINTOlib.barGraph import BarGraph	BarGraph(*parameters*)
Combination	from TINTOlib.combination import Combination	Combination(*parameters*)

Arquitectura TINTOlib



TINTO
problem
verbose
algorithm
blur
amplification
distance
steps
option
seed
times
submatrix
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)

REFINED
problem
verbose
hIterations
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)
SuperTML
problem
verbose
Postal Code
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)

IGTD
problem
verbose
scale
scale
fea_dist_method
image_dist_method
save_image_size
max_step
val_step
error
switch_t
min_gain
seed
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)

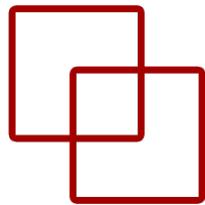
BarGraph
problem
verbose
pixel_width
gap
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)

DistanceMatrix
problem
verbose
scale
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)

Combination
problem
verbose
pixel_width
gap
saveHyperparameters(filename)
loadHyperparameters(filename)
generateImages(data,folder)



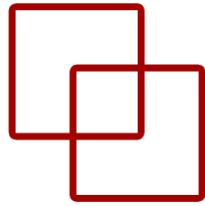
Clases y Parámetros comunes



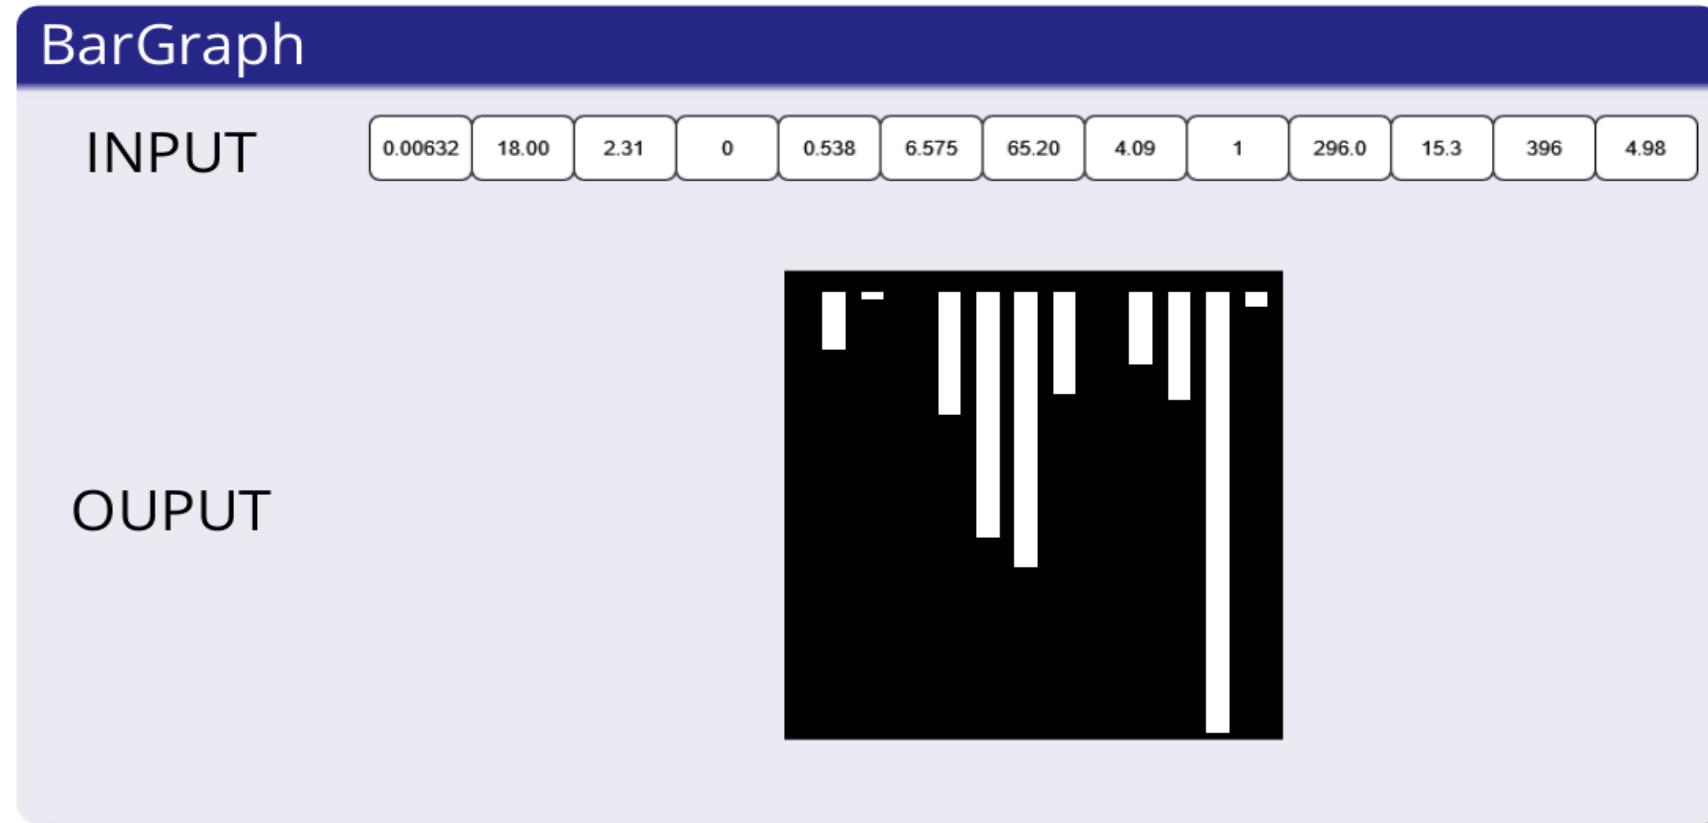
Función	Descripción	Output
saveHyperparameters(filename)	Guarda los hiperparámetros usados	Archivo .pkl con la configuración usada
loadHyperparameters(filename)	Carga los hiperparámetros de un archivo .pkl Genera las imágenes y las agrupa en carpetas.	-
generateImages(data, folder)	■ data: dataframe pandas o ruta al csv de datos ■ folder: ruta de la carpeta donde guardar las imágenes	Carpetas con las imágenes y un csv con las rutas de las imágenes

Parámetro	Tipo de variable	Valor por defecto	Descripción
problem	[supervised, regression]	supervised	Sirve para definir el tipo de problema que se quiere abordar. Afectará en la distribución por carpetas de las imágenes. En los problemas de clasificación se agruparán las clases por carpetas, mientras que en regresión se agruparan todas las imágenes en la misma carpeta.
verbose	boolean	False	Muestra información en la terminal sobre la ejecución de los métodos.

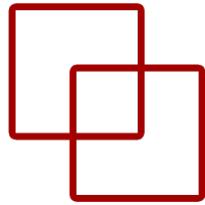
BarGraph



Parámetro	Tipo de variable	Valor por defecto	Descripción
pixel_width	integer	3	Anchura de las barras en píxeles
gap	integer	2	Píxeles de distancia entre cada barra



DistanceMatrix



Parámetro	Tipo de variable	Valor por defecto	Descripción
scale	integer	1	La escala de la imagen. Con escala 1 cada píxel representa un valor de la matriz de distancias

DistanceMatrix

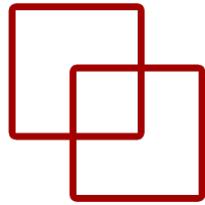
INPUT

0.00632 18.00 2.31 0 0.538 6.575 65.20 4.09 1 296.0 15.3 396 4.98

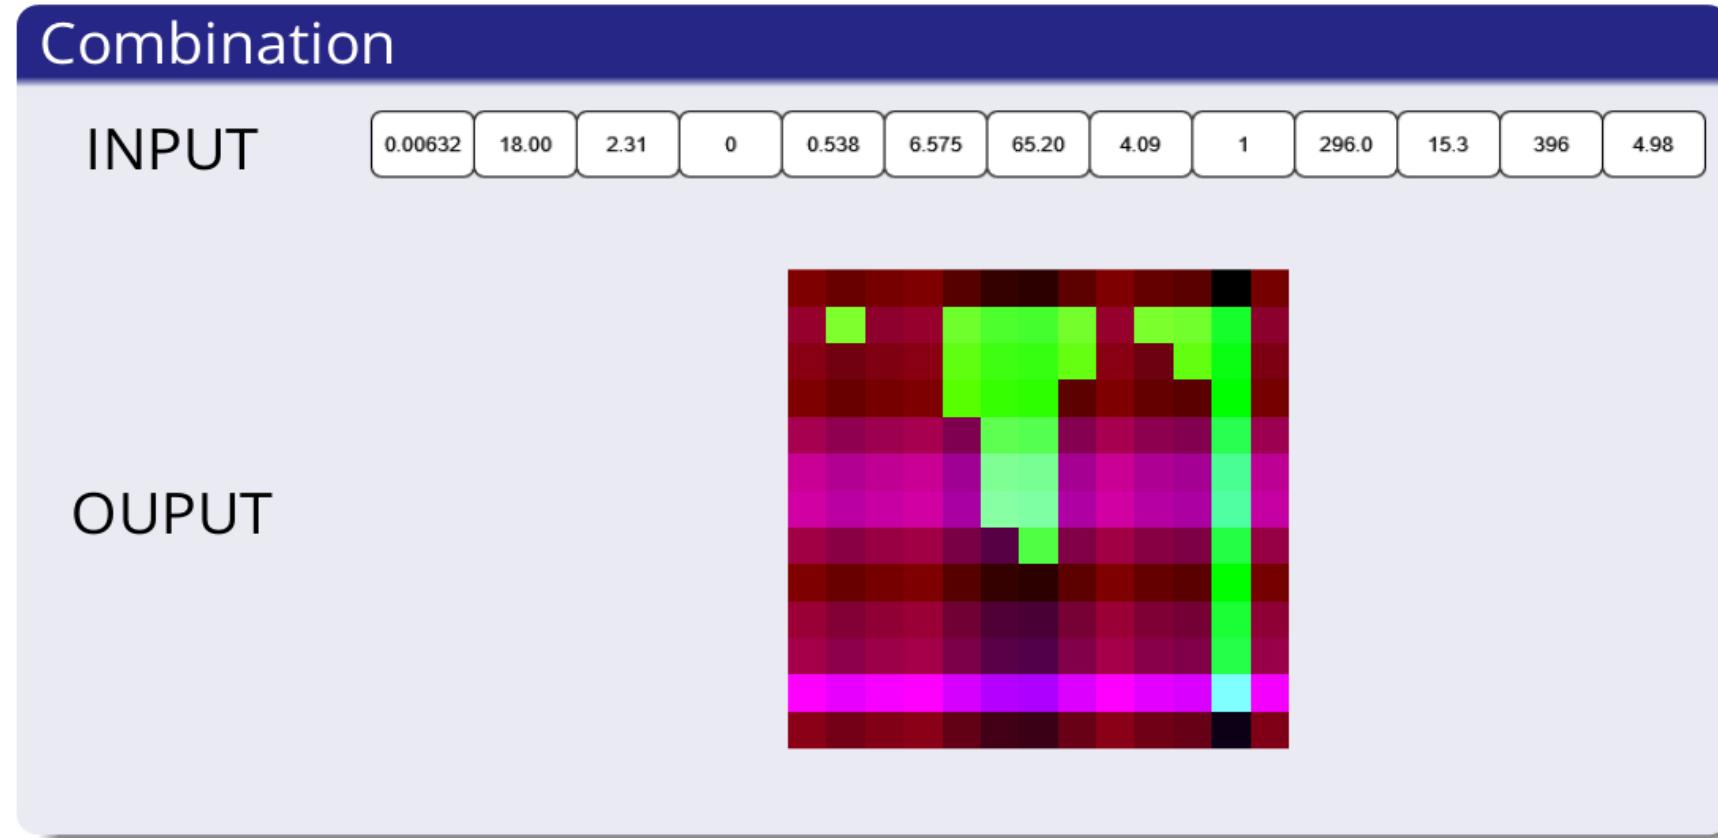
OUTPUT

A 12x12 pixel grayscale heatmap. The pixels transition from white at the bottom to black at the top. A single vertical column of black pixels runs along the right edge of the grid.

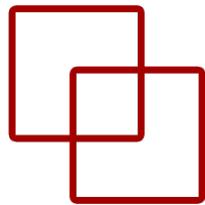
Combination



Parámetro	Tipo de variable	Valor por defecto	Descripción
pixel_width	integer	3	Anchura de las barras en píxeles
gap	integer	2	Píxeles de distancia entre cada barra



SuperTML



Parámetro	Tipo de variable	Valor por defecto	Descripción
columns	integer	4	Número de columnas en las que se dividirá la imagen
image_size	integer	224	Tamaño de la imagen
font_size	integer	10	Tamaño de fuente de la imagen

SuperTML

INPUT

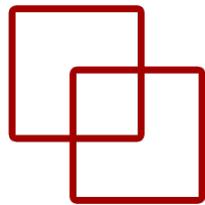
0.00632 18.00 2.31 0 0.538 6.575 65.20 4.09 1 296.0 15.3 396 4.98

OUTPUT

The output is a 4x4 grid of numbers, each representing one of the 16 elements from the input list. The numbers are arranged in a 4x4 pattern:

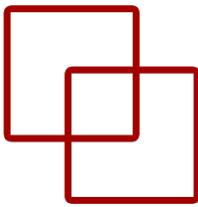
0.006	18.000	2.310	0.000
0.538	6.575	65.200	4.090
1.000	296.000	15.300	396.900
4.980			

TINTO



Parámetro	Tipo de variable	Valor por defecto	Descripción
algorithm	[PCA, t-SNE]	PCA	Algoritmo de reducción de dimensionalidad a utilizar
pixels	integer	20	El numero de píxeles de cada lado de la imagen. Píxeles totales = píxeles x píxeles
blur	boolean	False	Uso del método de blurring o no
amplification	float	np.pi	En caso de usar blurring, radio de amplificación del blurring
distance	integer[0,1]	0.1	En caso de usar blurring, distancia en los que tendrá efecto el blurring (en porcentaje)
steps	integer	4	En caso de usar blurring, pasos del método de blurring
option	[mean, maximum]	mean	En caso de usar blurring, técnica para abordar la superposición de píxeles
seed	integer	20	Semilla utilizada para los números aleatorios
times	integer	4	En caso de utilizar t-SNE como algoritmo, indica las veces que se replicara el t-SNE
submatrix	boolean	True	Utilizar submatrices para realizar los cálculos de manera más eficiente

TINTO



TINTO

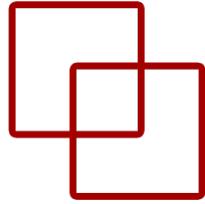
INPUT

0.00632	18.00	2.31	0	0.538	6.575	65.20	4.09	1	296.0	15.3	396	4.98
---------	-------	------	---	-------	-------	-------	------	---	-------	------	-----	------

OUTPUT

A 28x28 pixel grayscale image showing a highly pixelated version of the number '4'. The image is rendered in a blocky, low-resolution style with varying shades of gray.

REFINED



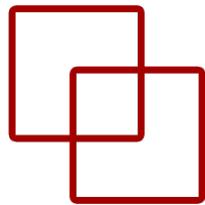
Parámetro	Tipo de variable	Valor por defecto	Descripción
hcIterations	integer	100	Número de iteraciones máximas del algoritmo hill climbing

REFINED

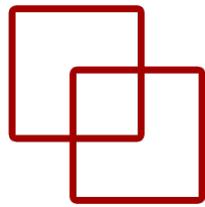
INPUT

0.00632	18.00	2.31	0	0.538	6.575	65.20	4.09	1	296.0	15.3	396	4.98
---------	-------	------	---	-------	-------	-------	------	---	-------	------	-----	------

OUTPUT



Parámetro	Tipo de variable	Valor por defecto	Descripción
scale	[integer,integer]	[2,2]	Píxeles característicos de la imagen final (fila x columna)
fea_dist_method	[Pearson, Spearman, Euclidean set]	Pearson	Método utilizado para evaluar la distancia entre pares de las características
image_dist_method	[Euclidean, Manhattan]	Euclidean	Método utilizado para calcular las distancias de los píxeles asignados en la imagen
save_image_size	integer	20	Número de píxeles de la imagen (n x n)
max_step	integer	1000	El número máximo de pasos en caso de que el algoritmo no converja
val_step	integer	50	Número de pasos para verificar la ganancia en la función objetivo para determinar la convergencia
error	[squared, abs]	squared	Función para evaluar la diferencia entre la clasificación de distancia de características y la clasificación de distancia de píxeles
switch_t	integer	0	El umbral para determinar si la permutación de píxeles debe realizarse
min_gain	float	0.00001	Si la función objetivo no se mejora más que 'min_gain' en los pasos 'val_step', el algoritmo termina
seed	integer	1	Semilla utilizada para los números aleatorios



IGTD

INPUT

0.00632	18.00	2.31	0	0.538	6.575	65.20	4.09	1	296.0	15.3	396	4.98
---------	-------	------	---	-------	-------	-------	------	---	-------	------	-----	------

OUTPUT

A 4x4 grid of colored squares. The colors transition from white to dark gray across the rows and columns. The bottom-right square is solid black, while all other squares are white, light gray, or medium gray.

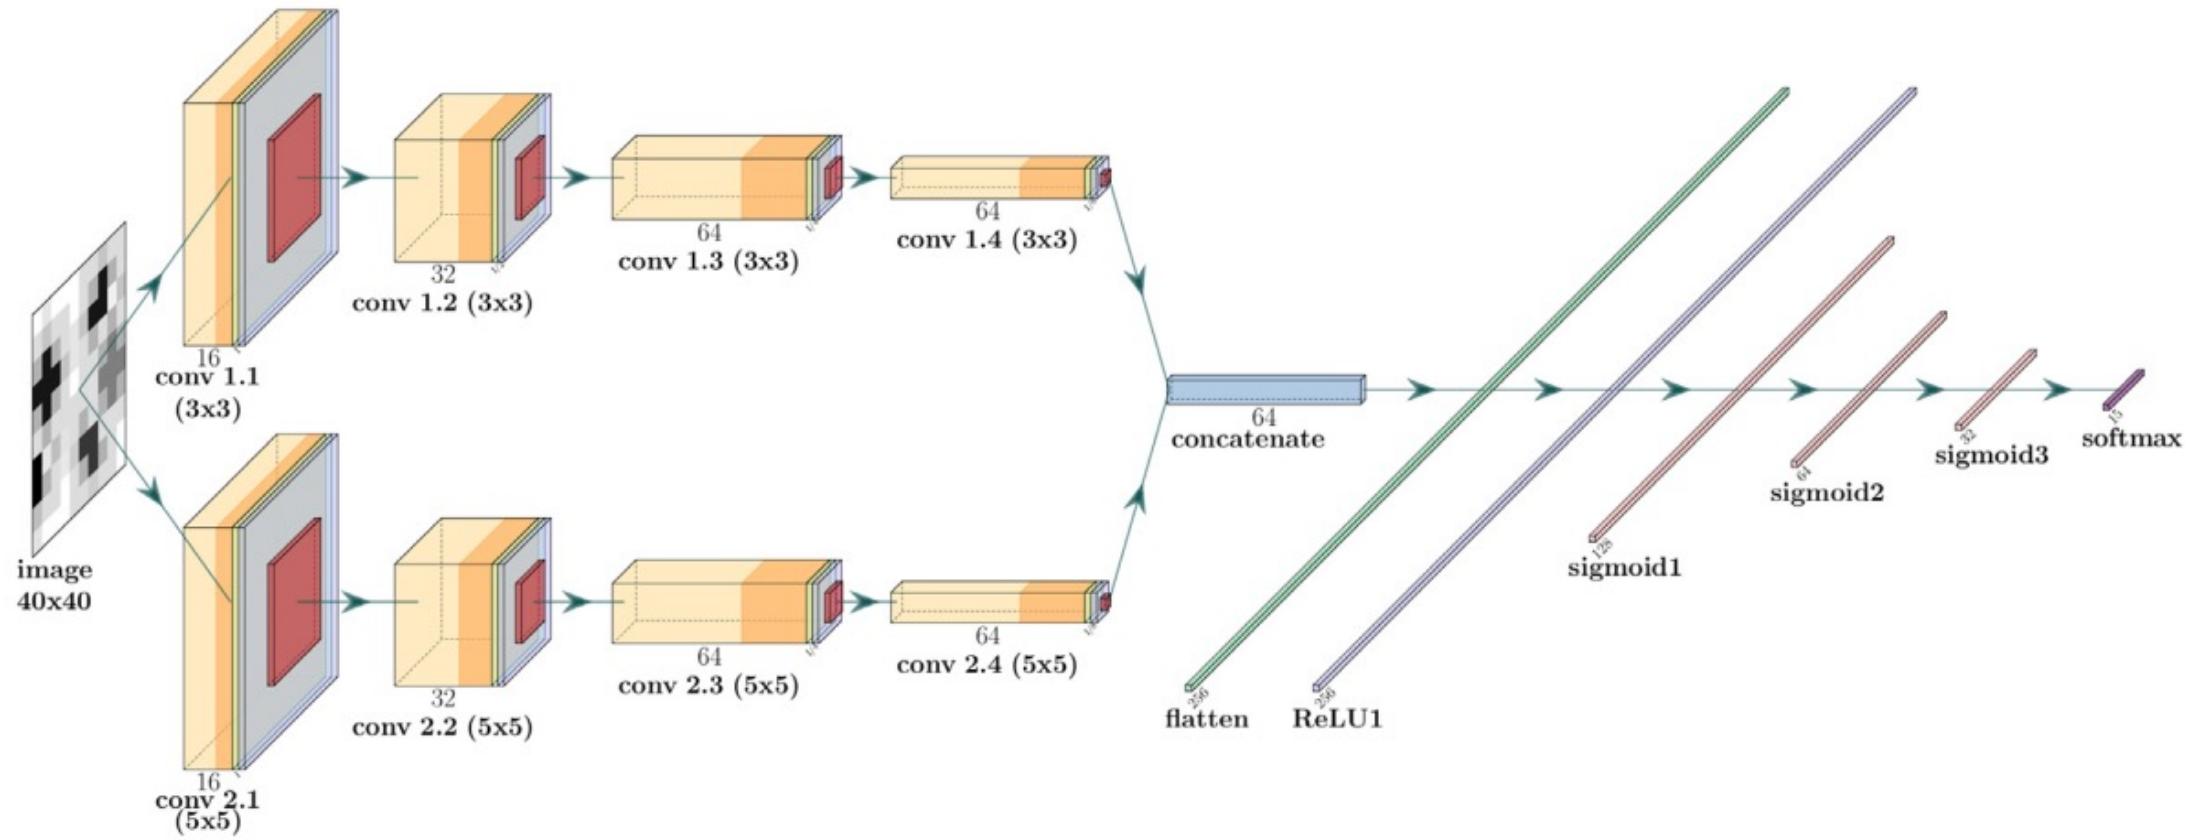
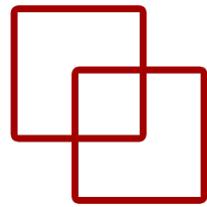
\Arquitecturas Híbridas

ETS de
Ingeniería
Informática

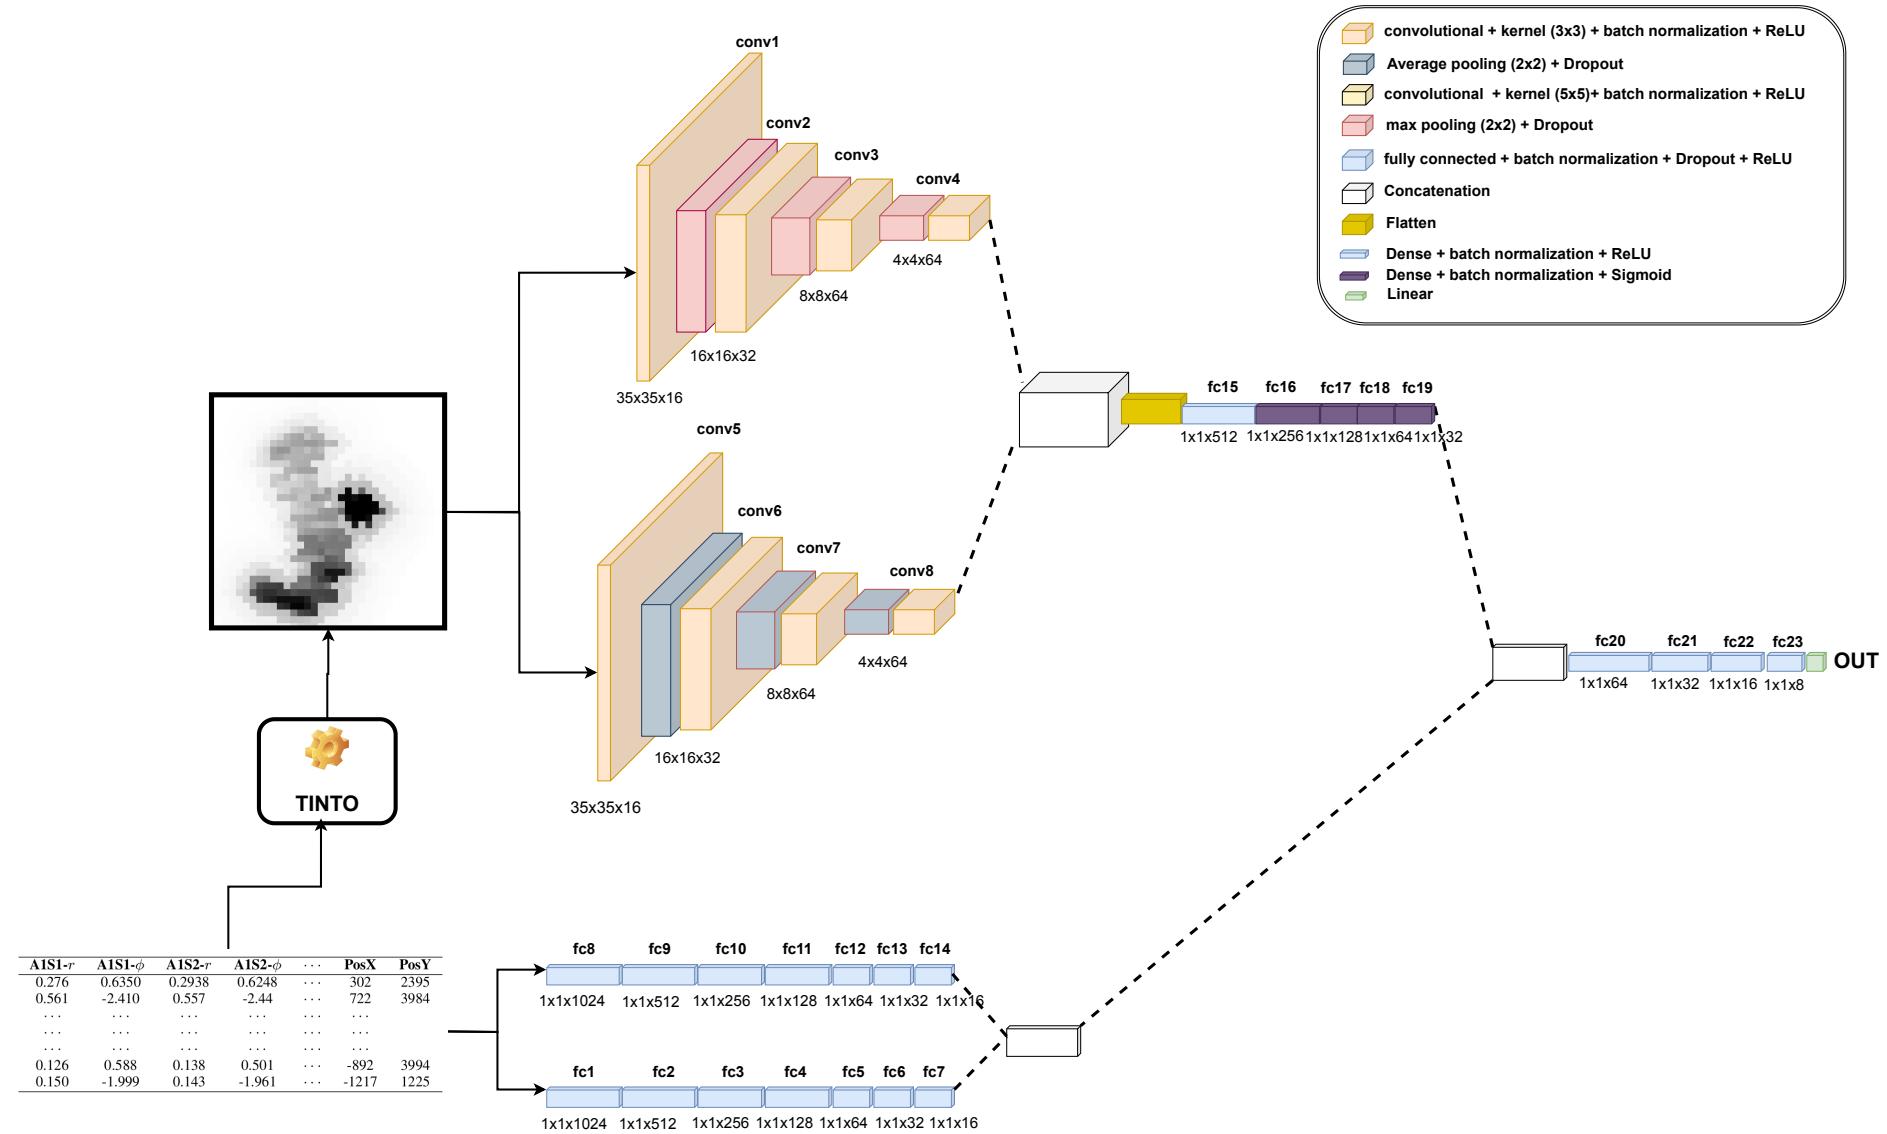
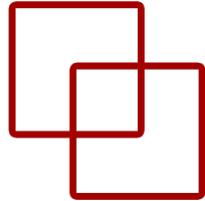


UNED

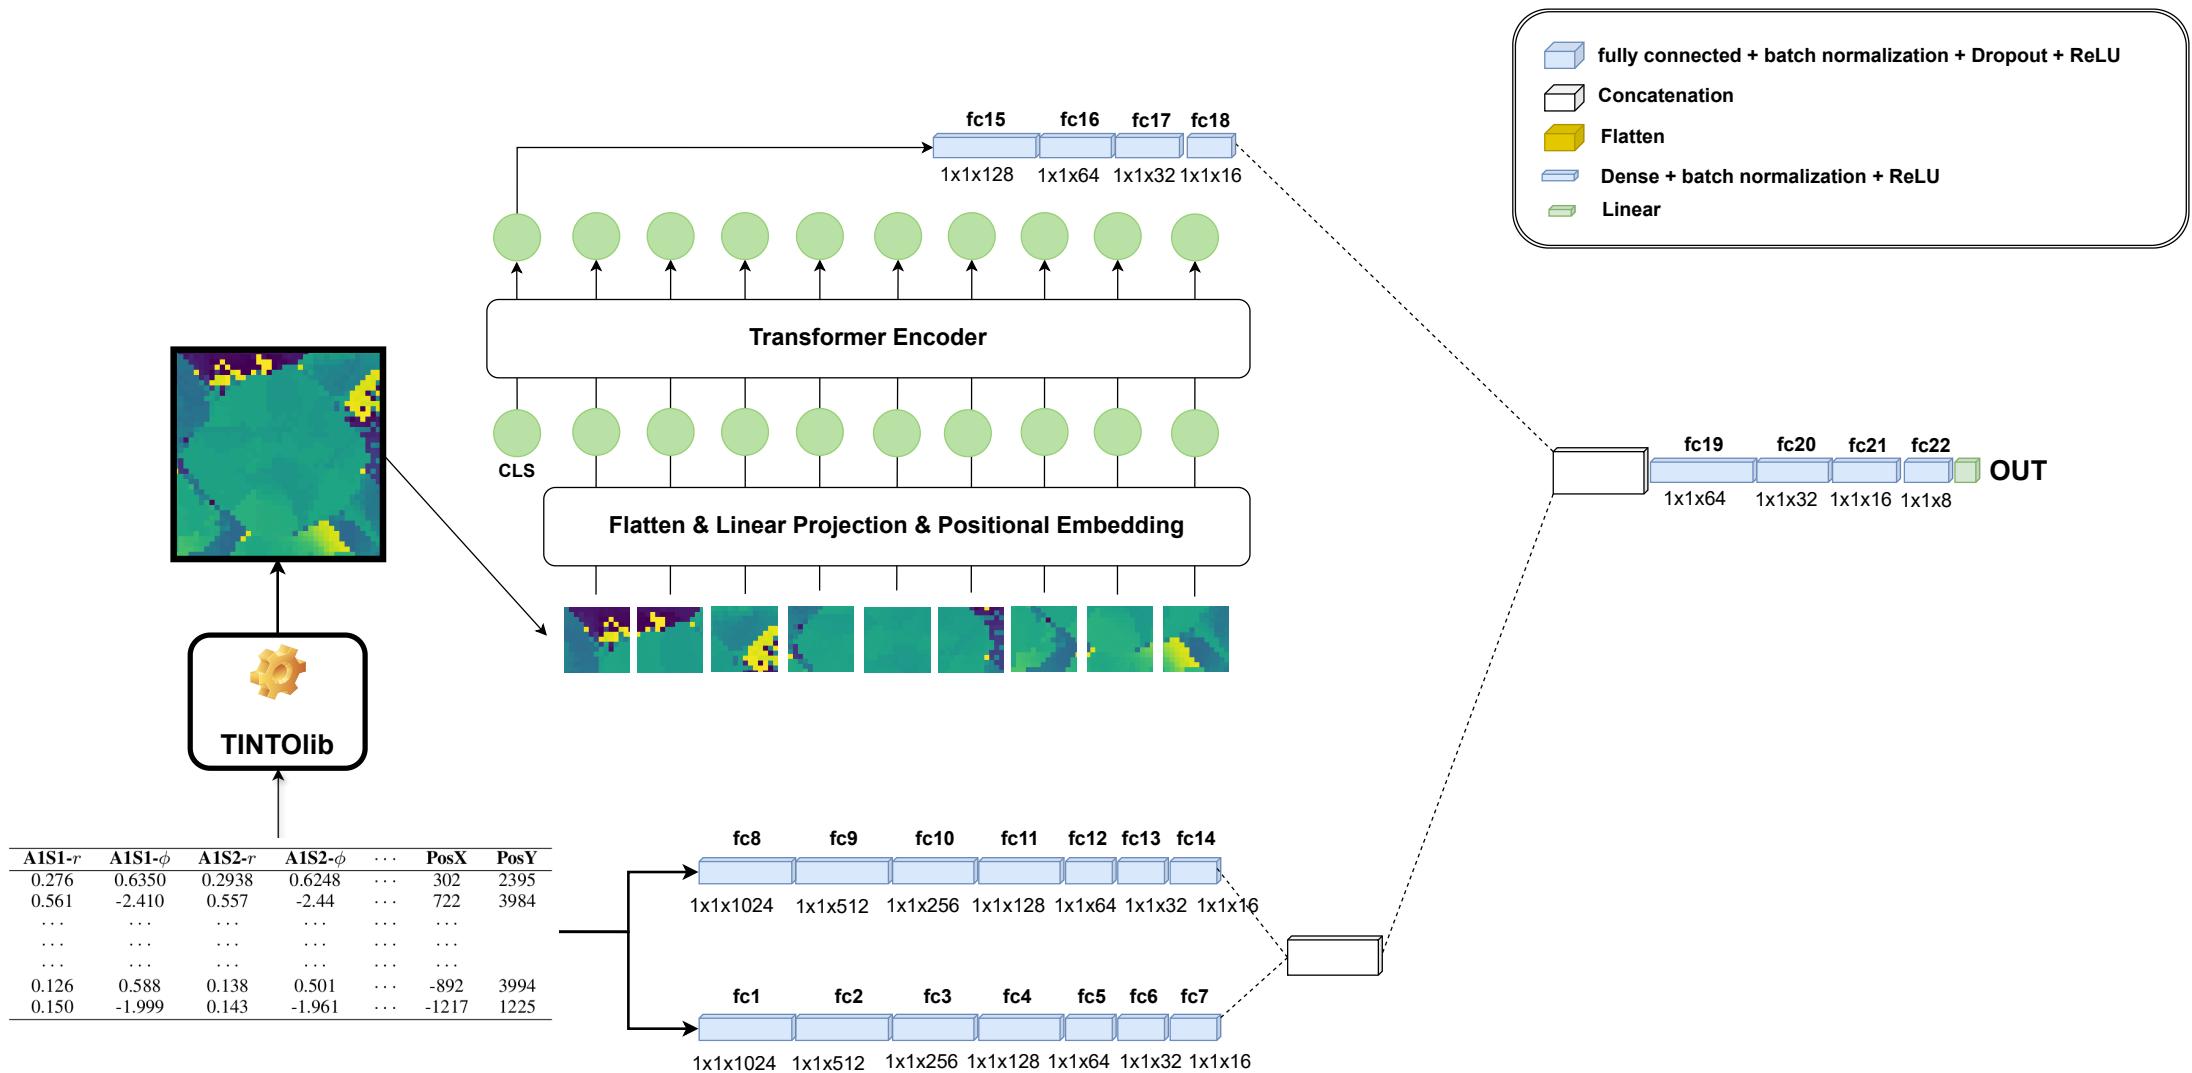
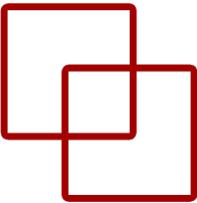
CNN



HyNN



HyViT



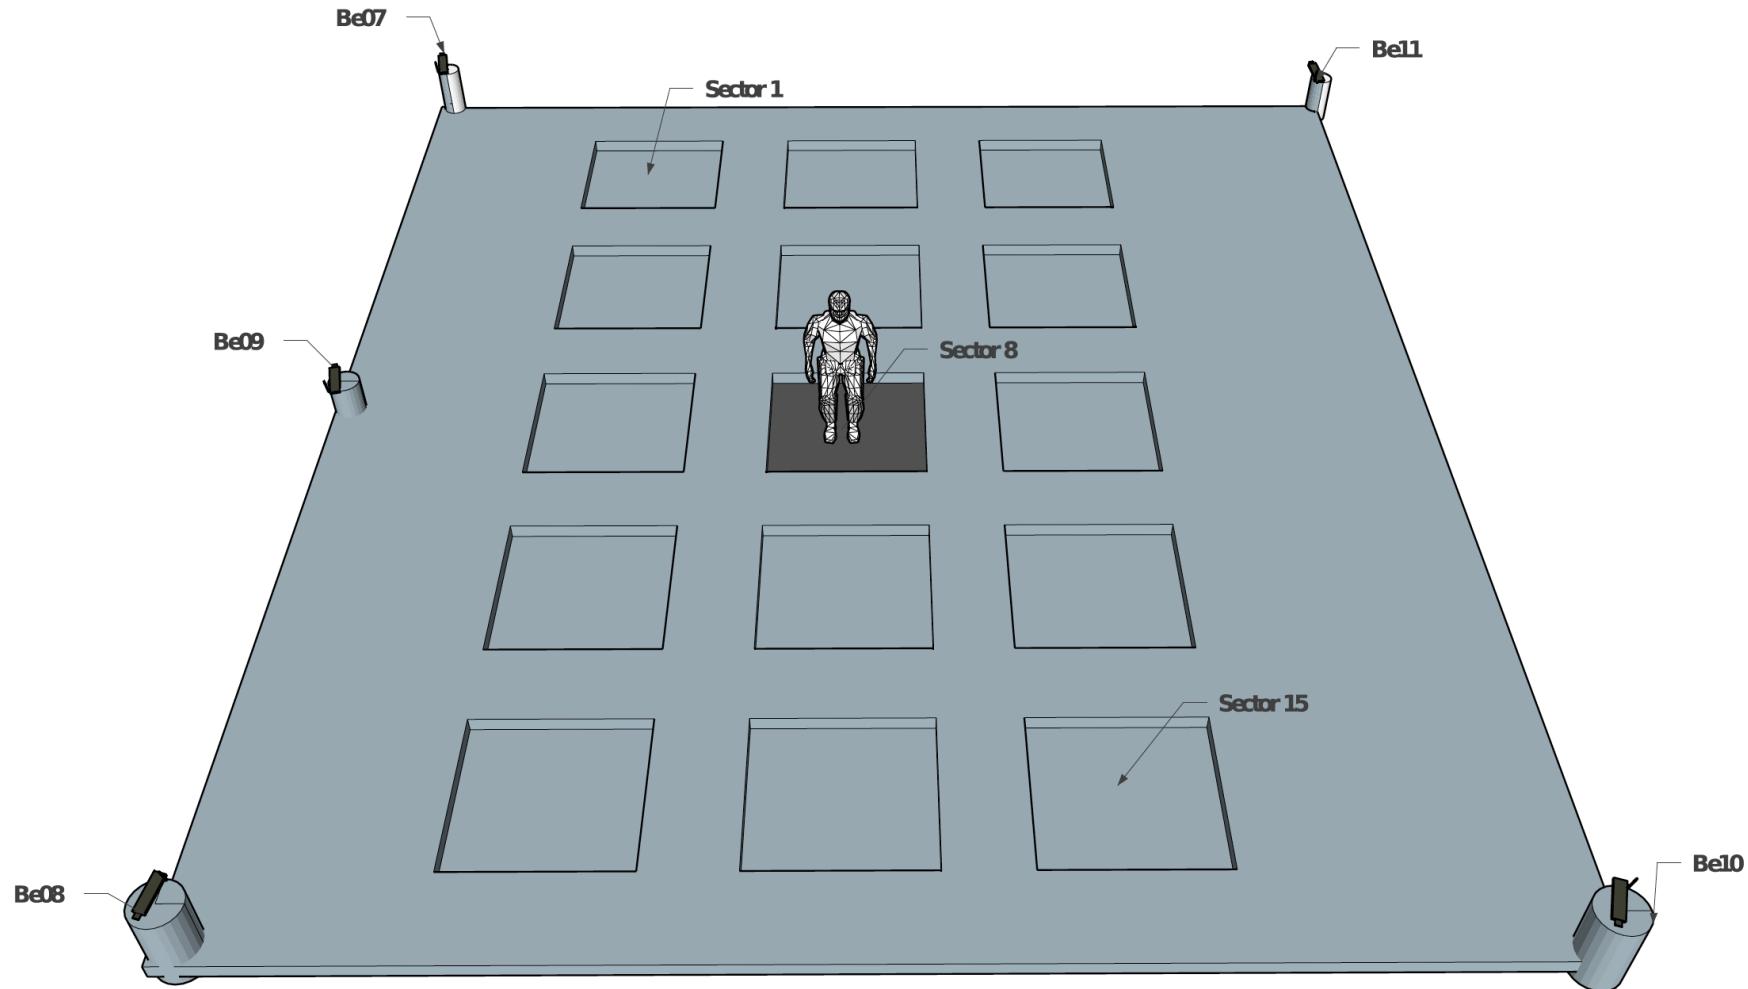
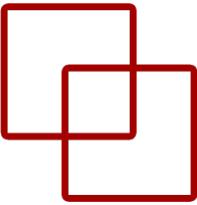
‘Caso de uso 1: Localización en interiores con BLE

ETS de
Ingeniería
Informática

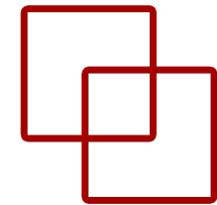


UNED

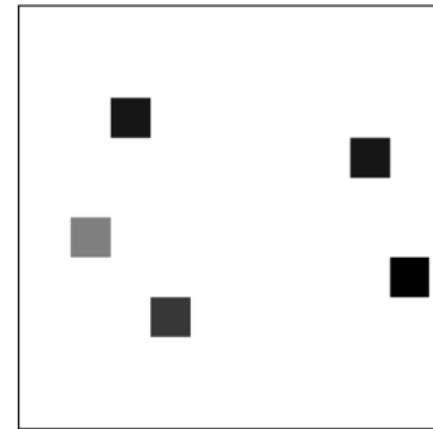
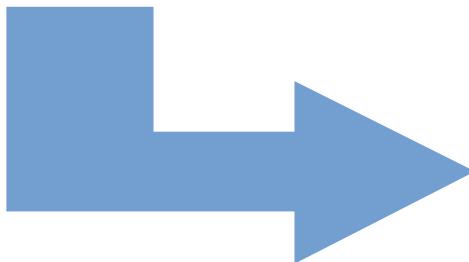
Escenario



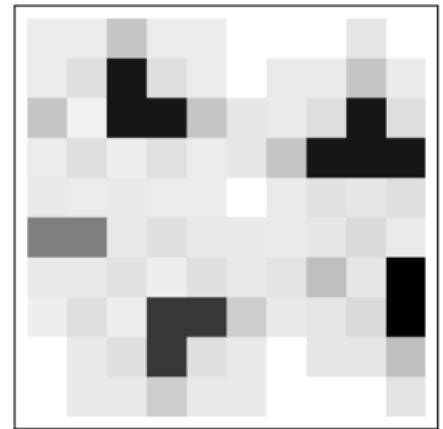
Transformación de datos



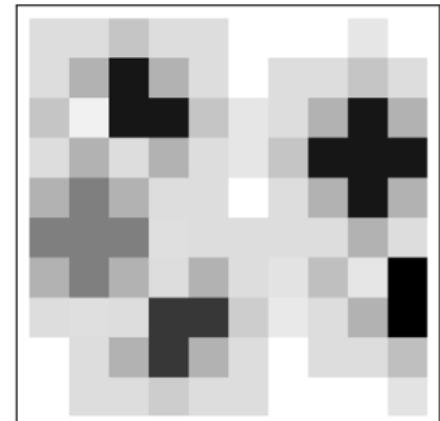
Be07	Be08	Be09	Be10	Be11	Sector
-65	-61	-74	-73	-67	1
-60	-57	-83	-62	-69	2
-66	-70	-78	-63	-73	3
...
-58	-66	-71	-73	-69	14
-60	-62	-73	-69	-57	15



(a) Without blurring.

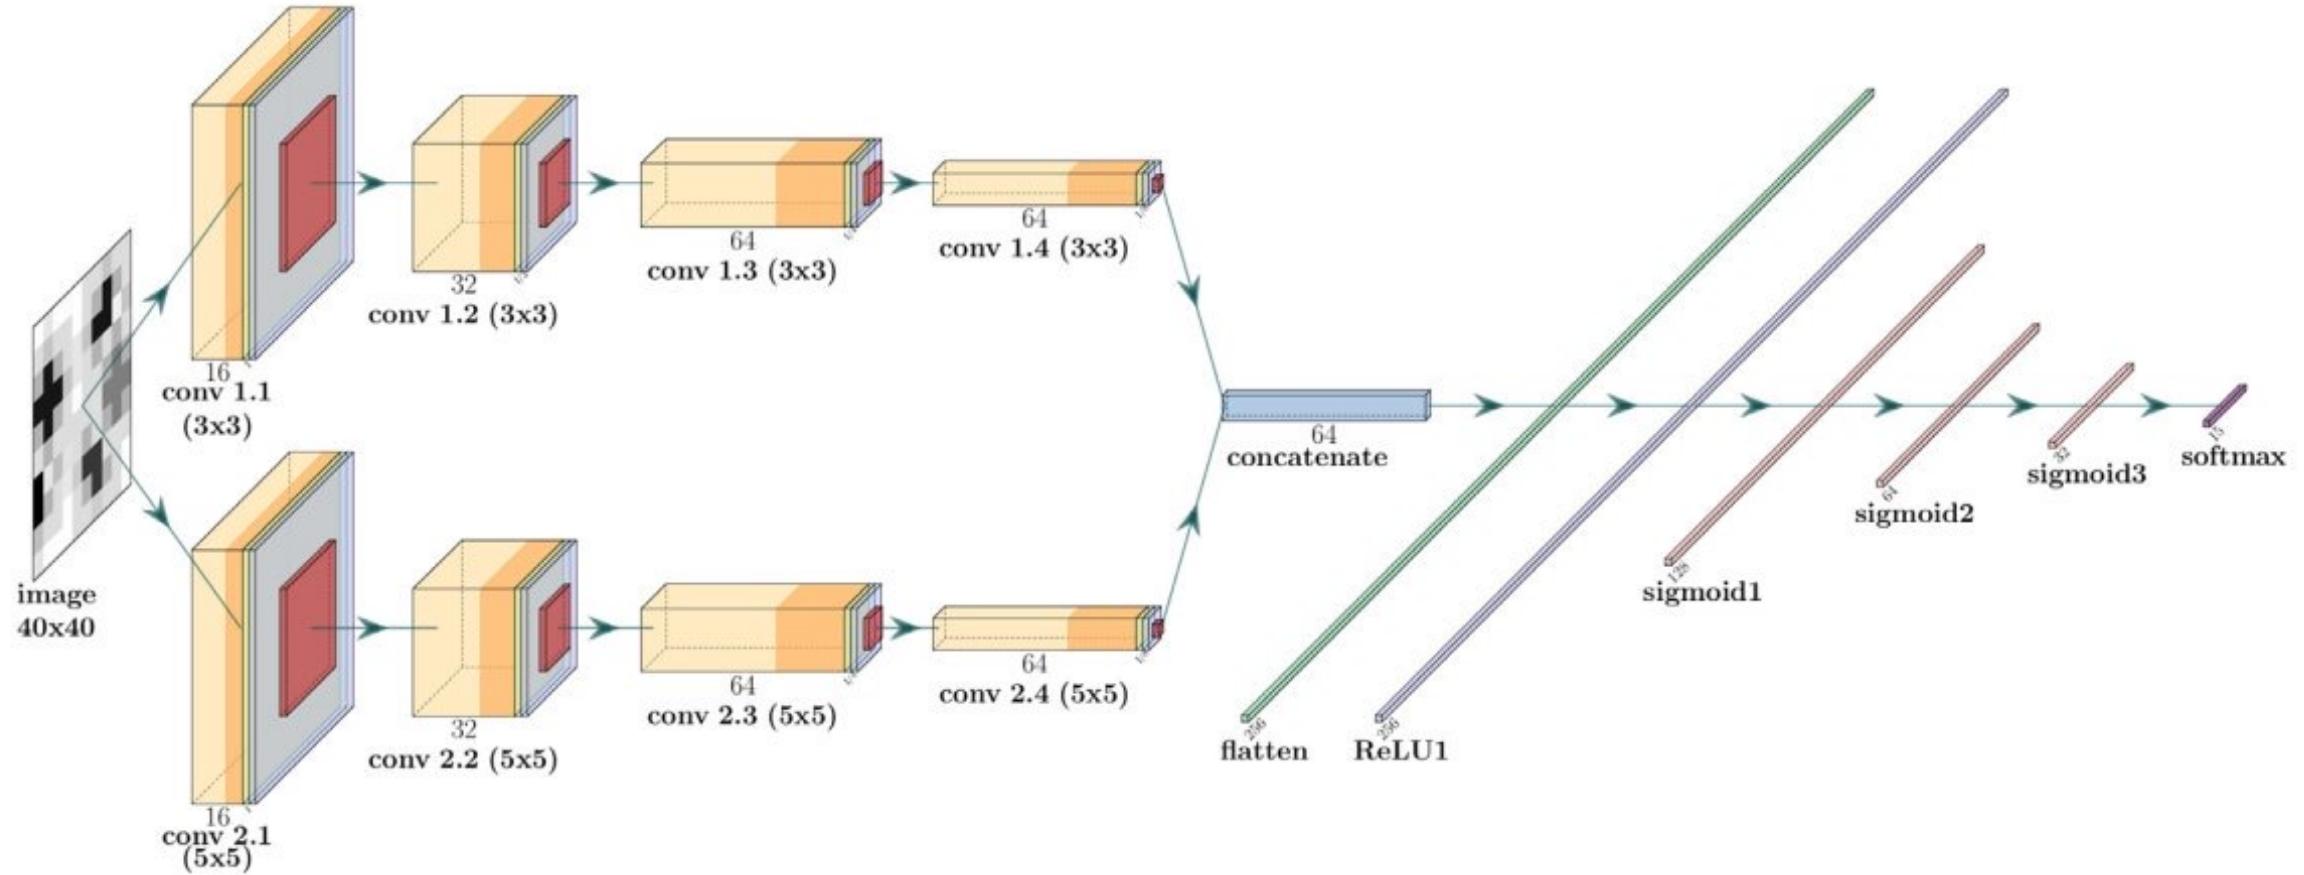
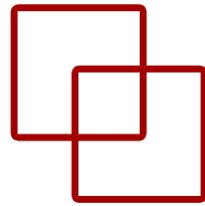


(b) Blurring with average value.

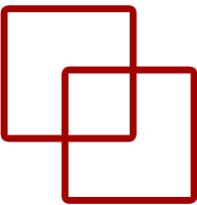


(c) Blurring with maximum value.

Arquitectura Convolucional



Resultados TINTO



Con modelos clásicos

Model	TxPower Setting	Acc	ME	RT
LoR	[4-1-2-3-1]	76.71	0.487	10.001
LDA	[6-1-3-3-5]	77.60	0.481	0.031
GNB	[4-1-2-6-1]	86.01	0.289	0.020
MLP	[4-1-4-6-1]	72.21	0.613	3.660
SVM	[6-6-3-3-5]	83.00	0.512	2.881
DT	[6-1-3-3-5]	85.80	0.326	0.020
<i>k</i> -NN	[6-1-3-6-1]	87.87	0.249	0.031
RF	[6-1-3-3-5]	90.56	0.201	0.082
ET	[6-1-3-3-5]	91.03	0.209	0.050
GBM	[6-1-3-3-5]	91.87	0.180	3.269
AB	[6-1-3-3-1]	89.24	0.242	3.907
VC	[6-1-3-3-5]	92.08	0.181	3.365

Con CNN

TxPower	Alg.	Blurring	Acc	Loss	ME (m)
[3-6-6-3-1]	PCA	Max.	93.94	0.254	0.148
[3-6-1-3-5]	<i>t</i> -SNE	Max.	93.35	0.283	0.157
[3-6-1-3-2]	PCA	Aver.	92.91	0.364	0.161
[3-4-1-2-2]	<i>t</i> -SNE	Aver.	92.54	0.373	0.173

‘Caso de uso 2: Localización en interiores con MIMO

ETS de
Ingeniería
Informática



UNED

Escenario

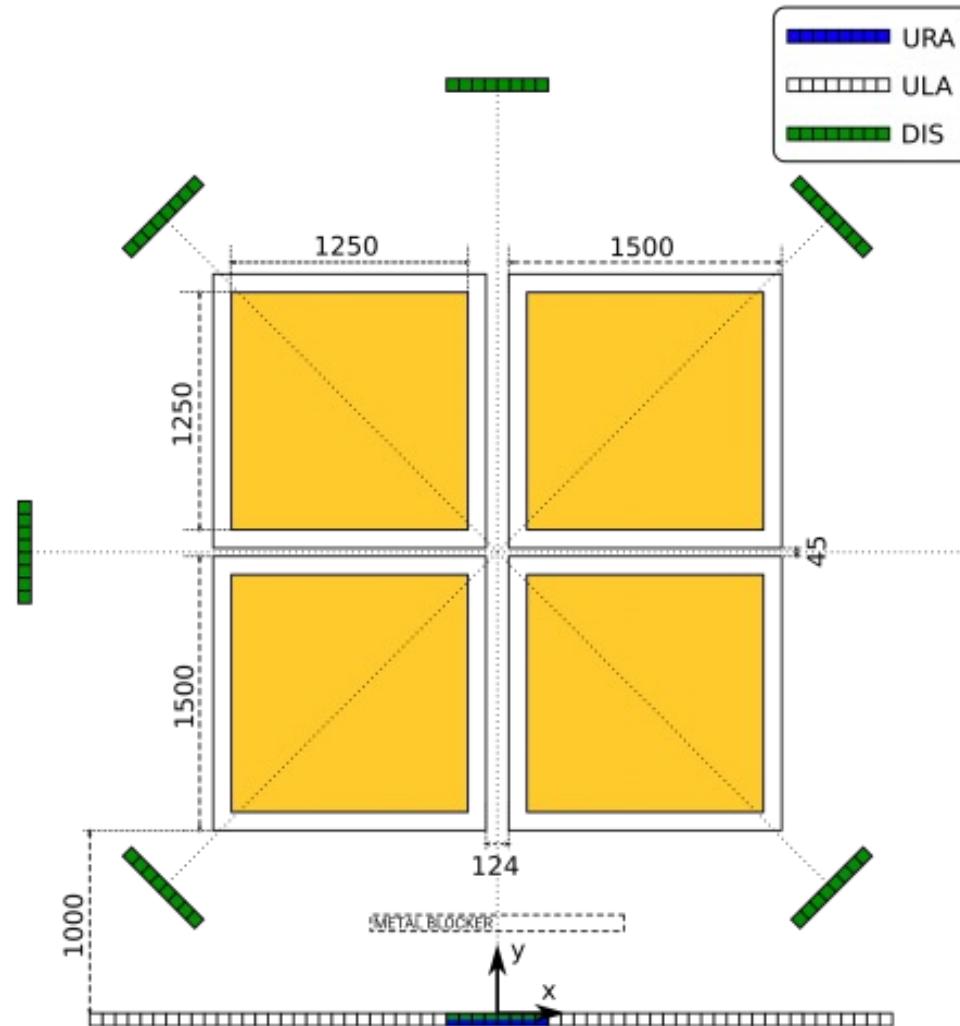
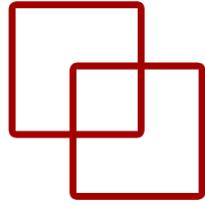
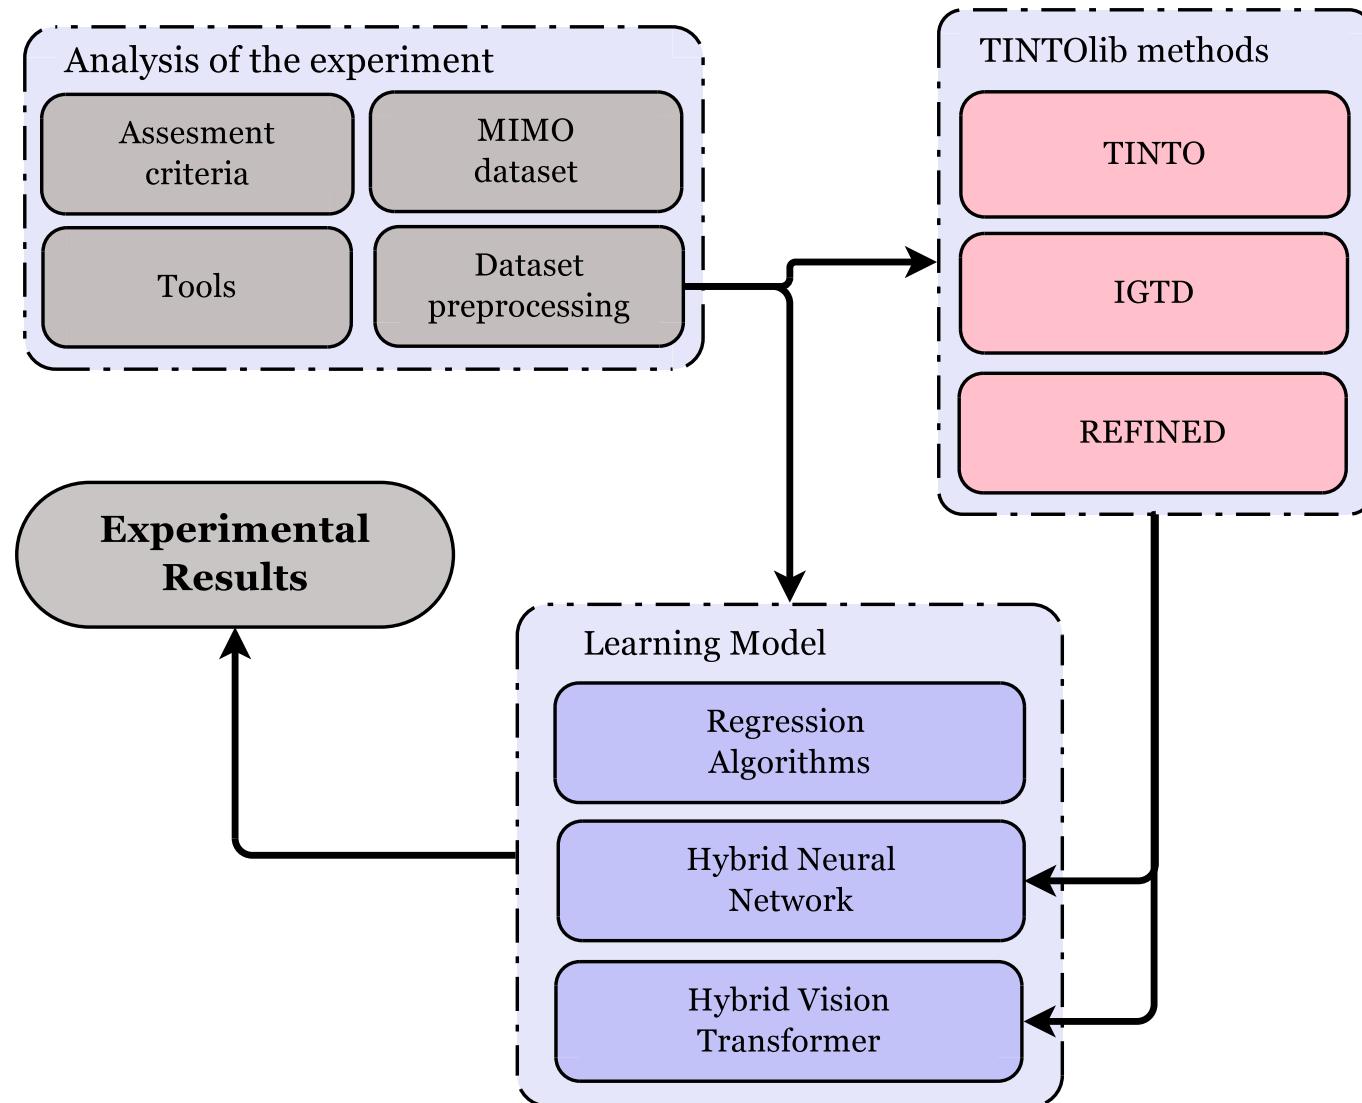
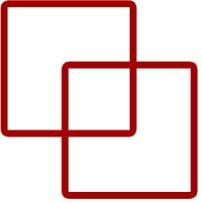
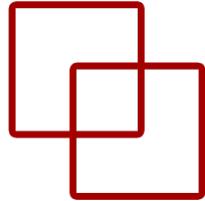


Figure taken from the paper: S. D. Bast, A. P. Guevara and S. Pollin, "CSI-based Positioning in Massive MIMO systems using Convolutional Neural Networks," 2020 IEEE 91st Vehicular Technology Conference (VTC2020-Spring), Antwerp, Belgium, 2020, pp. 1-5

Metodología



Imágenes sintéticas



A1C1- <i>m</i>	A1C1- ϕ	A1C2- <i>m</i>	A1C2- ϕ	...	PosX	PosY
0.276	0.6350	0.2938	0.6248	...	302	2395
0.561	-2.410	0.557	-2.44	...	722	3984
...
...
...
0.126	0.588	0.138	0.501	...	-892	3994
0.150	-1.999	0.143	-1.961	...	-1217	1225

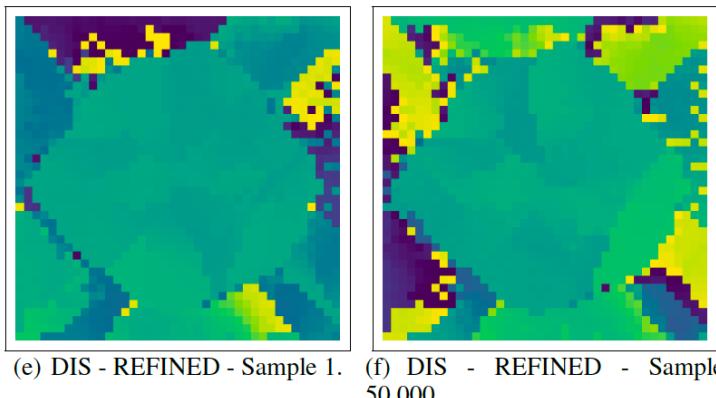
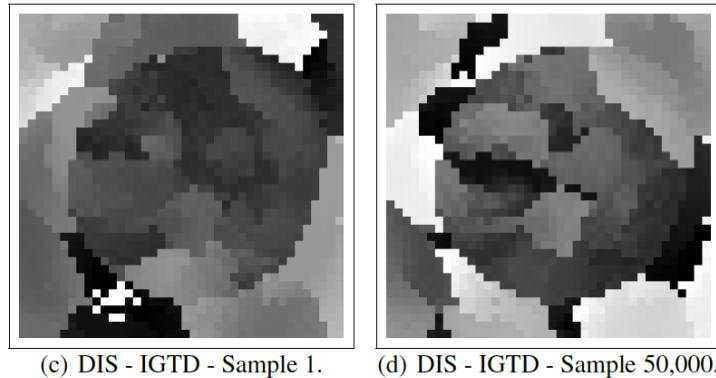
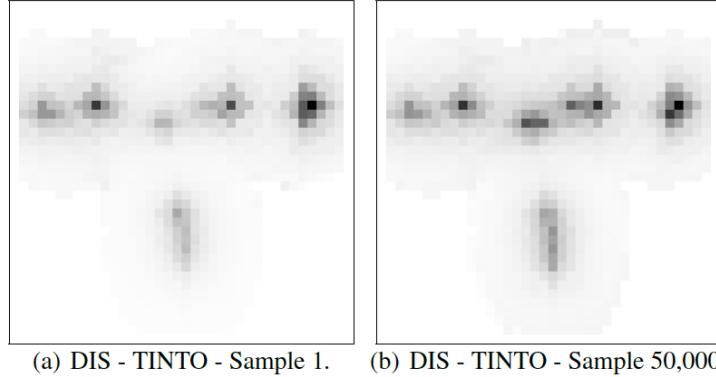
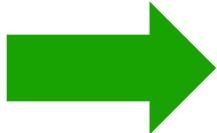
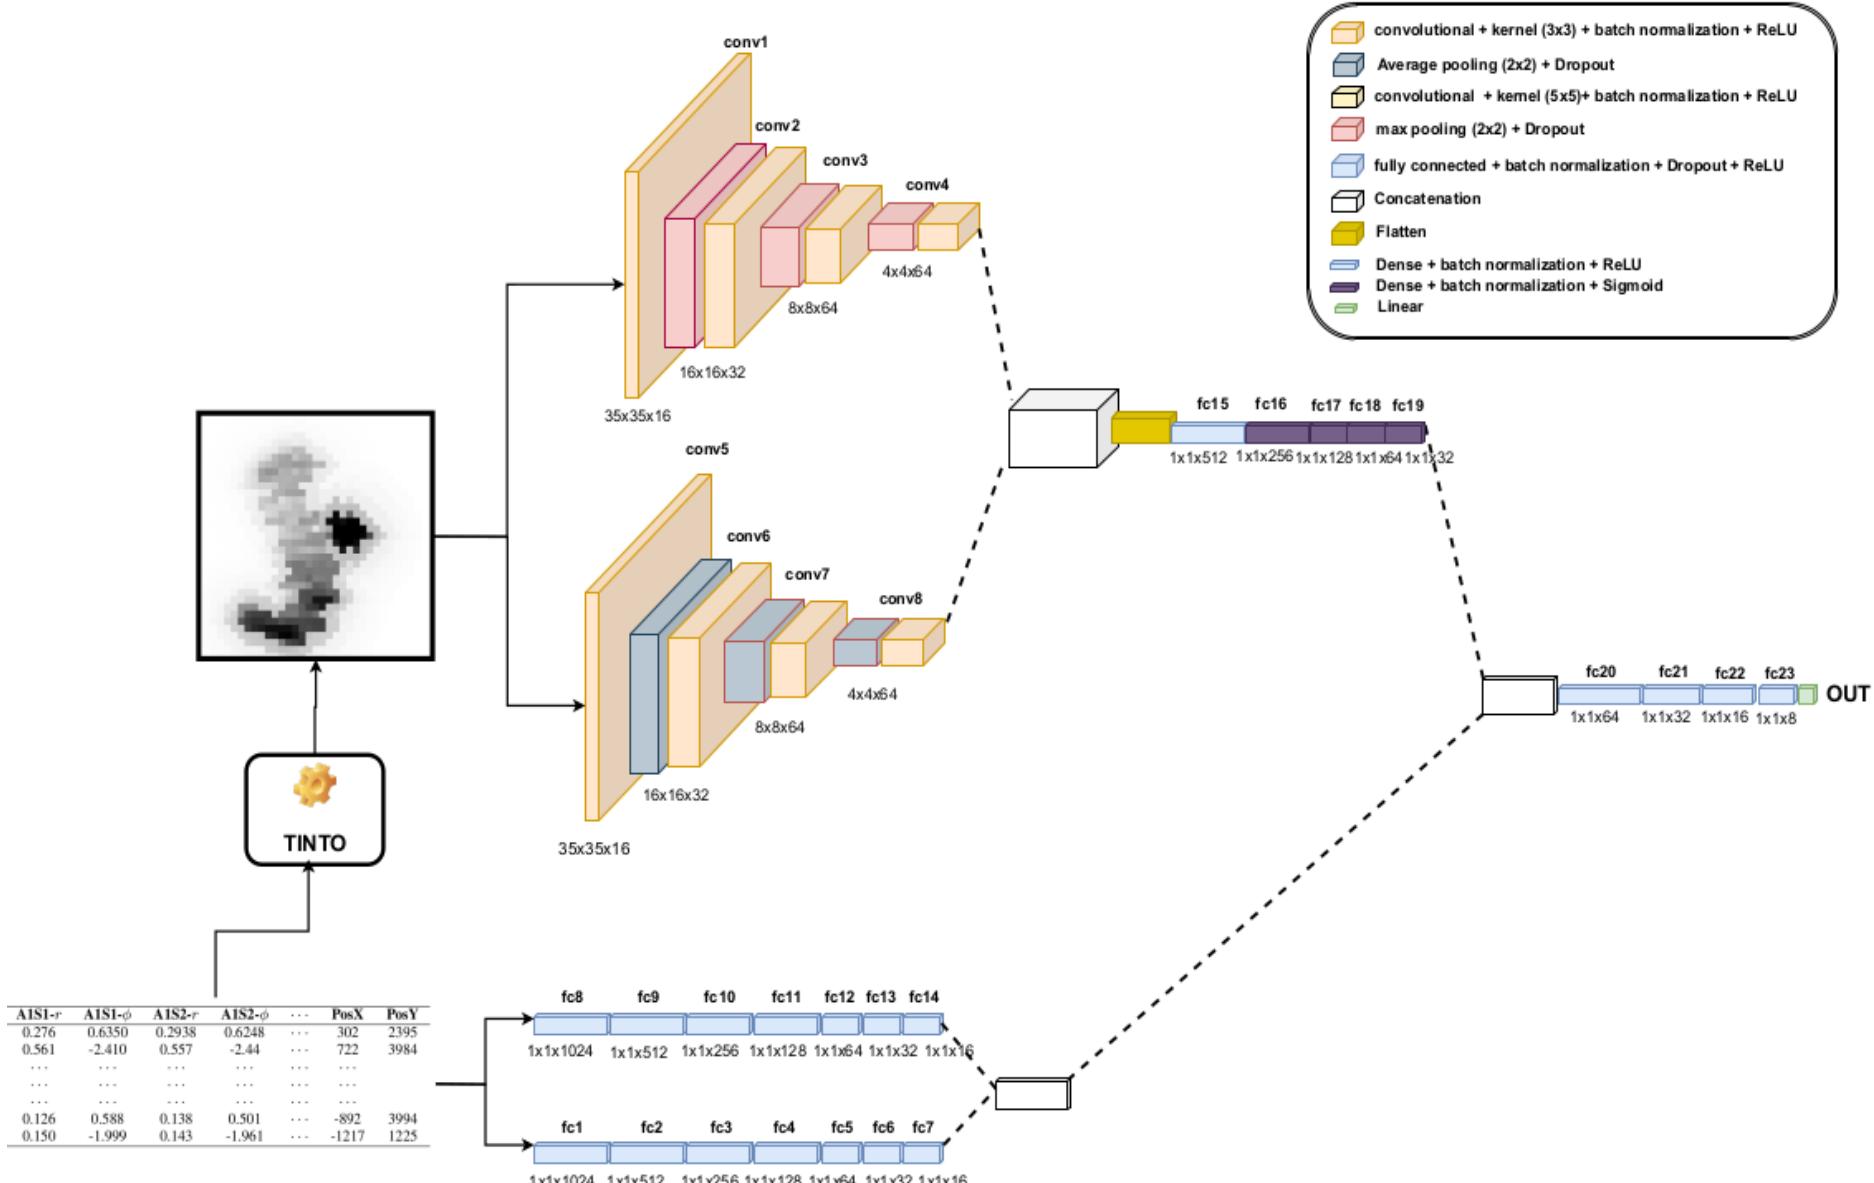
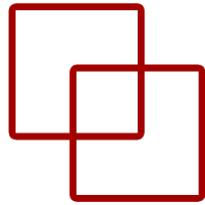
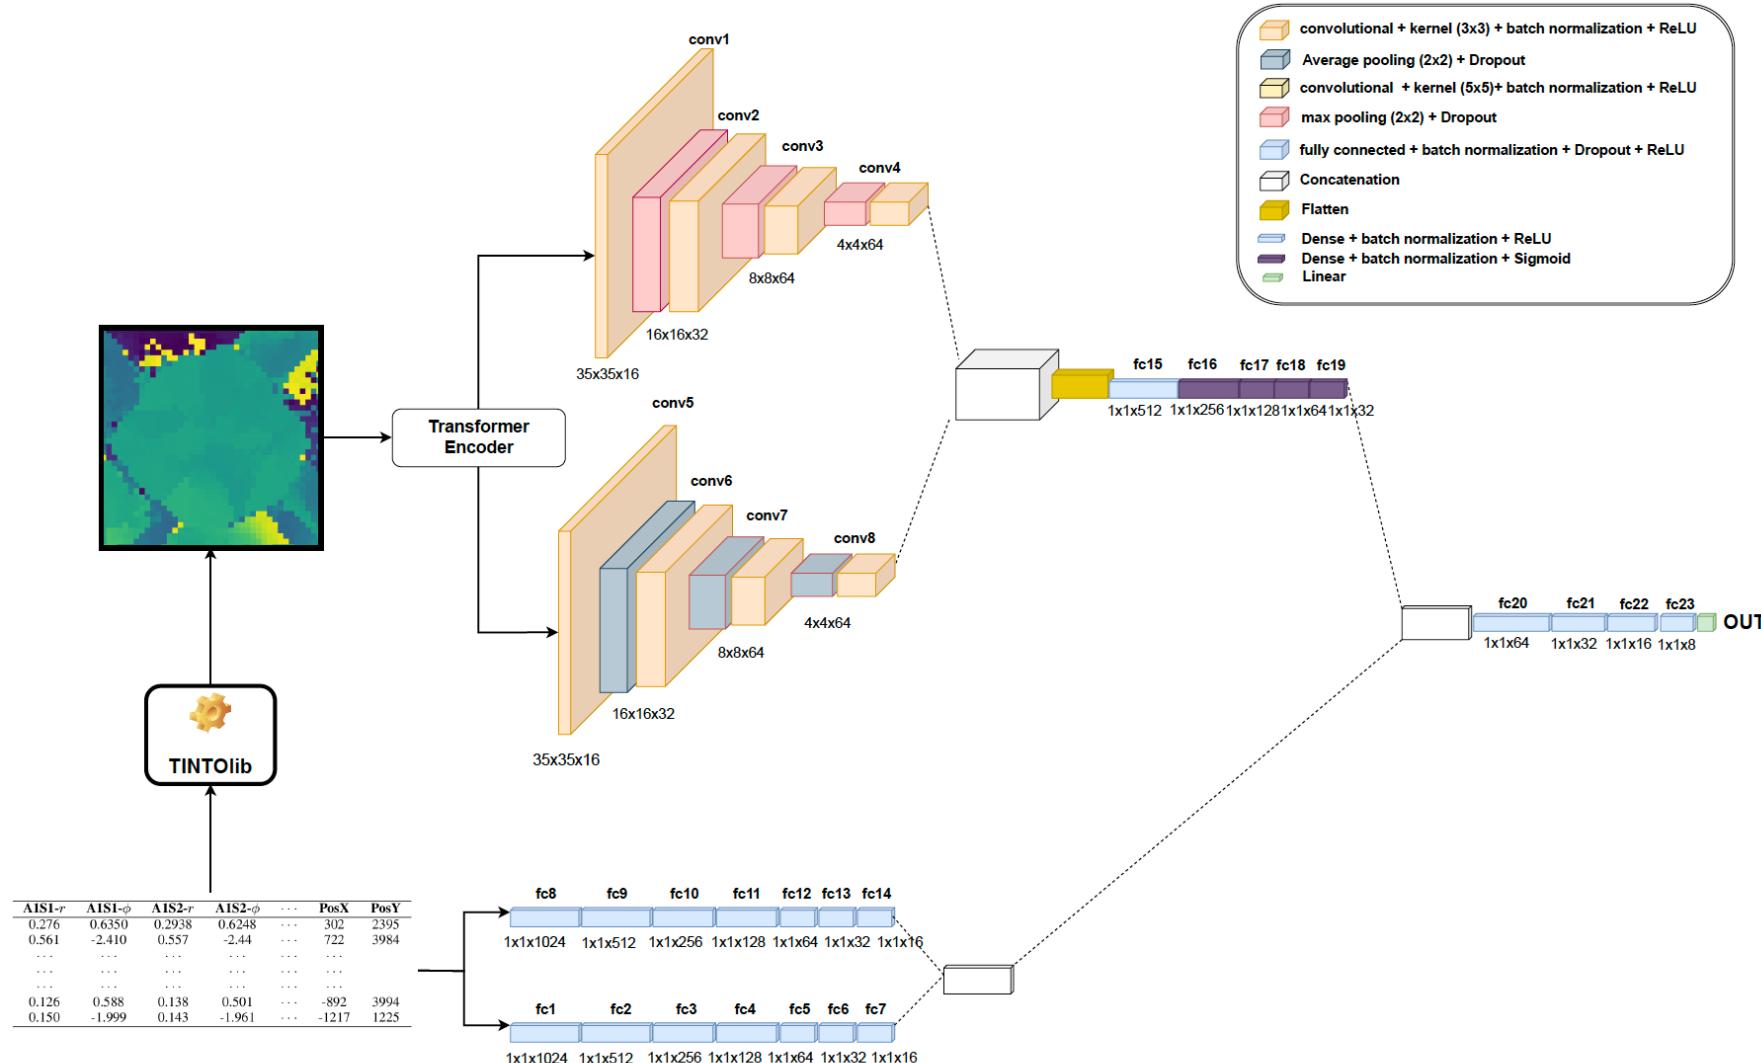
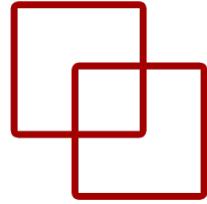


Figure 3. Synthetic image samples generated by TINTOlib for different samples in 8 antennas DIS scenario.

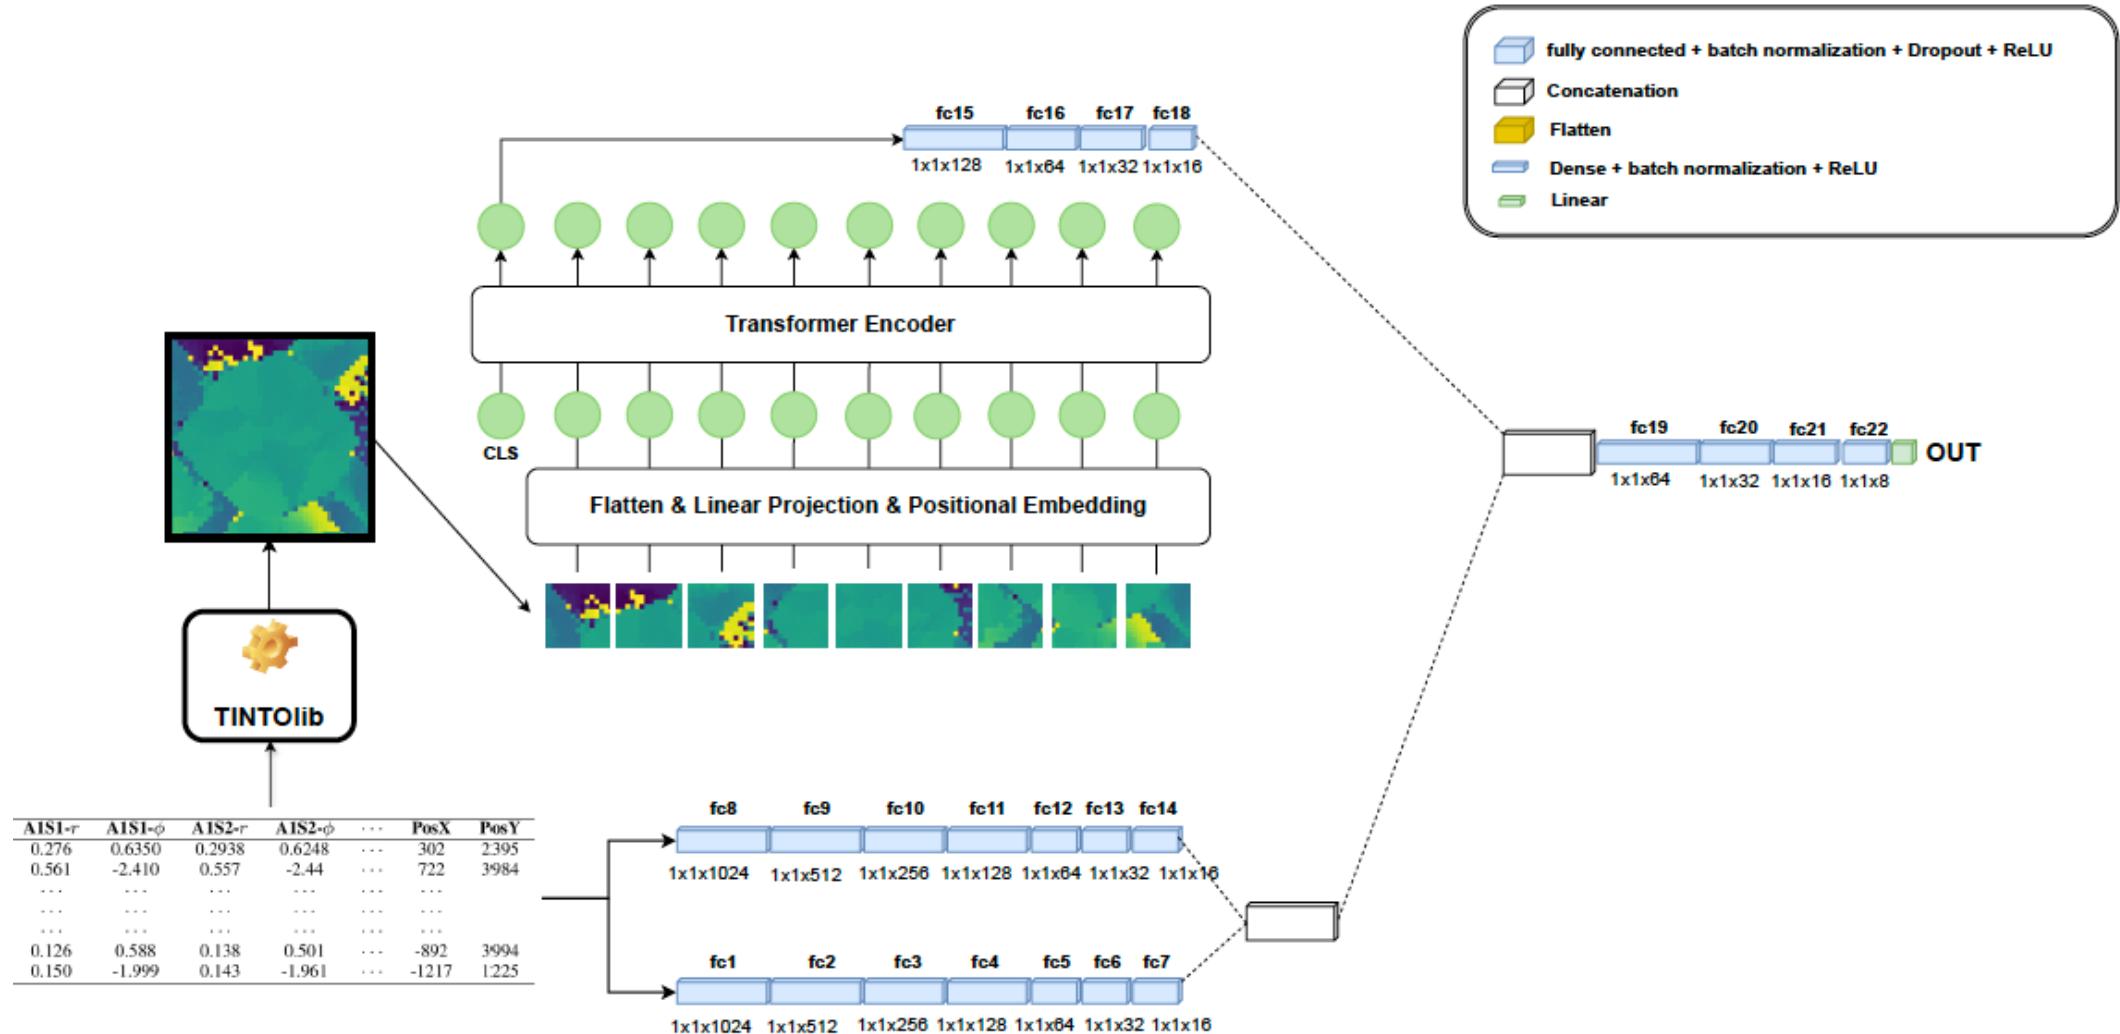
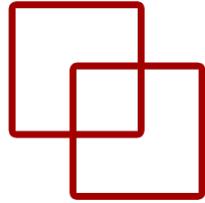
HyNN → CNN+MLP



HyNN → Encoder+CNN+MLP



HyViT → ViT+MLP



Baseline Results

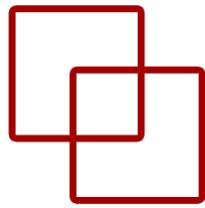


Table 2. RMSE (in mm) in validation (Val) and test split. Best results are shown in bold.

Algorithm	PosX		PosY	
	Val	Test	Val	Test
BR	226.05	225.00	251.43	255.54
ET	163.15	161.65	180.00	185.70
HGB	194.10	194.97	236.55	236.46
KNN	110.50	110.54	133.70	140.16
LiR	383.05	386.95	432.83	439.10
MLP	179.80	178.82	326.11	334.76
RF	226.09	225.18	251.37	255.62
RCV	383.04	386.94	432.80	439.06
XGB	178.41	180.03	202.45	201.66
LGB	194.14	194.15	231.19	232.89

Hybrid Neural Networks Results

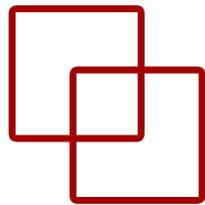


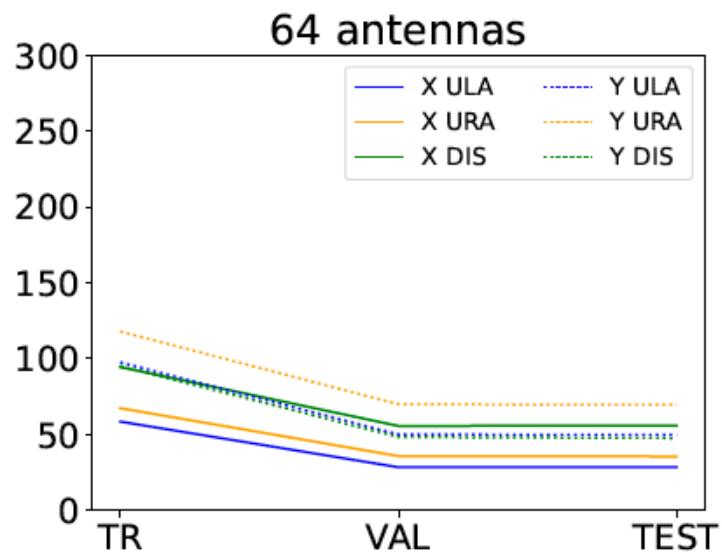
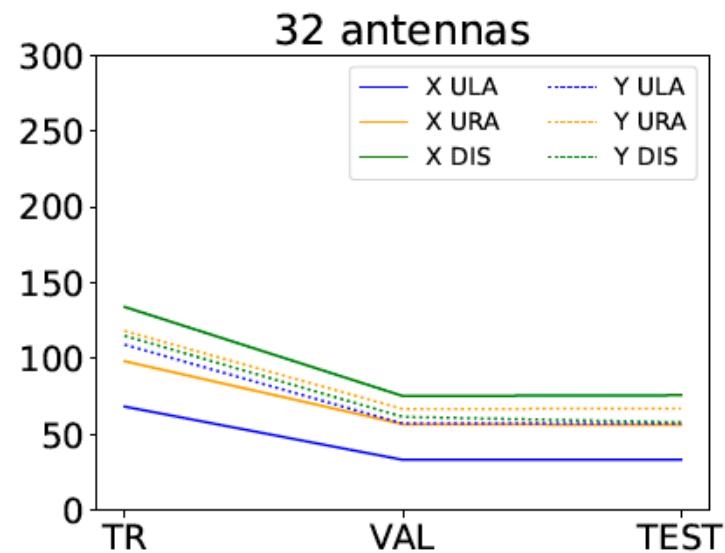
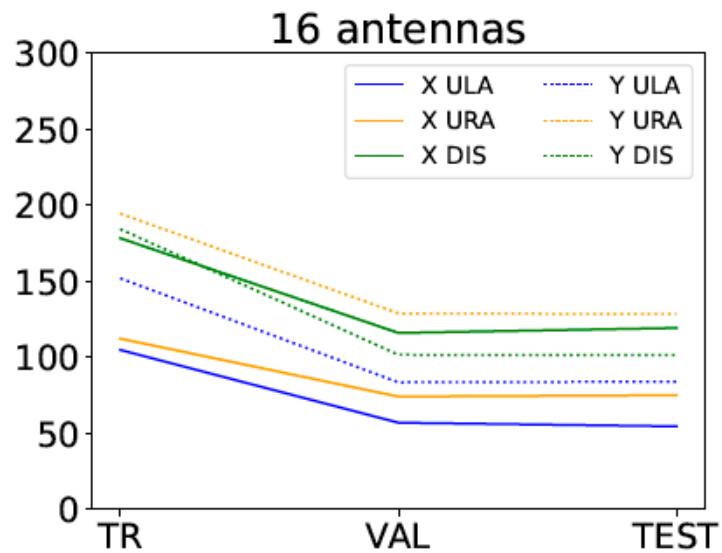
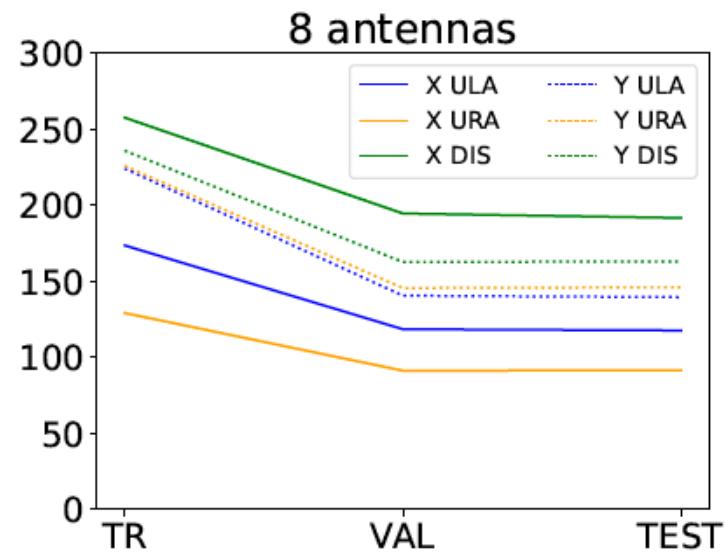
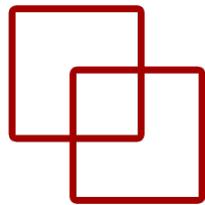
Table 2. RMSE (in mm) in validation (Val) and test split. Best results are shown in bold.

Algorithm	PosX		PosY	
	Val	Test	Val	Test
BR	226.05	225.00	251.43	255.54
ET	163.15	161.65	180.00	185.70
HGB	194.10	194.97	236.55	236.46
KNN	110.50	110.54	133.70	140.16
LiR	383.05	386.95	432.83	439.10
MLP	179.80	178.82	326.11	334.76
RF	226.09	225.18	251.37	255.62
RCV	383.04	386.94	432.80	439.06
XGB	178.41	180.03	202.45	201.66
LGB	194.14	194.15	231.19	232.89

Table 3. RMSE (in mm) for the different HyNNs architectures and HyViT in Validation (Val) and test. Best results are shown in bold.

Position	Model	TINTO		IGTD		REFINED	
		Val	Test	Val	Test	Val	Test
PosX	HyCNN	187.10	188.10	92.8	92.21	105.69	105.38
	HyTNN	178.28	179.25	119.59	119.62	115.90	114.98
	HyTTNN	181.96	184.19	179.01	180.05	193.56	196.09
	HyGTNN	176.71	176.43	173.42	174.20	173.38	174.02
	HyViT	103.27	104.17	46.57	45.77	41.38	41.84
PosY	HyCNN	152.19	151.94	101.01	99.45	115.40	114.69
	HyTNN	143.10	143.29	95.95	95.83	112.27	112.02
	HyTTNN	151.35	151.97	155.35	154.12	147.22	146.01
	HyGTNN	155.06	153.40	154.68	154.50	157.10	155.39
	HyViT	121.77	123.90	70.84	68.93	90.11	90.56

Inferencia



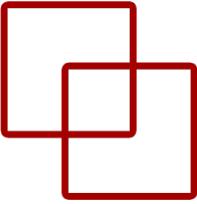
Más
información

ETS de
Ingeniería
Informática



UNED

Más información



- Documentación oficial de TINTOlib:
<https://tintolib.readthedocs.io/en/latest/>
- Librería TINTOlib en PyPI: <https://pypi.org/project/TINTOlib/>
- GitHub con el código de TINTOlib: <https://github.com/oeg-upm/TINTOlib>
- GitHub con el código de TINTO: <https://github.com/oeg-upm/TINTO>
- Artículo sobre TINTO y su aplicación en indoor localization. Incluye la definición formal matemática:
<https://doi.org/10.1016/j.inffus.2022.10.011>
- Artículo sobre TINTO y su definición formal en Python:
<https://doi.org/10.1016/j.softx.2023.101391>



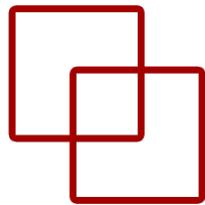
Challenge

ETS de
Ingeniería
Informática



UNED

Datasets



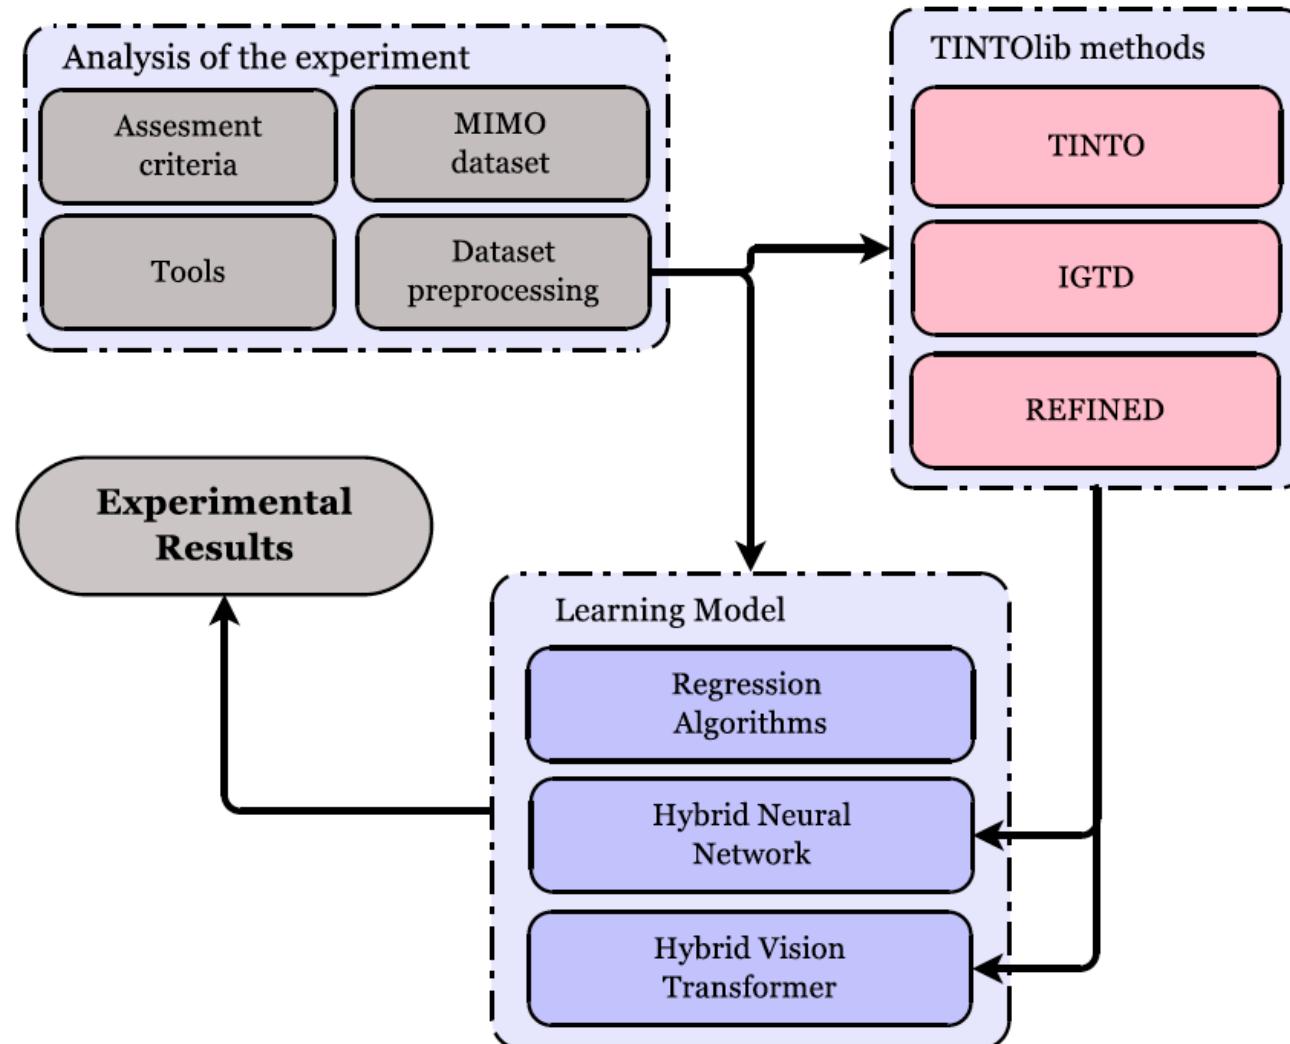
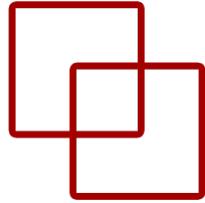
	HELOC	Adult Income	HIGGS	Covertype	California Housing
#Samples	9.871	32.561	11 M.	581.012	20.640
#Num. features	21	6	27	52	8
#Cat. features	2	8	1	2	0
Task	Binary	Binary	Binary	Multi-Class	Regression
#Classes	2	2	2	7	-

V. Borisov *et al.* (2023), "Deep Neural Networks and Tabular Data: A Survey," in IEEE Transactions on Neural Networks and Learning Systems

Data set	Classes	Total	Features
Arboviruses/Inconclusive	Arboviruses	11448	27
	Inconclusive		
Dengue/Chikungunya	Dengue	11448	
	Chikungunya		

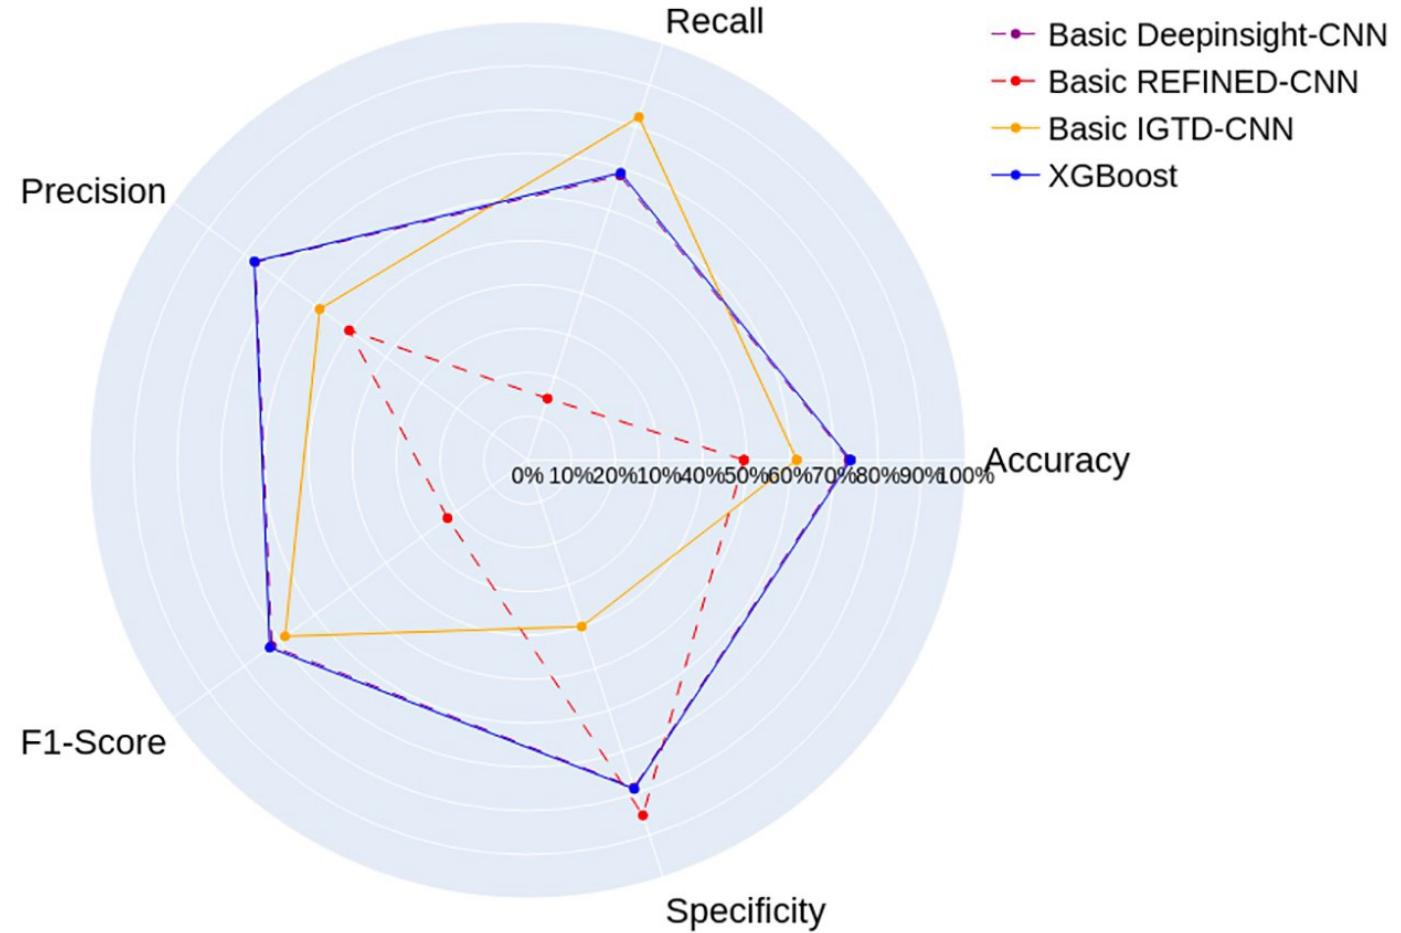
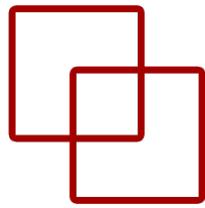
Medeiros Neto, L., et al. (2023). A comparative analysis of converters of tabular data into image for the classification of Arboviruses using Convolutional Neural Networks. Plos one, 18(12),

Challenge



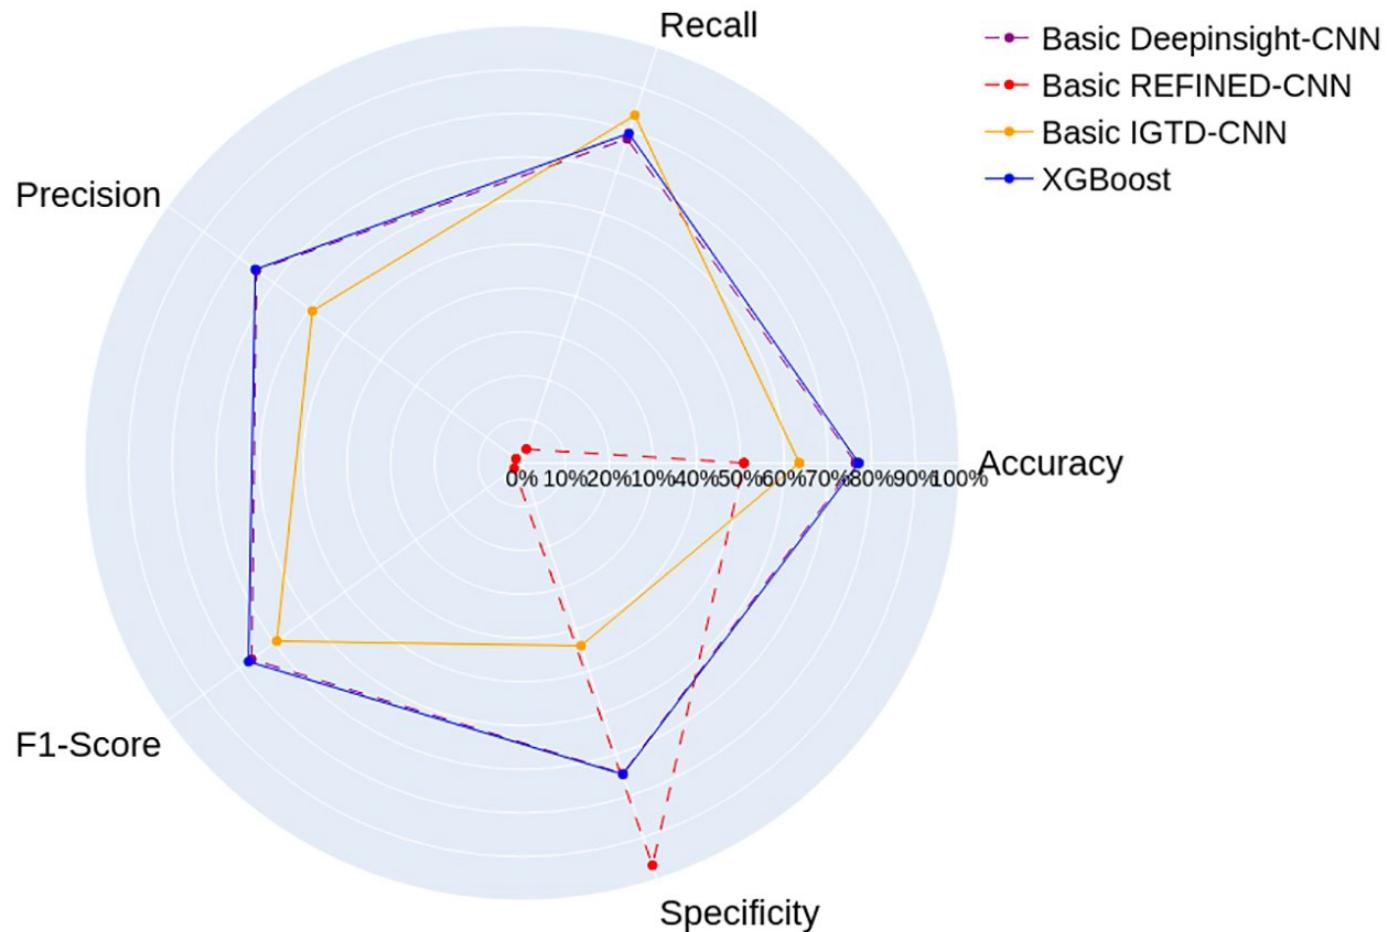
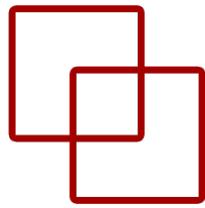
Results

Arboviruses/Inconclusive data set

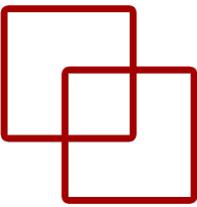


Results

Dengue/Chikungunya data set



Results



	Method	HELOC		Adult		HIGGS		Covertype		Cal. Housing
		Acc ↑	AUC ↑	MSE ↓						
Machine Learning	Linear Model	73.0±0.0	80.1±0.1	82.5±0.2	85.4±0.2	64.1±0.0	68.4±0.0	72.4±0.0	92.8±0.0	0.528±0.008
	KNN [58]	72.2±0.0	79.0±0.1	83.2±0.2	87.5±0.2	62.3±0.1	67.1±0.0	70.2±0.1	90.1±0.2	0.421±0.009
	Decision Trees [195]	80.3±0.0	89.3±0.1	85.3±0.2	89.8±0.1	71.3±0.0	78.7±0.0	79.1±0.0	95.0±0.0	0.404±0.007
	Random Forest [196]	82.1±0.2	90.0±0.2	86.1±0.2	91.7±0.2	71.9±0.0	79.7±0.0	78.1±0.1	96.1±0.0	0.272±0.006
	XGBoost [46]	<u>83.5±0.2</u>	92.2±0.0	<u>87.3±0.2</u>	<u>92.8±0.1</u>	<u>77.6±0.0</u>	<u>85.9±0.0</u>	97.3±0.0	99.9±0.0	0.206±0.005
	LightGBM [70]	<u>83.5±0.1</u>	<u>92.3±0.0</u>	87.4±0.2	92.9±0.1	77.1±0.0	85.5±0.0	93.5±0.0	99.7±0.0	0.195±0.005
	CatBoost [71]	83.6±0.3	92.4±0.1	87.2±0.2	<u>92.8±0.1</u>	77.5±0.0	85.8±0.0	<u>96.4±0.0</u>	<u>99.8±0.0</u>	0.196±0.004
	Model Trees [197]	82.6±0.2	91.5±0.0	85.0±0.2	90.4±0.1	69.8±0.0	76.7±0.0	-	-	0.385±0.019
Deep Learning	MLP [198]	73.2±0.3	80.3±0.1	84.8±0.1	90.3±0.2	77.1±0.0	85.6±0.0	91.0±0.4	76.1±3.0	0.263±0.008
	VIME [79]	72.7±0.0	79.2±0.0	84.8±0.2	90.5±0.2	76.9±0.2	85.5±0.1	90.9±0.1	82.9±0.7	0.275±0.007
	DeepFM [15]	73.6±0.2	80.4±0.1	86.1±0.2	91.7±0.1	76.9±0.0	83.4±0.0	-	-	0.260±0.006
	DeepGBM [62]	78.0±0.4	84.1±0.1	84.6±0.3	90.8±0.1	74.5±0.0	83.0±0.0	-	-	0.856±0.065
	NODE [7]	79.8±0.2	87.5±0.2	85.6±0.3	91.1±0.2	76.9±0.1	85.4±0.1	89.9±0.1	98.7±0.0	0.276±0.005
	NAM [85]	73.3±0.1	80.7±0.3	83.4±0.1	86.6±0.1	53.9±0.6	55.0±1.2	-	-	0.725±0.022
	Net-DNF [50]	82.6±0.4	91.5±0.2	85.7±0.2	91.3±0.1	76.6±0.1	85.1±0.1	94.2±0.1	99.1±0.0	-
	TabNet [6]	81.0±0.1	90.0±0.1	85.4±0.2	91.1±0.1	76.5±1.3	84.9±1.4	93.1±0.2	99.4±0.0	0.346±0.007
	TabTransformer [90]	73.3±0.1	80.1±0.2	85.2±0.2	90.6±0.2	73.8±0.0	81.9±0.0	76.5±0.3	72.9±2.3	0.451±0.014
	SAINT [9]	82.1±0.3	90.7±0.2	86.1±0.3	91.6±0.2	79.8±0.0	88.3±0.0	96.3±0.1	<u>99.8±0.0</u>	0.226±0.004
	RLN [63]	73.2±0.4	80.1±0.4	81.0±1.6	75.9±8.2	71.8±0.2	79.4±0.2	77.2±1.5	92.0±0.9	0.348±0.013
	STG [93]	73.1±0.1	80.0±0.1	85.4±0.1	90.9±0.1	73.9±0.1	81.9±0.1	81.8±0.3	96.2±0.0	0.285±0.006

¡Gracias!



Dr. Manuel Castillo-Cara
www.manuelcastillo.eu

Departamento de Inteligencia Artificial
Escuela Técnica Superior de Ingeniería Informática
Universidad Nacional de Educación a Distancia (UNED)